Раздел 3.2.

Понимание внутреннего устройства моделей

3.2.1. Оцифровка языка: токенизатор

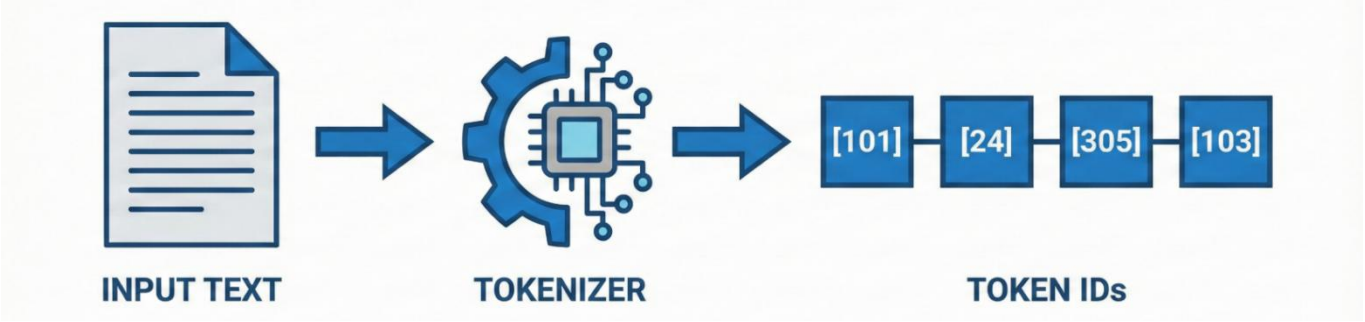
3.2.2. Архитектура Transformer

3.2.3. Предварительное обучение и данные

3.2.4. Понимание процесса вывода (инференса)

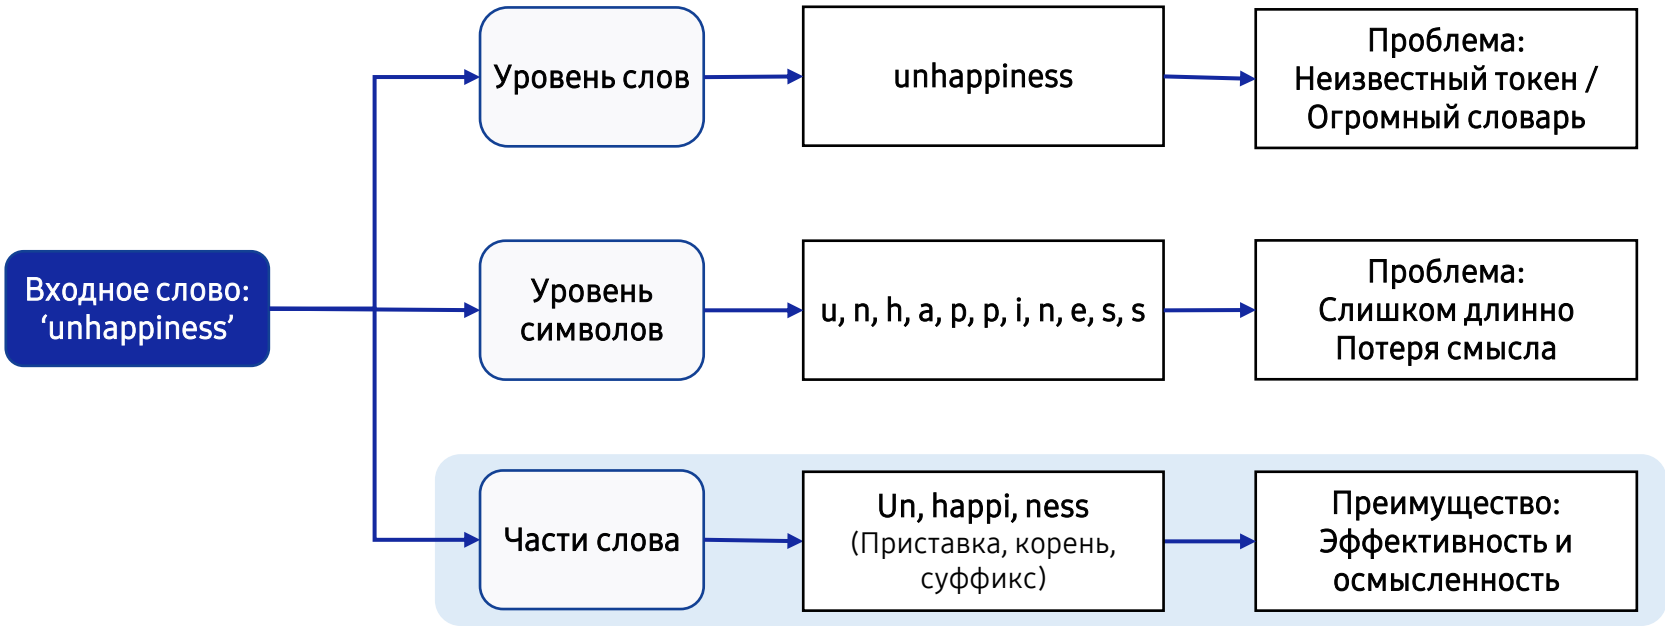
Обзор процесса токенизации

- Преобразование человеческого языка в числовые векторы, понятные машинам.
- Ход процесса:
  - Ввод: "I learn AI" (текст)
  - Токенизация: ["I", "learn", "AI"] (Chunks, фрагменты/чанки)
  - Кодирование: [101, 24, 305, 103] (целочисленные идентификаторы токенов)
- Ключевое понятие:
  - Токен: минимальная единица смысла, которую понимает модель
  - Словарь: набор всех токенов, известных модели



Токенизация на уровне частей слов

- Баланс между размером словаря и сохранением смысла путем разбиения слов на значимые части.

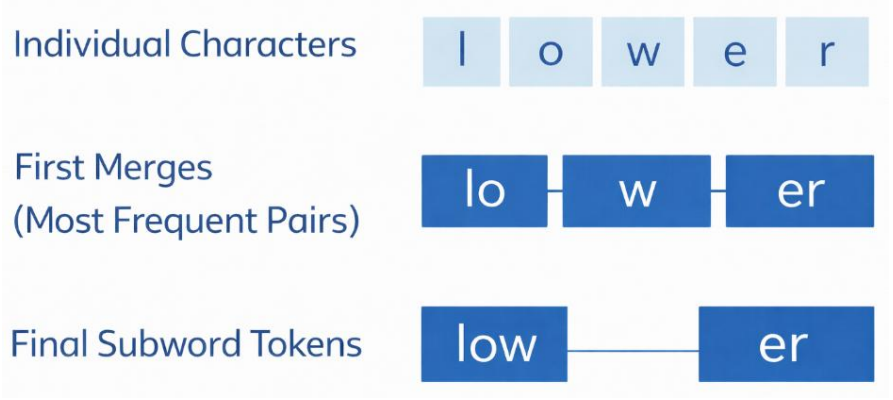


Сравнение уровней токенизации (по словам, по символам, по подсловам)

Алгоритм I: BPE (Byte Pair Encoding)

- Эффективное сжатие текста путем итеративного объединения наиболее часто встречающихся пар символов.
- Механизм: Объединение на основе частотности
  - Итеративно объединяет наиболее часто встречающуюся пару символов.
  - «Если символы часто встречаются вместе, можно объединить их в один токен».
- Используется многими современными большими языковыми моделями (широко принятый стандарт токенизации в LLM)

Как создаются токены подслов



Алгоритм I: BPE в действии (пошагово)

- Создание словаря путем склеивания часто встречающихся букв.
- Сценарий: Корпус = {'hug': 12, 'pug': 6, 'pun': 5, 'bun': 4}
  - Шаг 1. Разделение на символы (инициализация базового словаря): Базовый словарь: h, u, g, p, n, b
  - Шаг 2. Подсчет частых пар: u + g встречается 18 раз (12 из 'hug' + 6 из 'pug')
  - Шаг 3. Объединение и обновление словаря
    - Объединение u + g → ug
    - Обновленный корпус: { 'h ug': 12, 'p ug': 6, 'p un': 5, 'b un': 4 }
  - Повторять до достижения лимита словаря: продолжайте подсчет, объединение и обновление, пока не будет достигнут целевой размер словаря.

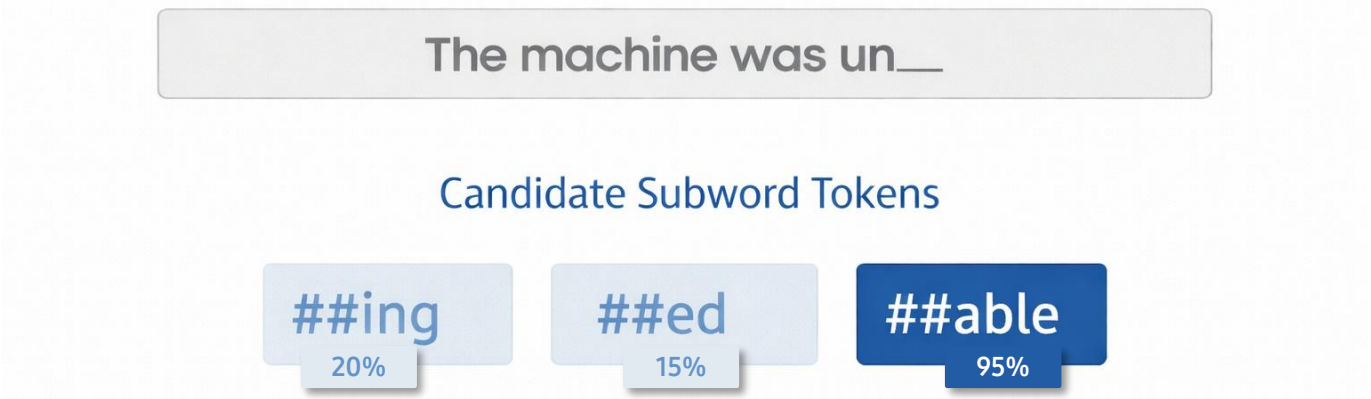
Алгоритм BPE: основные шаги



Алгоритм II: WordPiece

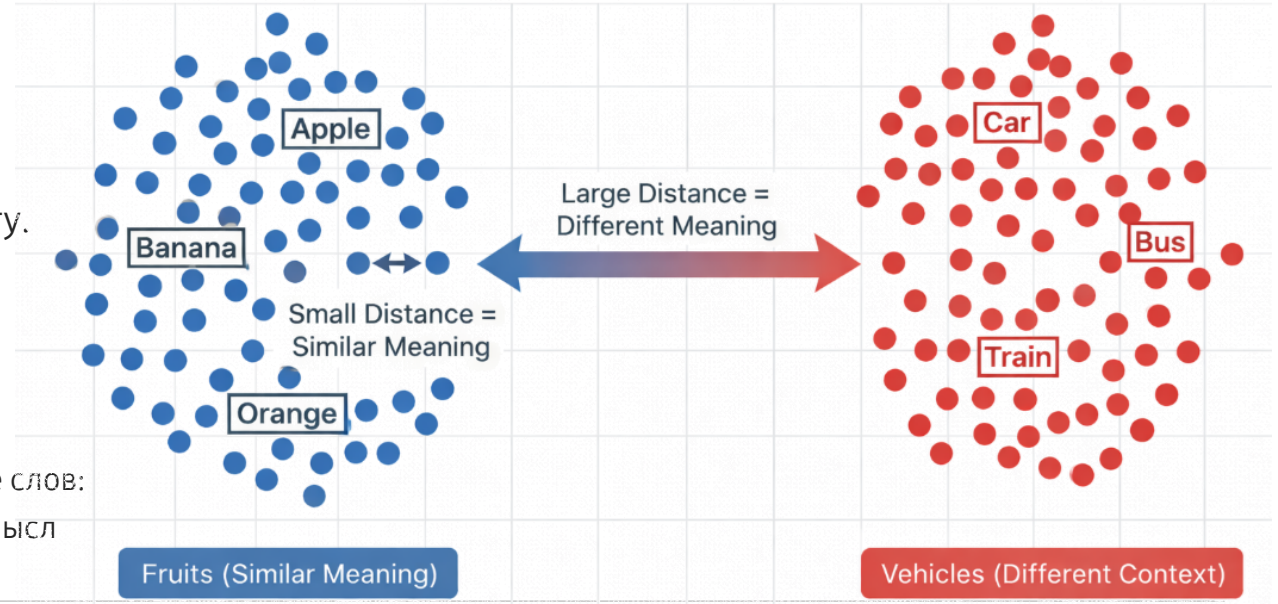
- Оптимизация выбора токенов на основе вероятности, а не только частоты.
- Механизм: объединение на основе правдоподобия
  - Выбирает пары на основе **вероятности предсказания**, а не только частоты.
- Представление:
  - Использует маркер ## для внутренних подслов (например, un, ##afford, ##able).
  - Использование: в BERT, моделях Google.

WordPiece: выбор токенов на основе правдоподобия



От кодов к смыслу: эмбеддинг (Word Embedding)

- **Преобразование идентификаторов токенов в плотные векторы для представления семантической близости.**
- Проблема: идентификаторы токенов (например, 101, 305) — это просто числа, не несущие смысла.
- Решение: преобразование идентификаторов в векторы (координаты) в многомерном пространстве.
- Результат:
  - Слова с похожими значениями и контекстами использованием располагаются ближе друг к другу.
  - "Apple" <-> "Banana" (близко)
  - "Apple" <-> "Car" (далеко)



Векторное представление слов: расстояние отражает смысл

Вычисление смысла с помощью векторов

- Доказательство того, что модель улавливает семантические связи с помощью математических операций
- Векторная арифметика:
  - Семантические связи можно вычислять математически.
- Известный пример:
  - Король - Мужчина + Женщина ≈ Королева
  - Корея - Сеул + Токио ≈ Япония
- Значимость: показывает, что модель способна к аналогическим рассуждениям.

Векторная арифметика для семантического значения

