Раздел 3.2.

Понимание внутреннего устройства моделей

3.2.1. Оцифровка языка: токенизатор

3.2.2. Архитектура Transformer

3.2.3. Предварительное обучение и данные

3.2.4. Понимание процесса вывода (инференса)

От архитектуры к интеллекту

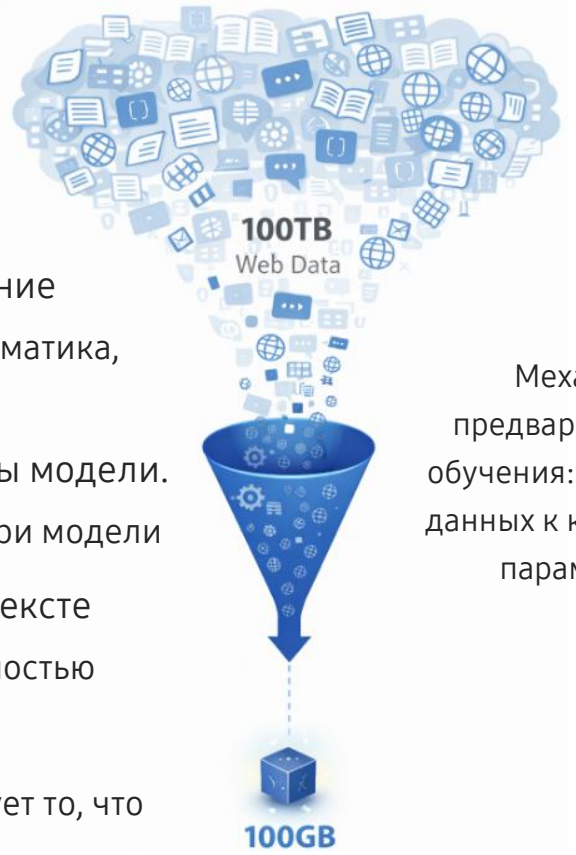
- Превращение потенциала в интеллект:
  внедрение огромных объемов данных для преобразования пустой архитектурной оболочки в базовую модель.



Роль предварительного обучения: от структуры к знаниям

Обучение модели – это поиск закономерностей в массивах данных

- ИИ не хранит информацию как база данных
  - База данных сохраняет точный исходный текст и извлекает его в неизменном виде при необходимости
- Процесс обучения — это поиск закономерностей, а не запоминание
  - Модель изучает часто встречающиеся зависимости, такие как грамматика, выражения и взаимосвязи в данных
- Огромные объемы исходных данных преобразуются в параметры модели.
  - Терабайты текста сводятся к статистическим представлениям внутри модели
- Процесс обучения неизбежно приводит к потере деталей в контексте
  - Точные источники, временные метки и факты сохраняются не полностью
- В результате могут выдаваться гладкие, но ошибочные ответы
  - Это объясняет, почему возникают галлюцинации: модель генерирует то, что вероятно, а не то, что проверено



Механизм предварительного обучения: от больших данных к компактным параметрам

Ингредиенты интеллекта

- Сбалансированная диета для интеллекта:
  веб-тексты для широты охвата, книги для глубины,
  код для логического мышления.
- 1. Веб-тексты (количество):
  - Обширные общедоступные данные дают общие знания о мире и языковых конструкциях.
  - Примеры: Common Crawl, C4 (Colossal Clean Crawled Corpus)*
- 2. Книги и статьи (качество):
  - Выверенные объемные тексты: книги и научные статьи.
  - Дают структурированные знания, богатый словарный запас и понимание длинного контекста.
- 3. Код (логическое мышление):
  - Код и данные из вопросов и ответов обучают логической структуре, пошаговому рассуждению и следованию правилам.
  - Примеры: GitHub, Stack Overflow



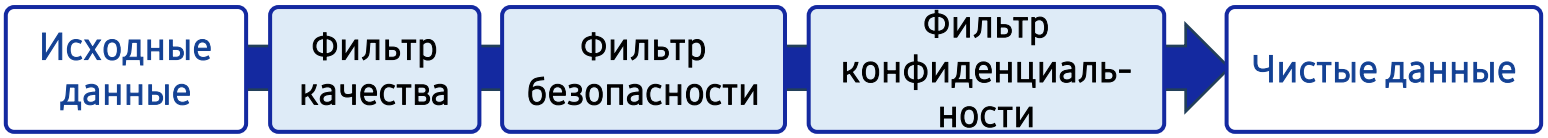
*) Common Crawl — это открытый огромный массив миллиардов веб страниц, используемый для обучения больших языковых моделей, C4 - англоязычное высококачественное подмножество Common Crawl, созданное Google.

Источник логического мышления

- Код как «тренажер логики»: использование строгой структуры программирования обучает модель причинно-следственному мышлению и «цепочке рассуждений» (Chain of Thought).
- Зачем изучать код?
  - Языки программирования обладают строгой логикой и причинно-следственными связями.
  - Если условие → То результат → Иначе альтернатива.
- Эффект:
  - Обучение на коде значительно повышает способности к общему логическому мышлению.
  - Обеспечивает «цепочку рассуждений»: способность модели выполнять **пошаговые внутренние рассуждения**, вместо того чтобы сразу переходить к ответу.

«Мусор на входе – мусор на выходе»: предобработка и фильтрация данных

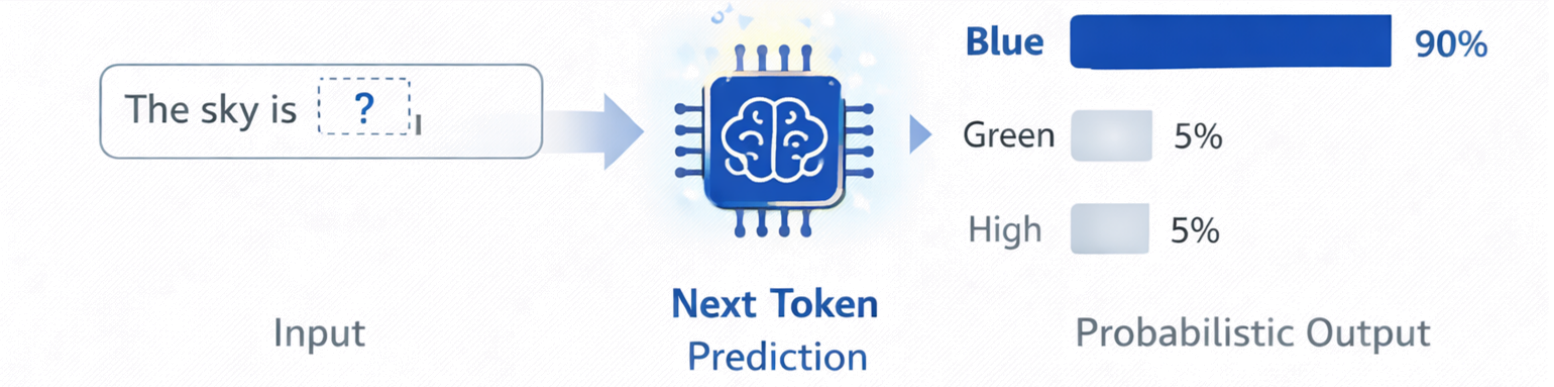
- Понимание принципа «Мусор на входе — мусор на выходе» требует применения строгого трехэтапного конвейера для фильтрации шума, токсичности и конфиденциальных персональных данных (PII).
- Конвейер фильтрации:
  - Фильтр качества: дедупликация (удаление повторяющегося/низкокачественного текста)
  - Фильтр безопасности: удаление токсичности, предвзятости и насилия
  - Фильтр конфиденциальности (корпоративный): маскирование персональных данных (имена, адреса электронной почты, номера телефонов).
- Безопасность корпоративного уровня требует тщательной очистки.



Конвейер фильтрации данных: от сырых к чистым

Предсказание следующего токена

- **Обучение без учителя**: освоение знаний о мире с помощью «самообучения» (Self-Supervised Learning) путем предсказания следующего скрытого токена
- **Самообучение**: разметка человеком не требуется. Сами данные выступают в роли учителя
- **Задача:** «def calculate_sum(a, b): return [?]» → Предсказать «a + b»
- **Масштаб:** повторение этого миллиарды раз создает интеллект



Механизм самообучения

Формула интеллекта: законы роста

Законы роста

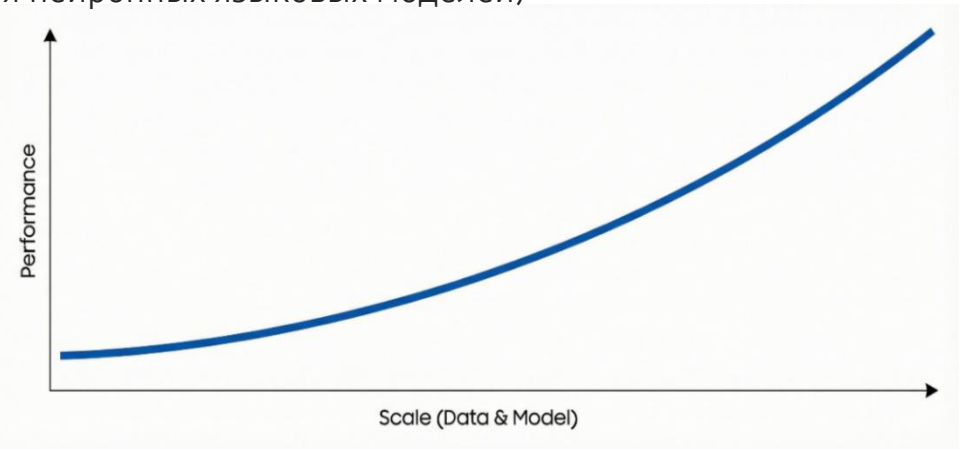
- Производительность растет в геометрической прогрессии в зависимости от размера модели, объема данных и количества вычислительных ресурсов, используемых для обучения.
  (Kaplan et al., 2020 — Законы масштабирования для нейронных языковых моделей)

Ключевая идея

- Масштабирование работает лучше, когда данные содержат **чистые и информативные сигналы**

Почему важно качество данных

- Зашумленные или дублированные данные снижают эффективность обучения и расходуют вычислительные ресурсы впустую



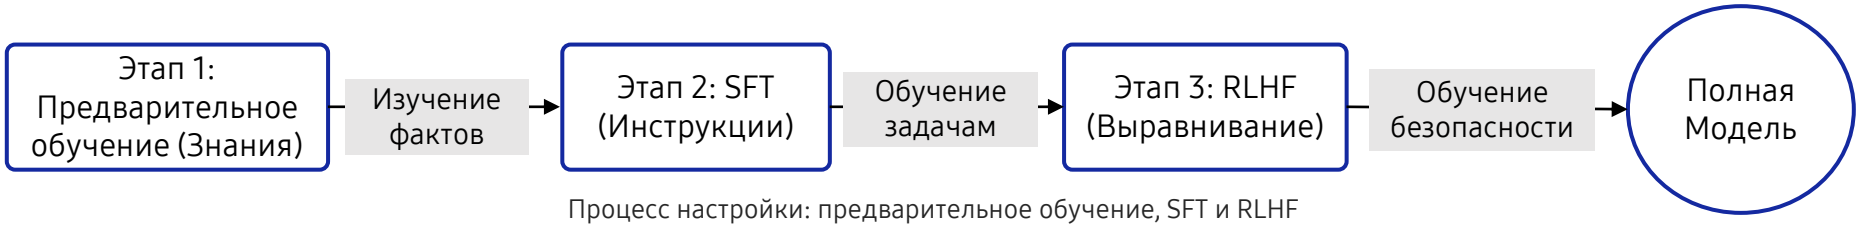
Законы масштабирования: почему качество важнее количества

Современная тенденция

- Меньшие по объему, но высококачественные наборы данных (datasets) часто оказываются эффективнее гораздо больших, но низкокачественных наборов, особенно при ограниченных вычислительных ресурсах

Эволюция: от исходной модели к помощнику

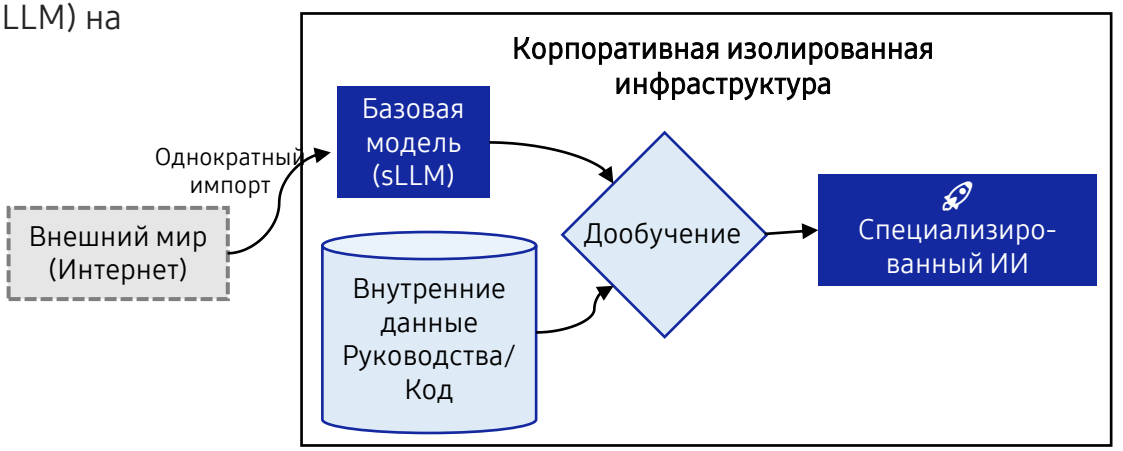
- Трансформация исходной модели в надежного помощника посредством обучения и настройки.
- Этап 1: Предварительное обучение (базовая модель):
  - Изучает общие знания и закономерности на основе обширных данных. (Базовая способность без понимания конкретных задач)
- Этап 2: SFT (Supervised Fine-Tuning, Обучение с учителем):
  - Учится выполнять задачи, следуя инструкциям и примерам (Обучение задачам / профессиональное обучение)
- Этап 3: RLHF (Reinforcement Learning from Human Feedback, Обучение с подкреплением на основе отзывов людей):
  - Изучает предпочтительное поведение, границы безопасности и социальные нормы на основе отзывов людей. (Равнение на человека)



Процесс настройки: предварительное обучение, SFT и RLHF

Корпоративная стратегия: Безопасное дообучение (частный ИИ)

- В целях безопасности: перенос базовой модели во внутренний контур инфраструктуры организации для дообучения специализированного ИИ без утечек данных
- Проблема: публичным моделям общего назначения не хватает «внутренней безопасности и специализированных знаний».
- Решение: дообучение sLLM (малых языковых моделей) в частной инфраструктуре
  - Обучение меньших, эффективных моделей (sLLM) на внутренних руководствах/документах и коде в закрытой сети
- Результат: оптимизированный ИИ, который понимает специфические для предприятия знания без утечки данных.



Корпоративная стратегия: безопасное дообучение и частный ИИ