Раздел 3.2.

Понимание внутреннего устройства моделей

3.2.1. Оцифровка языка: токенизатор

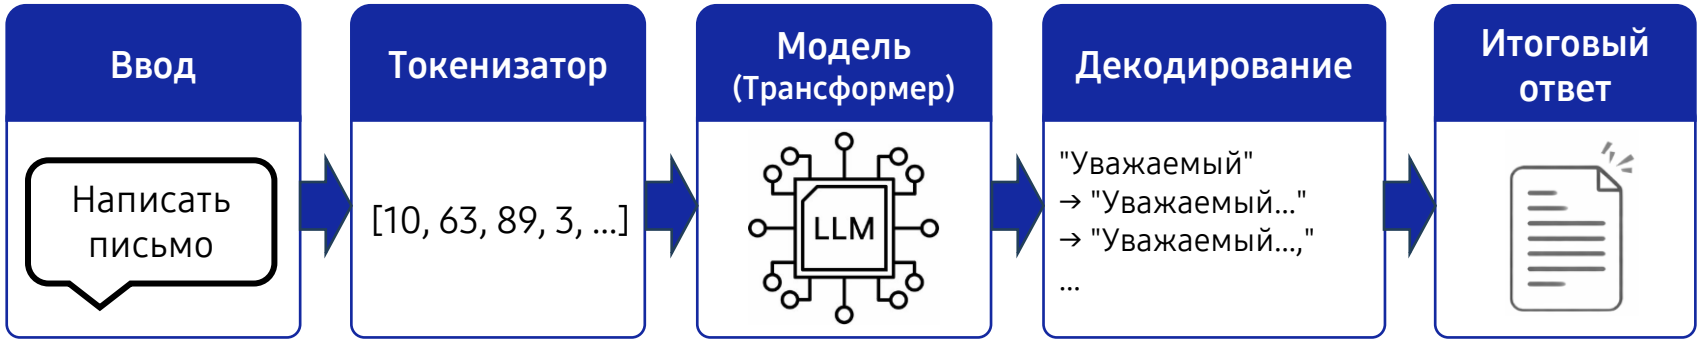
3.2.2. Архитектура Transformer

3.2.3. Предварительное обучение и данные

3.2.4. Понимание процесса вывода (инференса)

Как ИИ дает ответы: конвейер вывода

- От вероятностей к тексту:
  конвейер вывода (inference pipeline) за доли секунды преобразует запросы пользователей в рассчитанные ответы.



Конвейер вывода: ввод, обработка и генерация

Механизм в действии: Авторегрессионный цикл

- Понимание последовательной генерации:
  - «Авторегрессионный цикл» (Autoregressive Loop). Выходные данные модели тут же становятся входными данными для следующего шага.
- Последовательная генерация
  - В отличие от чтения (которое выполняется параллельно), запись происходит по одному слову за раз
- Цикл обратной связи:
  - Текущий вывод становится следующим вводом
  - История накапливается: T1 -> T2 -> T3
- Влияние на производительность:
  - Этот цикл объясняет задержку вывода (Inference Latency).

Стратегия I: Жадный поиск

- Что такое стратегия декодирования?
  - Стратегия декодирования определяет, как модель выбирает следующий токен из предсказанных вероятностей.
  - Различные стратегии управляют балансом между точностью, согласованностью и креативностью в сгенерированном тексте.

- Жадный поиск (Greedy Search): детерминированный подход
  - Последовательный выбор слова с наибольшей вероятностью, идеально подходит для логических задач, таких как математика и программирование.
  - Метод: всегда выбирать слово №1 с наивысшей вероятностью.
  - Лучше всего подходит для: математических задач, логических рассуждений и генерации кода.

Стратегия II: Выборка (Sampling)

Вероятностный подход: введение контролируемой случайности путем «бросания взвешенных костей» для выбора токенов, что обеспечивает креативность и разнообразие выходных данных.

Контролируемая случайность

- Выбор токена определяется вероятностью, а не строгим ранжированием.
- Предпочтение отдается токенам с высокой вероятностью, но возможны и другие варианты

Фильтры качества (Top-k/p)

- Ограничивает выборку набором правдоподобных вариантов.
- Отфильтровывает токены с очень низкой вероятностью и бессмысленные токены.

Человекоподобное творчество

- Генерирует более разнообразные и менее повторяющиеся ответы.
- Хорошо подходит для творческого письма, мозгового штурма и общения.

Контроль креативности: Температура

- Регулировка «ручки креативности»:
  Управление случайностью вывода от точной логики (низкая температура) до сочинительства (высокая температура).
- Низкая температура (0.1 ~ 0.3):
  - Придерживаться высоких вероятностей (сфокусированность, консервативность).
  - Использование: официальные отчеты, написание кода.
- Высокая температура (0.7 ~ 1.0):
  - Дать шанс более низким вероятностям (творчество, непредсказуемость).
  - Использование: мозговой штурм, написание историй.
- Пример применения: управление стилем письма
  - Температура обычно используется в помощниках по написанию текстов для настройки тона — от точного и формального до творческого и непринужденного.



Настройка температуры: между логикой и креативностью

Побочный эффект: галлюцинации

- Цена креативности: «вероятностный генератор текстов» (Probabilistic Text Completer) иногда выдает правдоподобную, но ошибочную информацию.
- Почему это происходит?
  - ИИ генерирует тексты, опираясь на вероятности. Он не проверяет факты.
- Механизм:
  - Если он не знает факта напрямую, он генерирует наиболее «правдоподобную» последовательность слов.
  - Пример: выдумывание фальшивой ссылки, потому что она выглядит как реальный пример цитирования.
- Решение:
  - Обоснование (Grounding): принуждение модели отвечать на основе внешних источников.
  - RAG: поиск + генерация для уменьшения галлюцинаций.

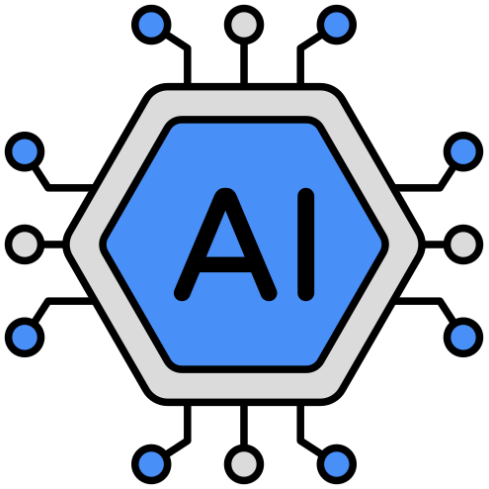
[Лабораторная работа 2] Понимание поведения больших моделей

Цель лабораторной работы

- Понять, как Базовые модели генерируют ответы вероятностным способом
- Объяснить, почему возникают вариативность вывода и галлюцинации
- Описать ограничения модели, используя концепции Модуля 2

Обзор лабораторной работы

- Повторить ключевые механизмы работы модели из Модуля 2
- Использовать Gemini для обобщения и объяснения основных понятий
- Выбрать одну тему из предложенных для более глубокого изучения
- Систематизировать полученные знания в кратком отчете по теме



Шаг 1: Обобщение ключевых понятий (Проверка понимания) (5 мин)

Задание

Повторите ключевые темы, представленные в Модуле 2 и попробуйте их обобщить, используя Gemini или другую модель

Тема для обсуждения

Проведите исследование по изученным темам, используйте Gemini или другую модель для создания кратких резюме по каждой из них и запишите основные моменты в рабочую тетрадь

Баллы

1. Подведите итог своими словами
2. Приведите по одному практическому примеру для каждой концепции

Шаг 2: Погружение в тематику (10 мин)

Задание

Вам будет предложено 2–3 основные темы на выбор.
Выберите одну тематику и изучите ее более глубоко с помощью Gemini или другой модели

Тема для обсуждения

Проведите исследование, следуя инструкциям в рабочей тетради,
или выберите свои собственные вопросы, основываясь на приведенных ниже соображениях

Баллы

1. Базовый механизм
2. Оптимизация и контроль
3. Влияние и перспективы на будущее

Шаг 3: Напишите отчет по материалу (10 мин.)

Задание

На основе вашего исследования на шаге 2 напишите краткий отчет

Тема для обсуждения

Следуйте формату и руководству рабочей тетради или попробуйте развить их, добавив собственные идеи

* Ссылка на источник данных значительно повысит глубину и достоверность вашего отчета

Практика

Определите пошаговую последовательность действий для этого сценария:
«В отличие от общих ответов ИИ, ответы, основанные на конкретных документах, _____, потому что _____».