Раздел 3.3.

Стратегии применения базовых моделей

3.3.1. Различные способы применения моделей

3.3.2. Изучение методов применения, соответствующих вашим целям

Сценарии применения моделей

Базовые модели могут применяться напрямую, а также путем специализации или расширения.

① Прямое использование (через API)

- Использование моделей напрямую через API: дообучение или внесение изменений не требуется
- Быстрое внедрение для задач написания текстов, суммаризации и общих вопросов и ответов

② Дообучение (Fine-Tuning)

- Дополнительное обучение модели на специфичных данных : повышает точность выполнения задач в целевой области применения
- Специализированные задачи, требующие единообразной терминологии или поведения

③ RAG (генерация с дополненной выборкой)

- Обоснование ответов модели с помощью внешних или внутренних источников знаний
- Повышает точность результата и снижает галлюцинации без переобучения

④ RAG + Агент

- Сочетание RAG с планированием, принятием решений и выполнением инструментов
- Обеспечивает многошаговые рабочие процессы и автоматизированное выполнение задач

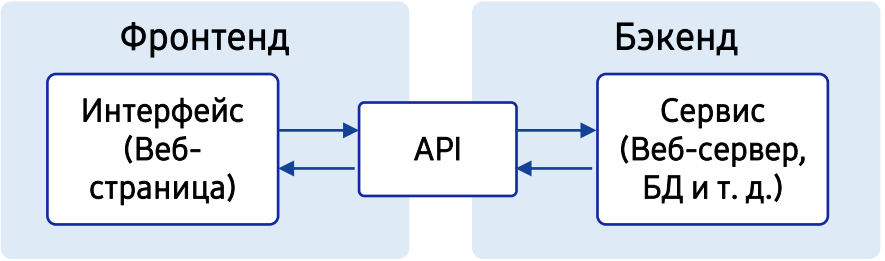
1 Прямое использование моделей через API

Что такое API?

- **API (интерфейс программирования приложений)** позволяет программам взаимодействовать друг с другом.
  - API работает как мост, который позволяет одному приложению попросить другую систему выполнить что-либо и получить результат.
- В генеративном ИИ API позволяет вашему приложению **отправить запрос к базовой модели и получить ответ.**

Использование API в генеративном ИИ

- Работа с моделями **напрямую через API**
- Не требует модификации или дообучения
- Модель обрабатывает входные запросы и возвращает сгенерированные ответы



Типовое взаимодействие на основе API

1 Как API обеспечивает взаимодействие с моделями генеративного ИИ

Что предоставляет API генеративного ИИ

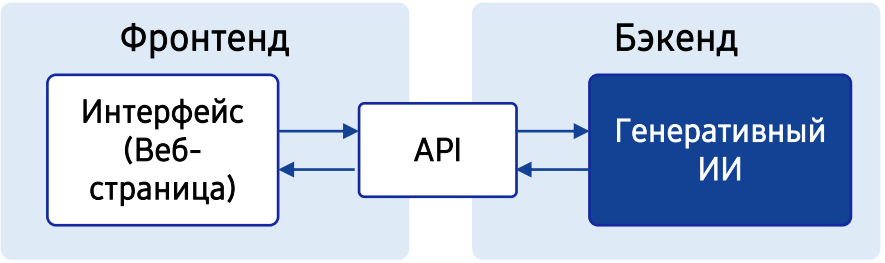
- Канал, позволяющий приложениям задействовать возможности фундаментальных моделей
- Возможности модели доступны **по сети без установки или обучения модели**

Типовые возможности, предоставляемые через API

- Генерация текста, суммаризация, перевод и генерация кода
- Генерация изображений, анализ документов и поиск/RAG

Способы использования API генеративного ИИ

- Работа на площадках провайдеров (no-code / low-code прототипирование)
- Добавление функций ИИ в существующие сервисы
- Написание прямых вызовов API для интеграции с приложениями



Использование генеративного ИИ через API

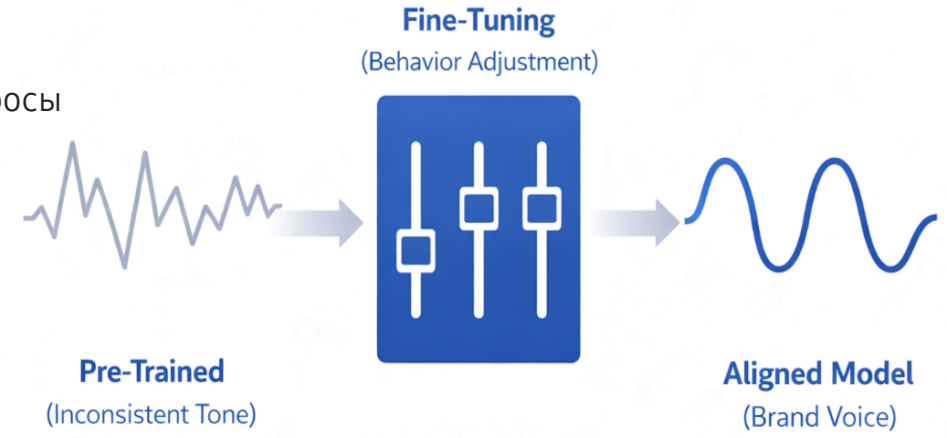
2 Дообучение фундаментальных моделей

Что такое дообучение (Fine-Tuning)?

- Дообучение — это процесс **дополнительного обучения модели на данных, специфичных для предметной области**
- Модель не перестраивается с нуля, а **адаптируется под конкретную задачу или область**
- Цель состоит в повышении **согласованности и точности результата** для конкретного сценария

Дообучение как стратегия

- Подстраивает **поведение модели**, а не входные запросы
- Требует дополнительных обучающих данных и вычислительных ресурсов
- Полезно, когда работы через API недостаточно



Критерии дообучения: усвоение тона и правил

2 Зачем нужно дообучение?

Ограничения прямого использования

- Качество ответов может варьироваться в зависимости от формулировки запроса
- Модели общего назначения могут не полностью отражать правила или терминологию предметной области
- Поддерживать согласованность ответов только с помощью запросов бывает сложно

Когда дообучение является подходящим решением

- Задачи, требующие **строго согласованного формата или логики принятия решений**
- Приложения для конкретных областей (например, юридические, медицинские, промышленные документы)
- Ситуации, в которых работа с запросами (prompt engineering) не выдает стабильных результатов

2 Цель дообучения

От общего к частному: приведение знаний и поведения модели в соответствие с корпоративными стандартами и стилистикой бренда.

Формат и стиль

- Фиксирует шаблоны ответов (профессиональный стиль)

Меньше галлюцинаций

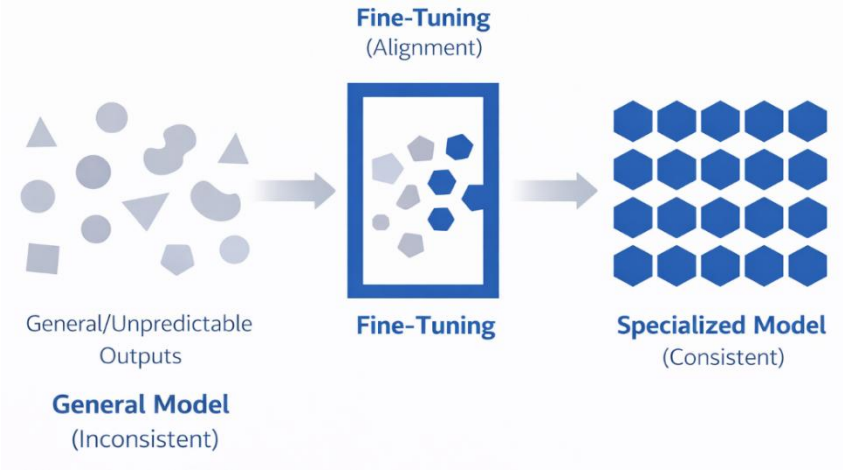
- Снижает количество ошибок за счет изучения границ применимости

Согласованность

- Обеспечивает стабильные результаты для автоматизации

Соблюдение стандартов бренда

- Применяет корпоративные правила и юридические ограничения



Эффект дообучения: согласованность и непротиворечивость

3 Почему появился RAG: Ограничения дообучения

Ограничения дообучения

- **Обновление знаний требует переобучения.**
  Обновление фактов или политик требует переобучения модели, что дорого и медленно.
- **Неэффективно для часто меняющейся информации.**
  Дообучение не позволяет легко адаптироваться под быстро обновляемый контент.
- **Ограниченная масштабируемость для больших баз знаний.**
  По мере роста предметных знаний дообученные модели становится сложнее поддерживать.
- **Не подходит для конфиденциальных или динамичных внутренних данных.**
  Конфиденциальные или часто меняющиеся документы невозможно эффективно обрабатывать.

Ключевой вывод

- Дообучение определяет поведение модели, но не то, как обновляются её знания.
- Это ограничение создало потребность в подходе, который хранит знания вовне и обеспечивает точную генерацию.

3 RAG - генерация с дополненной выборкой

Что такое RAG (Retrieval-Augmented Generation)?

- RAG — это метод, который позволяет базовой модели **извлекать релевантную информацию из внешних источников перед генерацией ответа.**

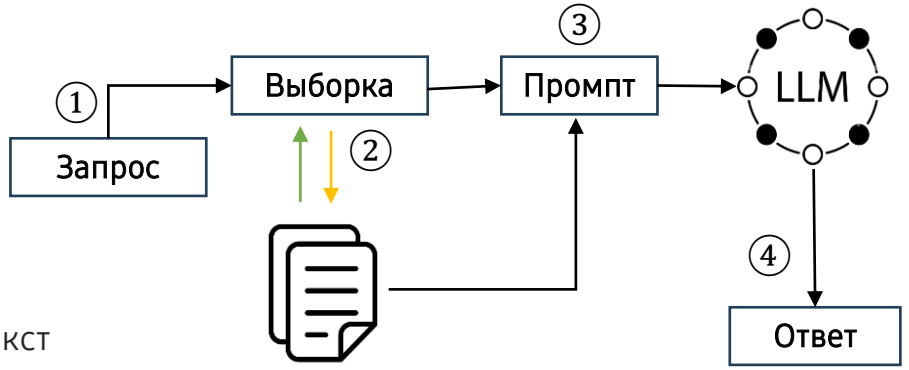
Как работает RAG

① Получение запроса пользователя

② Извлечение релевантных документов из базы знаний

③ Создание промпта с извлеченными документами

④ LLM выдает ответ, используя предоставленный контекст



База знаний (векторная БД)

- **Векторная БД** хранит документы в виде векторов (наборов чисел), которые отражают их смысл.
- Релевантная информация извлекается путем сравнения семантического сходства, а не по ключевым словам.

4 RAG + Агент: расширение действиями

Ограничения RAG

- RAG отвечает на вопросы, используя извлеченные знания.
- Но многие бизнес-задачи требуют **действий**, а не просто ответов

RAG + Агент

- Агенты объединяют поиск, рассуждение и действие.
- Они могут вызывать инструменты, запускать рабочие процессы и выполнять задачи.
- Обеспечивает сквозную автоматизацию с использованием базовых моделей.

Типичные кейсы

- Интеллектуальные помощники с функцией выполнения задач
- Автоматизированная отчетность и поддержка принятия решений
- Многоэтапные корпоративные рабочие процессы

4 Как RAG + Агенты выполняют задачи

- Не просто ответы на вопросы, а **итеративный поиск и выполнение действий до достижения цели**.
- RAG предоставляет обоснованные ответы, но **агенты позволяют принимать решения и действовать на основе полученных знаний**.



Целеориентированное планирование

- Использует извлеченные знания для планирования следующих шагов
- Выходит за рамки однократных ответов



Выполнение действий

- Вызывает инструменты, API или процессы на основе результатов RAG
- Превращает ответы в действия



Сохранение контекста

- Удерживает извлеченную информацию на множестве шагов
- Обеспечивает многоэтапную работу



Проверка результатов

- Оценивает соответствие действий и результатов
- Снижает количество ошибок в сложных задачах

Резюме: 4 сценария работы с моделями на практике

- Базовые модели можно применять четырьмя различными способами, в зависимости от того, что именно вы хотите получить
- API определяет способ вызова модели, дообучение (Fine-Tuning) меняет поведение модели, RAG расширяет знания модели, а RAG + агенты расширяют как знания, так и действия модели
- Эти подходы образуют прогрессивный спектр: от использования как есть до системного применения ИИ
- Понимание различий необходимо для выбора правильного подхода к решению реальных бизнес-задач

Метод	Что меняется	Типичное использование
Прямое использование (API)	Способ вызова модели	Быстрые задачи, общие действия
Дообучение (Fine-Tuning)	Поведение модели	Согласованность, соответствие области
RAG	Знания модели	Точные, актуальные знания
RAG + Агент	Возможности модели	Многошаговые процессы, автоматизация