Раздел 3.3.

Стратегии применения базовых моделей

3.3.1. Различные способы применения базовых моделей

3.3.2. Изучение методов применения, соответствующих вашим целям

Выбор правильной стратегии

Почему важна стратегия применения

- Базовые модели можно применять разными способами, но **каждый подход решает свой тип задач**.
- Выбор неверной стратегии часто приводит к лишним затратам, сложности или нестабильным результатам.
- Четкая стратегия применения помогает согласовать возможности ИИ с реальными бизнес-целями.

Сначала ответьте

- **Что вы на самом деле хотите изменить с помощью ИИ?**
  - Как **вызывается** модель?
  - Как **ведет** себя модель?
  - Что модель **знает или умеет делать**?
- Ответы на эти вопросы определяют выбор подходящего метода.

Ключевой момент

- Внедрять ИИ — не значит использовать самую передовую технологию.
- Это выбор наиболее подходящего уровня адаптации для конкретной задачи.

Где генеративный ИИ создает ценность

- Ценность генеративного ИИ в задачах проявляется неравномерно.
  - Вклад генеративного ИИ зависит от вида деятельности, а не от отрасли.
  - Ценность создается на уровне задач и рабочих процессов.
- Области деятельности с высокой отдачей

Работа с клиентами

- Повторяющиеся языковые взаимодействия
- Примеры: поддержка клиентов, обработка запросов, автоматизация ответов

Маркетинг и продажи

- Создание контента и коммуникация с клиентами
- Примеры: маркетинговые тексты, персонализация, планирование кампаний

Разработка ПО

- Структурированная логика и создание текстового контента
- Примеры: генерация кода, отладка, документация

Производство и НИОКР

- Синтез знаний и творческий поиск
- Примеры: обобщение итогов исследований, генерация новых идей, поддержка проектирования

Сопоставление задач с методами применения

- Почему это сопоставление важно
  - Разные задачи требуют разного уровня адаптации модели.
  - Соответствие задачи правильному методу снижает затраты и сложность.
- Рабочая задача → Метод применения

Языкозависимые, рутинные задачи
→ Прямое использование (API)

- Быстро, масштабируемо, низкая стоимость
- Лучший выбор для одноразовых задач

Единый стиль или специфический вывод
→ Дообучение

- Обеспечивает единообразие формата и правил
- Требует обучающих данных и высоких затрат

Наукоемкие задачи
→ RAG (поиск с дополнением)

- Извлекает точную и актуальную информацию
- Снижает вероятность галлюцинаций

Многоэтапные целеполагающие процессы
→ RAG + Агенты

- Обеспечивает планирование и автоматизацию
- Требует контроля и мониторинга

Выбор правильного метода применения

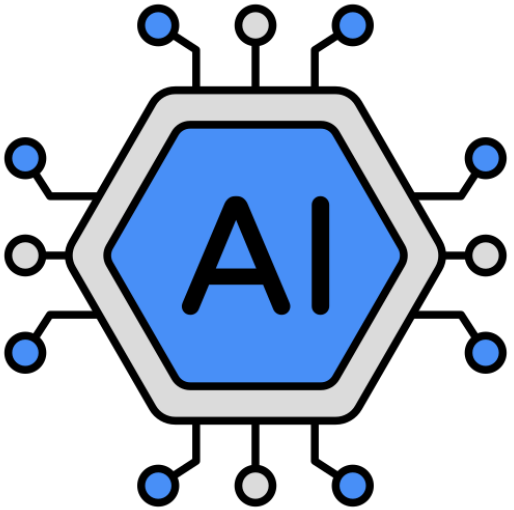
- Этот слайд обобщает, как характеристики задачи, допустимый уровень риска и операционные ограничения определяют подходящий метод применения.
- Когда использовать каждый подход

Вызов через API	▸ Простые, повторяющиеся и четко определенные задачи ▸ Лучший выбор для быстрого развертывания и экспериментов
Дообучение	▸ Требуется обеспечить строгое соответствие правилам ▸ Подходит для задач с четко определенными шаблонами
RAG	▸ Требуются точные, актуальные или внутренние знания ▸ Идеально для наукоемких задач, без риска галлюцинаций
RAG + Агенты	▸ Многоэтапное рассуждение, принятие решений и действия ▸ Требует строгого контроля, мониторинга и управления

[Лабораторная работа 3] Сравнение ответов с контекстом и без контекста (концепция RAG)

Цель лабораторной работы

- Понять ограничения ответов ИИ без контекста
- Увидеть на практике, как опора на конкретные документы улучшает качество ответов
- Объяснить, почему RAG необходим для целей индустрии



Обзор лабораторной работы

- Задавайте вопросы, не предоставляя никаких документов
- Задавайте те же вопросы с предоставленными документами
- Сравнивайте ответы, используя четкие критерии оценки
- Размышляйте о надежности и риске галлюцинаций

Шаг 1: Задайте вопросы без документов (базовый уровень) (5 мин)

Задача

Задайте модели вопросы, не загружая и не ссылаясь на какие-либо документы.

Тема для обсуждения

При задавании вопросов уточняйте, на что следует модель должна обратить внимание.

Внимание

Проверьте источник и перепроверьте точность информации
Используйте отдельный сеанс (окно чата) для каждого вопроса.

Шаг 2: Задайте вопросы с предоставленными документами (10 мин)

Задача

Предоставьте модели три документа и задайте те же вопросы, ссылаясь на документы.

Тема для обсуждения

Изучив обновленные ответы, проверьте следующие пункты.

Основные моменты

1. Стали ли ответы более конкретными и подробными?
2. Точно ли указаны цены, сроки и правила?
3. Основаны ли ответы на содержании документа?

Шаг 3: Сравнение результатов (15 мин)

Задача

Сравните ответы из шага 1 и шага 2, используя приведенные ниже критерии.

Тема для обсуждения

Проверьте отличия ответов на шаге 1 и шаге 2 по приведенным критериям и обобщите эту разницу.

Основные моменты

1. Точность: какой ответ более фактически верен?
2. Конкретика: какой ответ предоставляет конкретные детали (цифры, политики)?
3. Обоснованность: четко ли ответ основан на предоставленных документах?
4. Риск галлюцинаций: какой ответ с большей вероятностью содержит догадки?
5. Достоверность: какому ответу вы бы доверились в реальной бизнес-среде?

Шаг 4: Создание презентации (текст + изображения) (20 мин)

Задача

Используйте модель для создания презентации из 3–5 слайдов на основе вашего анализа

Тема для обсуждения

Цель — создать презентацию, которая передает идеи визуально, а не только через текст

Основные моменты

1. Определите четкую логику повествования, связав каждый слайд презентации своей идеей
2. Запросите структурированный макет с визуальными элементами: таблицами, графиками и диаграммами
3. Уточните уровень технической детализации в соответствии с целевой аудиторией