Раздел 4.2.

Этические проблемы ИИ

4.2.1. Предвзятость данных и проблема несправедливости

4.2.2. Целостность контента: галлюцинации и дипфейки

4.2.3. Проблемы непрозрачности «черного ящика»

4.2.4. Несанкционированное использование и защита прав

ИИ, который мы видим, лишь верхушка айсберга

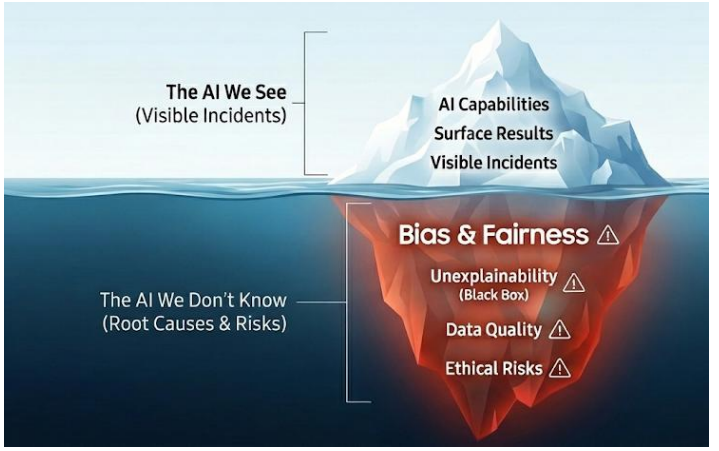
Видимые преимущества реальны, но скрытые риски приводят к реальным бизнес-инцидентам.

Связь с Разделом 4.1

Описанные инциденты с ИИ произошли, когда внезапно проявились скрытые и неуправляемые риски

Что скрыто под поверхностью (90% рисков)

- Предвзятость и несправедливые результаты
- Необъяснимость («черный ящик»)
- Качество данных (галлюцинации и дезинформация)
- Этические риски (конфиденциальность и нарушение авторских прав)
- Доверие и социальное воздействие (дипфейки и эрозия доверия)



Что будет в Разделе 4.2

Мы проведем диагностику «90% рисков»: что это такое, почему они возникают и как ими управлять.

Управление 90% скрытых рисков делает ИИ безопасным и готовым к бизнес-применению

Определения

Предвзятость данных

- Систематическая ошибка, при которой ИИ усваивает несправедливые закономерности в отношении определенных групп данных
- Возникает из-за исторических предрассудков и статистических дисбалансов в обучающих данных.

Несправедливость

- Дискриминационные результаты, основанные на чувствительных атрибутах (раса, пол, возраст).
- Нарушает равные права и лишает справедливых возможностей.

Основной механизм

- **Распознавание образов**:
  ИИ находит статистические корреляции в данных, ошибочно принимая их за причинно-следственные связи.
- **Слепая оптимизация**:
  ИИ оптимизирует строго определенные цели (точность) без привитого чувства «правильно или нет».

«Мусор на входе — мусор на выходе»: поскольку ИИ является чистым отражением своих входных данных, предвзятые данные неизбежно приводят к предвзятым результатам

1 Предвзятость данных

1 Предвзятость данных
2 Алгоритмическая предвзятость
3 Человеческая предвзятость

Определение

Предвзятость в данных, используемых для обучения или оценки модели

Распространенные типы

- Историческая предвзятость: прошлые социальные модели отражены в данных
- Предвзятость репрезентации: некоторые группы представлены недостаточно или чрезмерно
- Предвзятость измерения: данные собираются или маркируются неравномерно



Пример

- В обучающих данных систем распознавания лиц превалируют изображения людей со светлой кожей.

Риск появления несправедливости возникает, когда производительность/объем данных систематически различается между группами

2 Алгоритмическая предвзятость

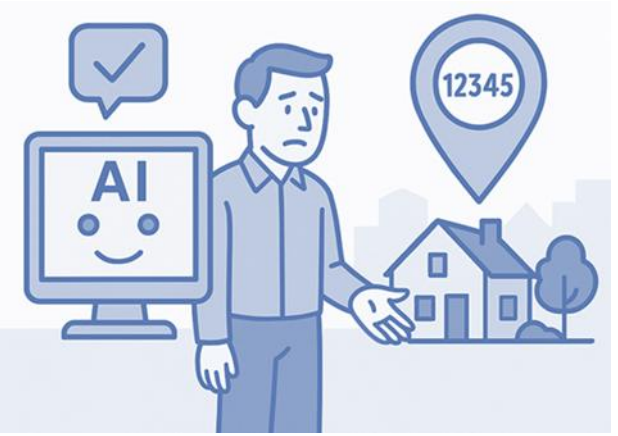
1 Предвзятость данных
2 Алгоритмическая предвзятость
3 Человеческая предвзятость

Определение

Предвзятость, вызванная выбором признаков, целями и пороговыми значениями принятия решений.

Распространенные причины

- Использование косвенных признаков (прокси-признаков), которые коррелируют с конфиденциальными атрибутами (например, почтовый индекс)
- Целевые функции, которые отдают предпочтение общей точности, а не справедливости в отношении групп
- Пороговые значения/веса, которые систематически ставят в невыгодное положение некоторые группы



Пример

- Модель кредитования использует «почтовый индекс» в качестве ключевого признака → ущемляет жителей определенных районов

Создаются неравные результаты, даже если конфиденциальные признаки не используются явно

3 Человеческая предвзятость

1 Предвзятость данных
2 Алгоритмическая предвзятость
3 Человеческая предвзятость

Определение

Человеческие суждения и предпочтения формируют данные, метки и системные правила

Где это проявляется

- Выбор предвзятых обучающих данных или предоставление предвзятой обратной связи
- Установление субъективных правил (например, «приемлемый язык») на основе одной культурной нормы
- Чрезмерная фильтрация или неверная маркировка выражений из других культур



Пример

- Правила модерации определяют «приемлемый язык», используя стандарты одной культуры → другие культуры отфильтровываются

Может привести к маргинализации определенных групп и созданию неравных условий для пользователей

Воздействие: от индивидуального вреда до социального недоверия



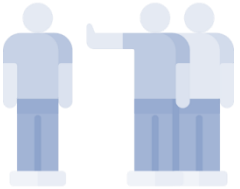
1. Индивидуальный вред (Deprivation & Rights Violations)

- **Экономические**: дискриминация при найме/продвижении по службе, отказ в доступе к кредитам, ограниченный доступ к услугам
- **Психологические и социальные**: ущерб достоинству, социальная стигматизация (навешивание ярлыков на группы людей)
- **Юридические**: нарушения фундаментальных прав и права на информацию



2. Углубление структурного неравенства (Laundering)

- **«Отмывание» предвзятости:** дискриминация, оправданная как «объективный ИИ»
- **Петля обратной связи**: предвзятые данные -> предвзятое решение -> новые предвзятые данные (циклически повторяется)
- **Проблема масштаба**: затрагивает тысячи людей одновременно, трудно обнаружить



3. Социальное доверие и слежка (Erosion & Chilling Effect)

- **Эрозия доверия:** растущее недоверие общественности к надежности ИИ. Глобальное доверие к ИИ-компаниям упало до 53% (Edelman, 2024 г.)
- **Эффект сдерживания:** опасения по поводу слежки ограничивают свободу выражения мнений: нерегулируемое распознавание лиц создает страх перед мониторингом

Реальный кейс 1

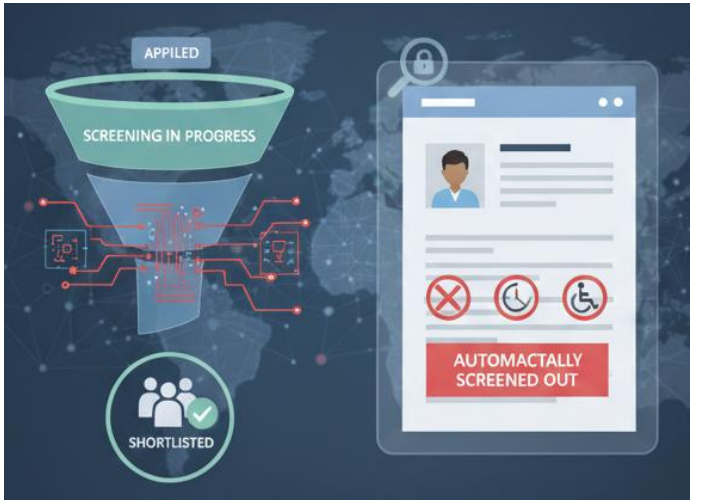
ИИ-отбор кандидатов

Что это такое

- Соискатель заявил, что глобальная HR-платформа «A» автоматически отсеяла его более чем в 100 заявках на трудоустройство.
- Он утверждал, что результаты отбора были дискриминационными по признаку расы, возраста и инвалидности.

Ключевые вопросы

- Когда ИИ-инструмент поставщика отфильтровывает кандидатов, то поставщик может рассматриваться как «агент» в процессе найма.
- Из-за повсеместного применения инструмента без участия человека предвзятость может незаметно масштабироваться



Когда ИИ отбирает кандидатов, риски нарушения принципов справедливости распределяются между поставщиками технологий и работодателями.

Реальный кейс 1

Где возникает предвзятость

- Инструмент изучает закономерности на основе исторических результатов и сигналов «успешного профиля».
- На первый взгляд нейтральные входные данные — такие как местоположение, перерывы в работе, образование или ключевые слова — могут служить косвенными признаками (прокси) для защищенных характеристик.
- Даже при оптимизации общей точности система все равно может выдавать неравные показатели прохождения для разных групп людей.
- Без прозрачности и мониторинга соискателям могут неоднократно отказывать без четких объяснений.

ПРОКСИ-ПРИЗНАКИ
Нейтральные входные данные могут выступать в качестве прокси-признаков для защищенных характеристик.

ОБЪЕКТИВНОСТЬ
Оптимизация точности все равно может создавать неравенство между группами.

МОНИТОРИНГ
Без регулярных аудитов предвзятость может оставаться незамеченной при масштабировании.

Мини-пример

«Прокси-признаки (например, почтовый индекс) могут ставить в невыгодное положение определенные группы, даже при отсутствии явных защищенных характеристик».

Удаление только защищенных признаков – недостаточная мера, справедливость необходимо постоянно измерять и проверять

Реальный кейс 1

Почему это важно для бизнеса

- Эффект масштаба: один предвзятый фильтр может повлиять на тысячи кандидатов у множества работодателей.
- Юридические риски: суды активно изучают, как ответственность распространяется на поставщиков ИИ для найма и их клиентов.
- Операционные риски: команды могут не обнаружить проблему до тех пор, пока жалобы, аудиты или судебные иски не спровоцируют расследование.
- Влияние на доверие: несправедливый отбор может ухудшить опыт кандидата и подорвать бренд работодателя.



Справедливость — это не разовая настройка, а непрерывный процесс измерения и управления.

Реальный кейс 2

Предвзятость в распознавании лиц

Что это такое

NIST* протестировал коммерческие системы распознавания лиц, выявив различия в точности между демографическими группами.

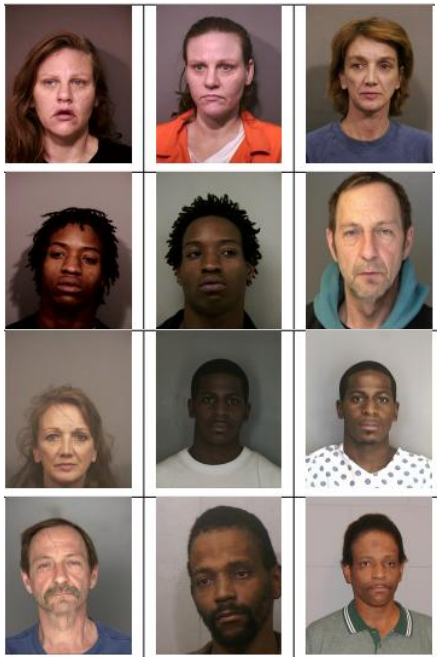
Масштаб исследования

Бенчмарк под эгидой правительства: 189 алгоритмов, 99 разработчиков и около 18 млн изображений.

Ключевые выводы

- Частота ложноположительных результатов варьируется от 10 до более чем 100 раз в зависимости от группы.
- Эти разрывы повышают риски ошибочной идентификации в сфере безопасности, контроля доступа и расследований.

NIST FRVT (2019)



Предвзятость — это не теория:
бенчмарки выявляют значительные различия в ошибках между демографическими группами.

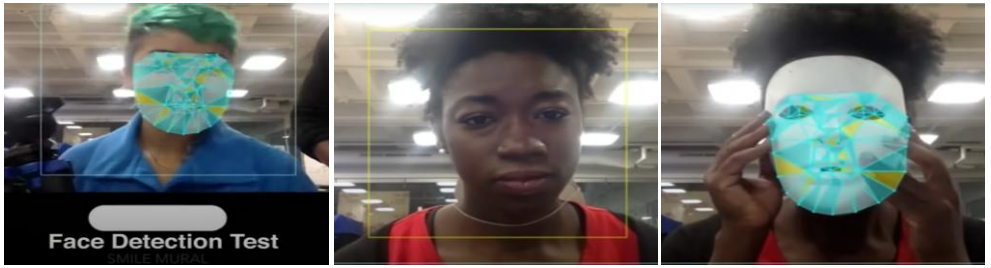
*) National Institute of Standards and Technology - Национальный институт стандартов и технологий США, разрабатывающий стандарты в области измерений, информационных технологий и кибербезопасности

Реальный кейс 2

Почему это важно

Влияние на бизнес

- Риск: Ошибочная идентификация может привести к несправедливым результатам и юридической ответственности
- Операционный аспект: Проблемы часто остаются скрытыми до тех пор, пока не возникнут жалобы, аудиты или инциденты
- Управление: Удаления только чувствительных полей недостаточно — системы все равно могут полагаться на косвенные признаки (прокси)
- Доверие: Воспринимаемая несправедливость подрывает авторитет и принятие технологий



Карточки доказательств

Что меняется в реальной жизни

- Производительность варьируется в новых условиях (например, маски, освещение, качество камеры).
- Справедливость требует постоянного тестирования, а не однократной проверки.

Пример интерсекционального разрыва

(классификация пола — Gender Shades)

- Светлокожие мужчины: до 0,8% (наименьший показатель)
- Светлокожие женщины: 7,1%
- Темнокожие мужчины: 12,0%
- Темнокожие женщины: 34,7% (наивысший показатель)

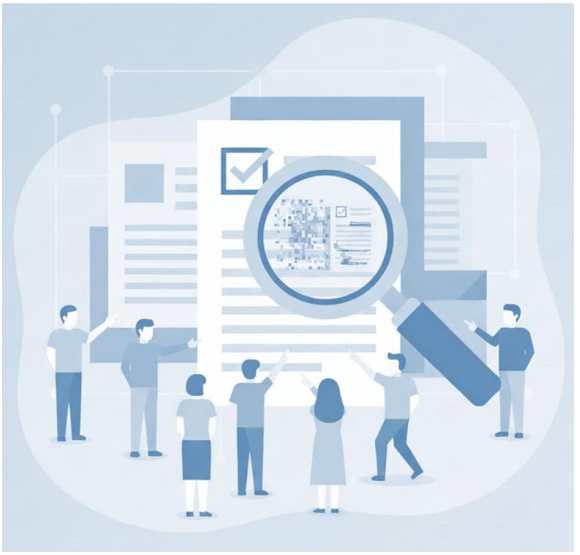
Справедливость необходимо постоянно измерять, отслеживать и контролировать

Реальный кейс 3

Скрининг социальных пособий с помощью МО

Проверка на мошенничество с социальными пособиями с помощью машинного обучения (Министерство труда и пенсий Великобритании, 2023–)

- Министерство труда и пенсий Великобритании (DWP) использует модель машинного обучения для пометки заявок на авансовые платежи Universal Credit (UC) для дополнительной проверки.
- Модель используется для авансовых платежей UC с мая 2023 года и обучена на исторических моделях мошенничества.
- Помеченные заявки отправляются сотрудникам для дальнейшей проверки перед выплатой.



Риск отсутствия надзора

Когда модель занимается сортировкой жизненно важных платежей, ошибки могут масштабироваться и непропорционально затрагивать одни группы больше, чем другие.

Когда ИИ распределяет пособия, справедливость и прозрачность становятся частью качества обслуживания

Реальный кейс 3

Выводы о справедливости

Что было измерено

- DWP провело проверку справедливости модели UC Advances, но ограничения данных не позволили протестировать многие защищенные признаки (например, расу, пол).

Что можно было протестировать

- Возраст, показатели здоровья/инвалидности (прокси), семейный статус (прокси) и гражданство.

Ключевой вывод

- Доля ложноположительных результатов варьировалась в зависимости от группы — некоторые группы чаще ошибочно помечались как подозрительные.

Проблема прозрачности

- Публичные сводки могут казаться обнадеживающими, но ключевые детали часто ограничены или отредактированы, что препятствует независимой проверке.

Карточки доказательств

Ограничения данных

Некоторые защищенные признаки невозможно проверить

Наблюдаемое неравенство

Доля ложноположительных результатов значительно варьировалась в зависимости от группы

Если вы не можете измерить результаты по разным группам, вы не можете с уверенностью заявлять о справедливости

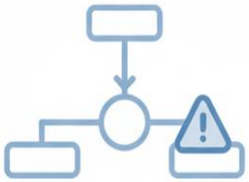
Реальный кейс 3

Где произошел сбой контроля

- **Пробелы в данных**
  - Отсутствие демографических данных препятствует надежному аудиту справедливости и обеспечению подотчетности.
- **Давление «черного ящика»**
  - Оптимизация эффективности обнаружения может скрыть вред, причиняемый добросовестным заявителям.
- **Неопределенность участия человека (Human-in-the-loop)**
  - Без четких инструкций и мониторинга проверка сотрудником не может надежно предотвратить несправедливые результаты.
- **Ограниченный контроль**
  - Когда ключевые детали невозможно объяснить или опубликовать, доверие общества к системе подрывается.



Данные



Процесс



Подотчетность

Проверка человеком эффективна только тогда, когда этот процесс должным образом спроектирован, контролируется и протоколируется

Реальный кейс 3

Средства контроля и выводы

Публикация значимых метрик

- Отчетность о частоте ложноположительных результатов, задержках и разбивке по группам.

Установите контрольные механизмы

- Определите максимальную задержку для правомерных требований, пути эскалации и четкие разъяснения для заявителей.

Отслеживайте отклонения

- Повторяйте проверки на справедливость после изменений в данных или моделях — не только при запуске.

Независимая проверка

- Проводите оценку воздействия на защиту данных (DPIA), планируйте аудиты и документируйте цели, входные данные и ограничения.



При принятии решений с высокими ставками алгоритмы должны поддерживать, а не заменять человеческое суждение