Раздел 4.2.

Этические проблемы ИИ

4.2.1. Предвзятость данных и проблема несправедливости

4.2.2. Целостность контента: галлюцинации и дипфейки

4.2.3. Проблемы непрозрачности «черного ящика»

4.2.4 Несанкционированное использование и защита прав

Определения: риски целостности контента

Когда ИИ генерирует текст или медиаконтент, «убедительно» все еще может означать «неверно».

Целостность контента

- Точность и отслеживаемость: можете ли вы сослаться на источник и проверить его?
- Низкая целостность увеличивает объем переделок, риски и наносит ущерб репутации.

Галлюцинации

- Правдоподобные, но не подтвержденные утверждения (факты, цифры, цитаты)
- Часто встречаются при расплывчатых запросах и длинных ответах

Дипфейки

- Синтетический медиаконтент, имитирующий реальных людей или события
- Способствуют мошенничеству и дезинформации — проверяйте источник и контекст

Что у них общего

- Генерация, основанная на правдоподобии: звучать правильно ≠ быть правильным
- Обучение на закономерностях наследует пробелы, ошибки и предвзятость из обучающих данных
- Отсутствие встроенной проверки на истинность: модели не сверяются с реальностью

Когда результаты работы ИИ выглядят убедительно, помните: правдоподобное не означает истинное — проверяйте, прежде чем доверять!

1 Вероятностная генерация (1)

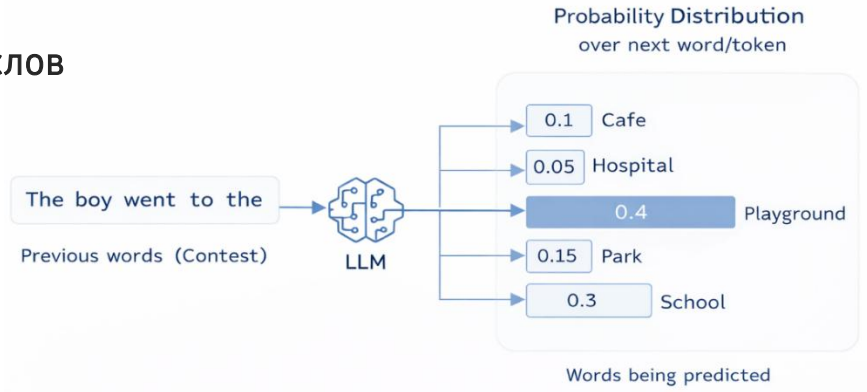
1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

Как фундаментально работают языковые модели

- Ввод: «Мальчик пошел в...»
- ИИ вычисляет вероятности: Кафе (10%), Больница (5%), Игровая площадка (40%), Парк (15%), Школа (30%).
- ИИ выбирает «Игровая площадка» как вариант с наибольшей вероятностью.

Генерация предложения = последовательное предсказание слов

- Повторение вышеуказанного процесса для каждого слова
- Вычисление вероятности следующего слова с учетом контекста
- Генерация «правдоподобного» предложения



Языковые модели генерируют правдоподобный текст, а не гарантированно истинный

1 Вероятностная генерация (2)

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

Пример сценария: Генерация ложной информации

Вопрос: «Какая частная компания первой успешно совершила посадку на Луну в 2024 году?»
↓
Ответ ИИ: «SpaceX успешно совершила посадку на Луну в марте 2024 года». (❌ Неверно)
↓
Реальность: Ни одна частная компания не добилась успеха в это время.

Причина: Высокая вероятность того, что ключевые слова «SpaceX», «посадка на Луну» и «успех» часто встречаются вместе в обучающих данных.

Основная проблема

- ИИ генерирует наиболее правдоподобный ответ на основе изученных паттернов
- Отсутствие механизма проверки фактов — невозможно отличить правдоподобное от точного

Не доверяйте результатам работы ИИ при принятии решений, основанных на фактах, без независимой проверки

2 Загрязнение обучающих данных

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

Обучающие данные веб-масштаба могут включать ненадежные, устаревшие и противоречивые источники.

Что это такое

- Веб-данные объединяют факты, мнения, слухи и спам
- Низкокачественные источники могут казаться достоверными в больших масштабах
- Наборы данных часто содержат противоречия

Как это работает

- Модели изучают текстовые закономерности, а не проверенную истину
- Частые утверждения становятся более вероятными вариантами завершения текста
- Редкие или противоречивые утверждения все равно могут появляться в результатах

Почему это важно

- Ненадежный текст может выглядеть как уверенные «факты»
- Риск возрастает в темах с высокими ставками (найм, финансы, здравоохранение, право)
- Фильтрация помогает, но масштаб делает достижение совершенства нереалистичным

Пример

- Непроверенные сообщения могут утверждать: «Компания X требует сертификацию Y».
- Модели повторяют это, заставляя соискателей тратить время впустую или подавать заявки неправильно.

Модели могут звучать уверенно, даже когда источники ненадежны.

3 Отсутствие контекста (1)

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

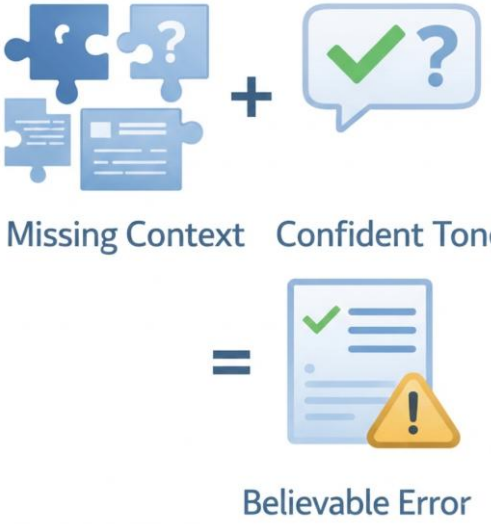
Когда контекст отсутствует, модели могут начать гадать — и звучать при этом уверенно

Ограничения ИИ

- Модели не могут надежно отделять факты от вымысла или предположений
- Они могут объединять противоречия в кажущуюся связной историю
- У них отсутствуют автоматические проверки на логическую непротиворечивость

Самоуверенность

- Они могут дать ответ вместо того, чтобы сказать «Я не знаю»
- Уверенный тон не равен правильности
- Грамотные ответы могут казаться более заслуживающими доверия, чем проверенные источники



Отсутствие контекста + уверенная формулировка = правдоподобные ошибки

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

3 Отсутствие контекста (2)

Один отсутствующий факт может спровоцировать уверенную фальсификацию.

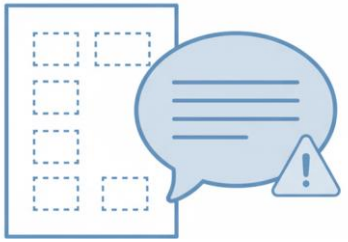
Пример сценария: Генерация ложной информации

Вопрос: «Объясните “эффект Голдмана-Смита”.»

Ответ ИИ: «Он был представлен профессором Голдманом в Гарварде в 1990-х годах...» (✕ Неверно)

Реальность: Этот термин и профессор вымышлены.

- Причина: При слабом обосновании модель объединяет правдоподобные имена и шаблоны в убедительную историю.



Основные проблемы

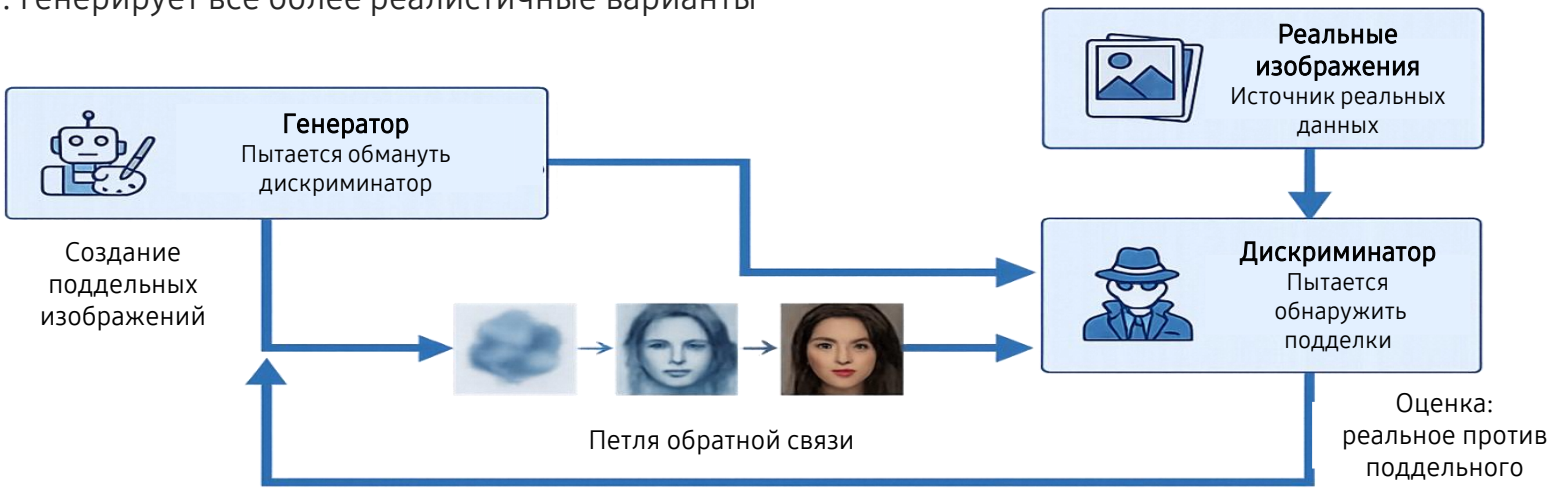
- Приоритет правдоподобия: завершает шаблоны, а не проверяет факты
- Отсутствие проверки фактов: не может отличить правдоподобное от достоверного

Если вы не можете это проверить, считайте это недостоверным

4 Генеративные технологии (1)

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

- GAN (Генеративно-состязательные сети)
- Состязательное обучение
  - Генератор: пытается обмануть дискриминатор
  - Дискриминатор: пытается обнаружить подделки
  - Результат: генерирует все более реалистичные варианты



Результат: создание все более реалистичных вариантов

4 Генеративные технологии (2)

1 Вероятностная генерация
2 Загрязнение обучающих данных
3 Отсутствие контекста
4 Генеративные технологии (дипфейки)

Те же генеративные инструменты могут создавать убедительные поддельные медиаматериалы

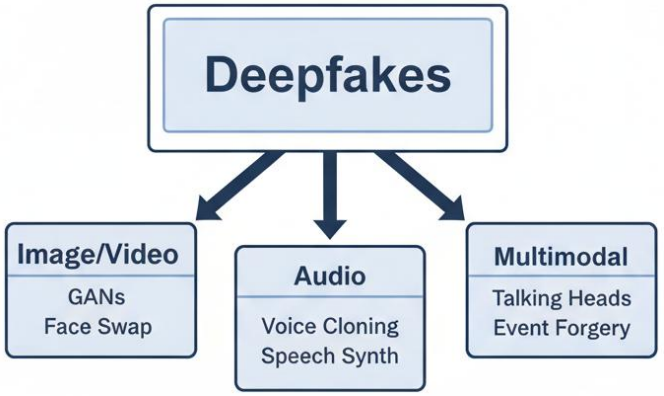
Что это такое
- Дипфейки — это синтетический медиаконтент, имитирующий реальных людей или события
- Они могут манипулировать лицами, голосами или тем и другим одновременно

Как это работает
- Генерация изображений (диффузия): пошаговое превращение шума в изображения
- Клонирование голоса: имитация голоса говорящего на основе коротких аудиофрагментов
- Редактирование + синхронизация: замена лица и синхронизация губ делают результаты правдоподобными

Что это может создавать
- Изображение/видео: замена лица, синхронизация губ
- Аудио: клонирование голоса, преобразование текста в речь
- Мультимодальность: видео + клонированный голос (клип или живой звонок)

Почему это важно
- Качество постоянно улучшается, поэтому обнаружение становится сложнее
- Дипфейки в реальном времени или почти в реальном времени становятся все более возможными
- Доверие может быстро разрушиться в сфере найма и общественных коммуникаций

Пример
- «Рекрутер» совершает видеозвонок с клонированным голосом и синхронизированными губами.
- Кандидаты делятся конфиденциальной информацией, полагая, что это реальное собеседование.



Эффект 1: Подрыв доверия и авторитета

Когда контент может быть сфабрикован, проверка становится новым стандартом по умолчанию.

Профессиональные риски

- В здравоохранении неверные рекомендации могут привести к опасным решениям
- В юриспруденции сфабрикованные цитаты могут привести к неверному пониманию ситуаций и нарушениям нормативных требований
- В академической среде фальшивые источники могут скомпрометировать исследования и процесс обучения

Повседневное информационное загрязнение

- Ложные утверждения распространяются быстрее, когда они хорошо оформлены и выглядят достоверными
- Люди могут повторять дезинформацию, потому что она звучит авторитетно
- Фраза «ИИ так сказал» может заменить прямую проверку первоисточников

Упадок истины

- Становится труднее прийти к согласию относительно того, что является правдой
- Доверие к институтам и СМИ может со временем разрушиться
- Общественная дискуссия ослабевает, когда факты становятся предметом торга

Быстрая проверка на доверие

- Источник + дата?
- Кто автор?
- Есть ли ссылки на доказательства?
- Есть ли подтверждения из альтернативного источника?



Если вы не можете это проверить, вы не можете на это полагаться

Эффект 2: Кто страдает в первую очередь

Обман бьет больнее всего, когда проверка затруднена.

Цифровой разрыв

- Людей с низким уровнем ИИ-грамотности легче ввести в заблуждение
- Пожилые люди и маргинализированные группы подвергаются более высокому риску
- Мошенники используют срочность, авторитет и незнакомые инструменты

Языковые барьеры

- У пользователей, не владеющих английским языком, может быть меньше надежных ресурсов для проверки фактов.
- Языковым меньшинствам часто не хватает своевременного охвата проверки фактов
- Дезинформация распространяется, когда к опровержениям трудно получить доступ

Личный и финансовый ущерб

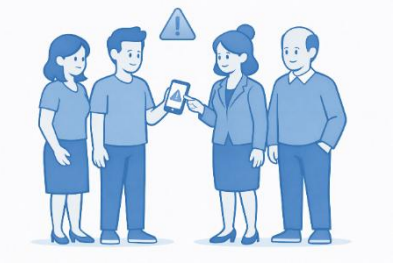
- Клонирование голоса может способствовать убедительной имитации и мошенничествам
- Дипфейки могут использоваться для преследования и нанесения репутационного ущерба
- Интимные дипфейки трудно удалить после того, как они были распространены

Пример

- Сексуальные дипфейки без согласия доминируют в ранних наборах данных

Широко цитируемый анализ 2019 года показал, что большинство обнаруженных дипфейков были порнографическими

В том же отчете отмечалось, что большинство целей в этом наборе данных были женщинами



Защищайте людей в первую очередь: проверяйте личность, источник и намерения

Эффект 3: Поляризация и социальные риски

Синтетический медиаконтент может манипулировать вниманием и ослаблять общую реальность.

Политическая манипуляция

- Фальсификация цитат или «скандальных» кадров, чтобы ввести избирателей в заблуждение.
- Целевая дезинформация распространяется быстрее, чем опровержения.
- Даже опровергнутый контент может оставить длительные сомнения.

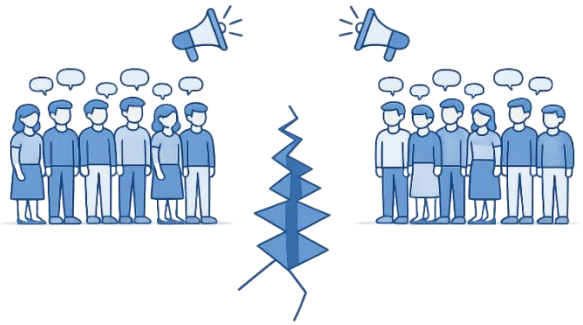
Социальный раскол

- Разжигание конфликтов, усиление нарративов, вызывающих возмущение
- Скоординированные кампании для искажения представления людей о том, «во что верят другие».
- Поляризация общества вследствие разрушения доверия между группами

Воздействие на системном уровне

- Когда люди перестают доверять всему, законные доказательства теряют свою силу
- Институты тратят больше времени на доказательство реальности, чем на решение проблем
- Гражданский дискурс ослабевает, поскольку скептицизм становится нормой

Дезинформация разрушает общую реальность



Скорость побеждает правду — если только проверка не встроена в систему

Реальный кейс 1

Фальшивые цитаты ИИ в суде (2023)

В юридическом документе были процитированы несуществующие дела

Обзор инцидента

- Когда/Где: май–июнь 2023 г., федеральный суд США (Южный округ Нью-Йорка)
- Что произошло: в судебный документ были включены шесть сфабрикованных цитат, сгенерированных ChatGPT
- Почему это важно: в условиях американского прецедентного права цитаты выглядели достоверно и были представлены как подлинные

Как это было обнаружено

- Противоположная сторона не смогла найти процитированные дела в юридических базах данных
- Судья обязал адвокатов предоставить копии этих дел
- В конечном итоге адвокаты признали, что цитаты были сфабрикованы



Правдоподобные цитаты — это не доказательство.
Всегда проверяйте информацию по первоисточникам!

Реальный кейс 1

Почему это произошло – и какова цена

Модель была оптимизирована для создания правдоподобного текста, а не для юридической точности.

Как возникают галлюцинации в цитатах

- Модель комбинирует правдоподобно звучащие названия, суды и юридические формулировки
- Она может отвечать уверенно, даже когда ошибается
- Она не проверяет, существует ли дело в официальных базах данных



Результаты и последствия

- Суд наложил штраф в размере 5000 долларов на адвокатов и фирму
- Суд потребовал направить письменное уведомление клиенту и затронутым судьям
- Решение подтвердило, что юристы несут ответственность за точность

Человеческий контроль необходим в работе с высокими ставками

Реальный кейс 1

Как безопасно и эффективно использовать ИИ

Ответственность за проверку лежит на вас

Практические меры предосторожности

- Относитесь к генеративному ИИ как к инструменту для черновиков, а не как к средству проверки фактов
- Проверяйте каждую цитату по первоисточнику или надежной базе данных
- Если вы не можете проверить информацию, удалите ее или пометьте как неподтвержденную
- Используйте ИИ для структурирования и ясности, а затем проверяйте содержание



Почему это остается актуальным

- Суды продолжают выявлять сгенерированные ИИ фальшивые цитаты в новых делах
- Судьи все чаще ожидают раскрытия информации и более строгих механизмов проверки

Независимо от того, насколько уверенно звучит ИИ — всегда проверяйте информацию, прежде чем полагаться на нее

Реальный кейс 2

Мошенничество с использованием ИИ-имитации голоса (2025 г.)

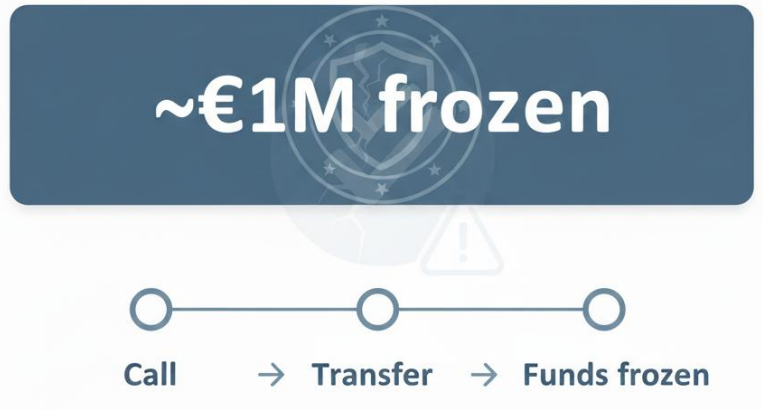
Когда «авторитет + срочность» искусственны, единственной защитой является проверка.

Обзор инцидента

- Когда/где:
  февраль 2025 г., Италия (телефонные звонки руководителям)
- Что произошло:
  мошенники клонировали голос высокопоставленного чиновника, чтобы потребовать деньги
- Уловка:
  «Срочный выкуп за освобождение похищенных журналистов»
- Почему это сработало:
  звонки звучали официально и требовали немедленной реакции
- Последствия:
  как минимум в одном случае было переведено почти 1 млн евро; позже власти заморозили и вернули средства
- Ключевой риск:
  правдоподобный голос может спровоцировать реальные платежи, прежде чем кто-либо проверит

Пример

- Звонящий звучит как правительственный чиновник и требует срочного перевода — правдоподобный голос может привести к дорогостоящим действиям.



Реальный кейс 2

Как действовали мошенники

Модель оптимизирована для правдоподобности, а не для правды.

Как это работает

ШАГ 1 **Имитация**
Клонирование знакомого голоса из общедоступных аудиозаписей

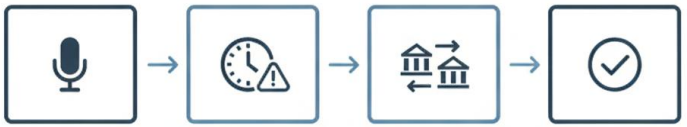
ШАГ 2 **Давление**
Создание ситуации срочности и конфиденциальности, чтобы избежать проверки

ШАГ 3 **Перенаправление**
Требование оперативного перевода на внешний счет

ШАГ 4 **Завершение**
Обещание возмещения «по официальным каналам»

Пример

- Убедительный голос + Кризисная история = Провал быстрой проверки



Почему это работает

Склонность к авторитетам
Люди подчиняются, когда статус звучит убедительно

Дефицит времени
Этапы проверки пропускаются

Обман с каналами связи
Идентификатор вызывающего абонента и детали кажутся «официальными»

Реальный кейс 2

Что делать, когда голос звучит «официально»

Вы несете ответственность за проверку

Практические меры защиты

- Используйте второй канал связи: перезвоните по известному номеру из справочника
- Замедлите транзакцию: добавьте обязательный этап ожидания
- Требуйте одобрения двумя лицами: отделите «запрос» от «исполнения»
- Кодовая фраза: договоритесь о ней заранее для подтверждения подлинности в чрезвычайных ситуациях



Бизнес-контроль

- Относитесь к срочности как к тревожному сигналу, а не как к причине
- Документируйте этапы проверки для действий с высокими ставками
- Обучайте команды: «Голос ≠ личность» во время учений и адаптации

Сначала проверьте источник — затем решайте, что делать или какой информацией делиться