Раздел 4.2.

Этические проблемы ИИ

4.2.1. Предвзятость данных и проблемы справедливости

4.2.2. Целостность контента: галлюцинации и дипфейки

4.2.3. Проблема непрозрачности «черного ящика»

4.2.4 Несанкционированное использование и защита прав

Определение

«Черный ящик»

- Процесс принятия решений ИИ настолько сложен внутри, что люди не могут логически понять или объяснить его

Проблема непрозрачности

- Трудности с объяснением того, как работает модель, что влияет на конкретный результат и почему было принято то или иное решение
- Это ограничивает подотчетность и подрывает доверие — особенно в ситуациях с высокими ставками

Суть

- Мы можем наблюдать входные и выходные данные, но промежуточные рассуждения/взаимодействия признаков не поддаются интерпретации.
- В результате система часто не может дать четкий ответ на вопрос: «Почему она приняла такое решение?»



1 Структура глубокого обучения

1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

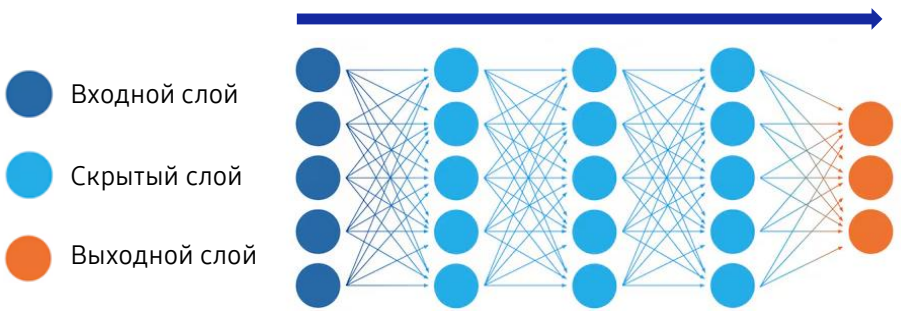
Сложность нейронных сетей

Масштаб параметров

- GPT-3: 175 миллиардов параметров / GPT-4: по оценкам, более 1 триллиона параметров

Многослойная структура

- Входной слой → Скрытый слой 1 (тысячи нейронов) → Скрытый слой 2 → Скрытый слой 3 → ... (от десятков до сотен слоев) → Скрытый слой N → Выходной слой
- Каждый нейрон получает сотни и тысячи входных сигналов
- Происходят миллионы и миллиарды математических операций, что делает невозможным их отслеживание человеком



1 Структура глубокого обучения

1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

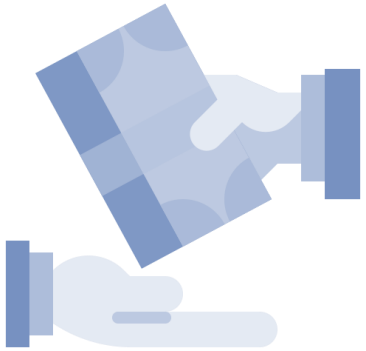
Нелинейное преобразование

- Линейное: y = ax + b (понятно)
- Нелинейное: вложенные функции в нескольких слоях
- Результат: связь между входом и выходом не является интуитивно понятной

Пример: ИИ для одобрения кредитов

- Вход: [доход, кредитный рейтинг, стаж работы, коэффициент задолженности, ...]
  → Скрытый слой 1: [0.234, 0.891, 0.456, ..., 0.723] (тысячи чисел)
  → Скрытый слой 2: [0.127, 0.598, 0.345, ..., 0.891] ...
  → Выход: вероятность одобрения 0.32 (отказ)
- Вопрос: «Почему было отказано?»

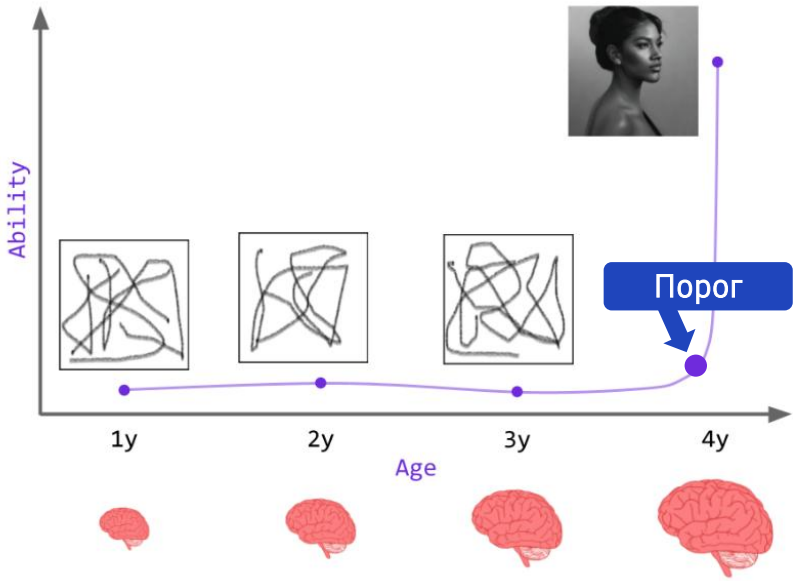
  Ответ: ??? (ИИ не может предоставить объяснение)



2 Эмерджентные свойства

1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

- Определение «эмерджентности»
  - В результате объединения множества простых частей в систему появляется новое поведение/качество
- Почему это важно для больших языковых моделей (проблема «черного ящика»)
  - Некоторые способности демонстрируют нелинейные «скачки» после достижения определенного порога по мере увеличения масштаба
  - Поэтому поведение трудно предсказать на основе меньших моделей → тестируйте на разных масштабах и постоянно контролируйте
- Пример: скачок в способностях ребенка рисовать
  - Продолжительное время ребенок рисует однотипно, выглядит так, что навыки не улучшаются, а затем при достижении порога происходит скачкообразное улучшение



AssemblyAI, Эмерджентные способности больших языковых моделей https://www.assemblyai.com/blog/emergent-abilities-of-large-language-models

2 Эмерджентные свойства

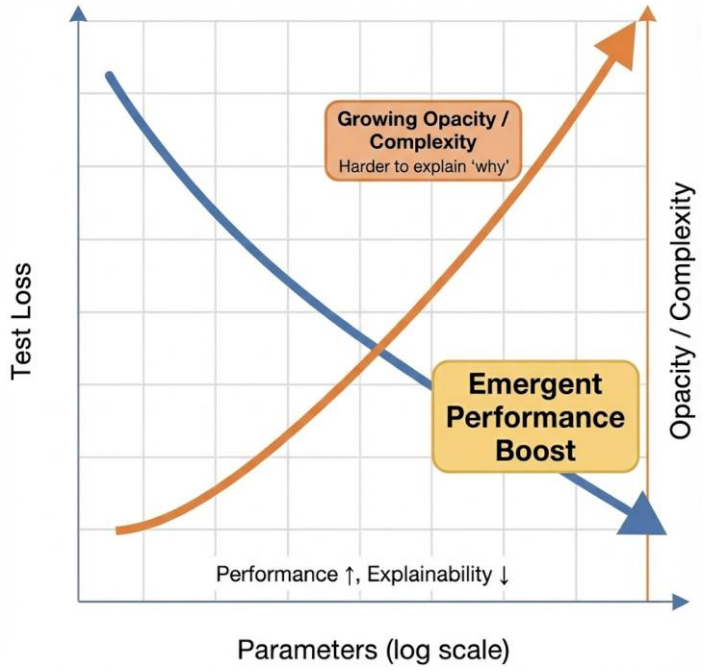
1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

Эмерджентные свойства в ИИ

- Возникают, когда миллиарды параметров взаимодействуют во время обучения, создавая неожиданные возможности, которые разработчики не программировали явно
- Например, модели классификации изображений могут спонтанно научиться отдавать приоритет фоновому контексту, а не объектам на переднем плане — паттерн, который возник во время обучения, а не был заложен разработчиками

Проблемы

- Объяснение причин возникновения этих эмерджентных паттернов в модели остается сложной задачей
- Условия, при которых эти возможности функционируют надежно, до сих пор неясны
- Такая непредсказуемость может привести к критическим ошибкам в реальных приложениях



3 Компромисс: объяснимость против точности

1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

Сложность модели и производительность

Простые модели (Приоритет ясности и доверия)

Высокая прозрачность решений
Позволяет людям легко их интерпретировать и проверять

Высокая подотчетность
Четкое обоснование результатов, позволяющее проводить проверку, и обеспечивающее подотчетность

Пример: линейная регрессия

Сложные модели (Приоритет производительности и мощности)

Превосходная производительность
Непревзойденная точность при обработке сложных многомерных данных

Природа «черного ящика»
Внутренние процессы непрозрачны, что затрудняет объяснение конкретных решений

Пример: глубокое обучение, Случайный лес*

Объяснимость ⟷ Точность

*) алгоритм машинного обучения Random Forest

3 Компромисс: объяснимость против точности

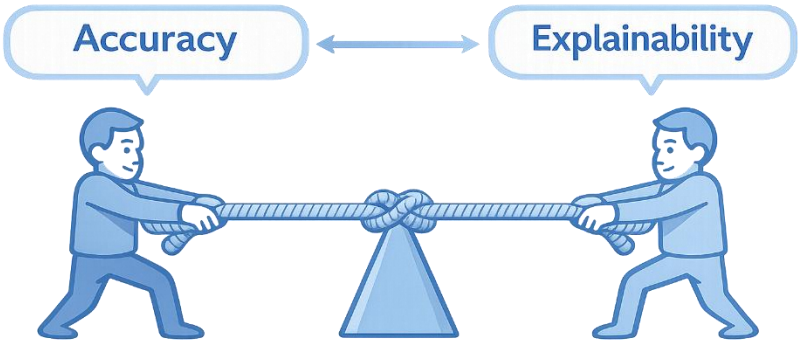
1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

Дилемма

- Высокая производительность часто требует сложных моделей, работу которых трудно объяснить
- Простые и понятные модели легче объяснить, но они зачастую имеют низкую производительность.
- В ситуациях с высокими ставками необходимы объяснения для обеспечения доверия, подотчетности и соблюдения нормативных требований, однако самые точные модели наименее прозрачны
- Даже если объяснения существуют, они могут быть неполными или вводящими в заблуждение (правдоподобность ≠ достоверность).

Проблема

- Приоритет конкурентоспособности заставляет команды выбирать сложные модели, создавая риск «черного ящика»
- В таких областях, как медицина и юриспруденция, объяснимость имеет важное значение, но есть ограничения
- Без объяснимости командам трудно отлаживать сбои, обосновывать решения и реагировать на инциденты (аудит/апелляция)



4 Проприетарные алгоритмы (коммерческая тайна)

1 Структура глубокого обучения
2 Эмерджентные свойства
3 Компромисс: объяснимость против точности
4 Проприетарные алгоритмы (коммерческая тайна)

Корпоративная политика неразглашения

- Алгоритмы — это основа конкурентоспособности, они защищены как коммерческая тайна
- Компании ограничивают раскрытие информации вовне
- Раскрытие информации может повысить риск безопасности (мошенничество)
- Юридические/регуляторные риски возрастают, если раскрытые детали позволяют манипулировать системой

Проблемы

- Внешний аудит не может проверить внутренние процессы — доверие строится на принципе «верь и пользуйся»
- Ограниченный доступ препятствует независимым исследованиям по выявлению предвзятости и нарушений безопасности
- Это ограничивает права пользователей быть информированными и возражать
- Подотчетность неясна, когда происходит ущерб (что изменилось, из-за чего)



Коммерческая тайна защищает инновации, но повышает планку для независимой проверки

1 Неясная подотчетность

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с обнаружением предвзятости и дискриминации
4 Правовые и этические риски

Сложная цепочка подотчетности

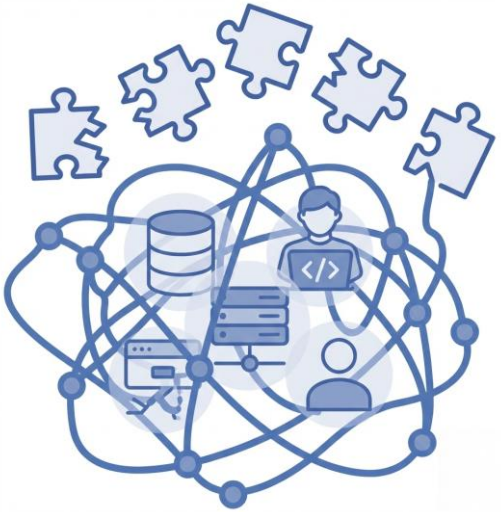
- Сборщик данных → Разметчик данных → Разработчик алгоритмов → Инженер по обучению моделей → Системный интегратор → Лицо, принимающее решение о внедрении → Конечный пользователь

Проблемы

- Трудно определить точную причину ошибки
- Сложно определить, кто виноват
- Каждая сторона может переложить ответственность на других

Правовой пробел

- Многим правовым базам до сих пор не хватает четких, явных правил подотчетности ИИ
- Традиционные подходы к ответственности за качество продукции трудно применить к адаптивным моделям, основанным на данных, что создает проблемы для компенсации ущерба пострадавшим



2 Трудности в формировании доверия

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с выявлением предвзятости и дискриминации
4 Правовые и этические риски

Психологическое сопротивление

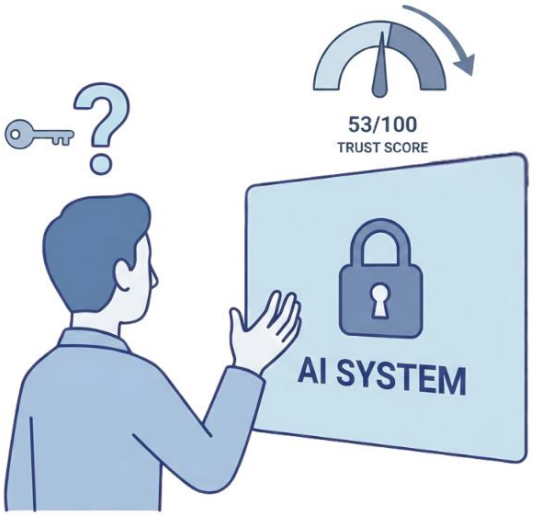
- Люди хотят понимать причины решений и принципиально не доверяют решениям, которые приняты без объяснений
- Это особенно распространено в таких сферах высокого риска, как медицина, финансы и юриспруденция

Статистика

- Согласно барометру доверия Edelman (2023), 61% респондентов заявили, что «не будут доверять ИИ, если не смогут понять, как он работает»
- Средний показатель доверия к ИИ составляет 53 из 100.

Долгосрочное влияние

- Препятствует внедрению технологий ИИ
- Даже полезные системы ИИ отвергаются
- Темпы инноваций замедляются



3 Трудности с выявлением предвзятости и дискриминации

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с выявлением предвзятости и дискриминации
4 Правовые и этические риски

Кейс глобальной HR-компании E: ИИ для найма (непрозрачность при предварительном отборе)

- Соискатель неоднократно отсеивался автоматизированной системой предварительного отбора
- Отказы происходили до любого этапа проверки человеком или собеседования
- Кандидаты получали мало объяснений или не получали их вовсе
- Ни кандидаты, ни работодатели не могли определить факторы, повлиявшие на результаты отбора
- В результате предвзятость может сохраняться незамеченной в больших масштабах за непрозрачными правилами

Почему прозрачность важна

- Без видимости признаков (параметров) команды не могут проверить, что стало причиной неравенства
- Без журналов событий и обоснования закономерности отказы кажутся случайными
- Без мониторинга проблемы могут повторяться в разных ролях и компаниях.

Пример

- Проблема → Предварительный отбор скрывает от людей факторы принятия решений
- Последствие → Предвзятость может сохраняться до тех пор, пока внешний триггер не заставит провести проверку

Непрозрачность не просто скрывает предвзятость — она препятствует её обнаружению и установлению ответственности

Трудности с обнаружением предвзятости и дискриминации

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с обнаружением предвзятости и дискриминации
4 Правовые и этические риски

Проблема обнаружения в «черном ящике»

- Предвзятость возникает, когда искаженные исторические данные исходно формируют закономерности
- Сложность «черного ящика» скрывает сигналы, задерживая их обнаружение
- Вред накапливается незаметно, поскольку решения принимаются до появления каких-либо предупреждений
- Проблемы часто всплывают чересчур поздно, через жалобы или расследования
- К тому времени могут пострадать тысячи людей — масштаб делает задержки дорогостоящими

Сложность аудита

- Несправедливость невозможно подтвердить без доступа к моделям, данным и журналам
- Ограниченная прозрачность блокирует независимую проверку и возможность конструктивного оспаривания
- Без доступа споры трудно разрешить и исправить на ранней стадии



Если систему нельзя проверить, ей нельзя доверять в широких масштабах

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с обнаружением предвзятости и дискриминации
4 Правовые и этические риски

4 Правовые и этические риски

Право на объяснение

Пример - статья 22 GDPR*

- Право запрашивать объяснение автоматизированных решений
- Касается решений, которые «порождают правовые последствия или иным образом существенно влияют» на физических лиц
- Например, отказ в кредите, отказ в приеме на работу, отказ в страховании.

«Черный ящик» = Нарушение прав

- Неспособность объяснить логику нарушает «право на объяснение» согласно GDPR
- Пользователи не могут понять, какие факторы привели к принятию решения
- Это подрывает подотчетность и способствует скрытым предвзятостям
- Не зная причин, пользователи не могут оспорить или улучшить решения



Необъяснимые решения ИИ превращают технологию из инструмента в барьер на пути к справедливости

*) GDPR (General Data Protection Regulation) — это регламент по защите персональных данных, действующий в странах ЕС с 2018 года

4 Правовые и этические риски

1 Неясная подотчетность
2 Трудности с формированием доверия
3 Трудности с обнаружением предвзятости и дискриминации
4 Правовые и этические риски

Элементы справедливого процесса

- Прозрачное принятие решений
- Предоставление разумного обоснования
- Возможность оспорить, обжаловать или запросить пересмотр решения



Как «черный ящик» нарушает справедливый процесс

- Логика принятия решений непрозрачна и не может быть объяснена
- Пользователи получают результаты без какого-либо обоснования
- Пользователи не могут оспорить решения, не зная причин
- У пользователей нет четкого пути для обжалования, поскольку доказательства и обоснования недоступны
- Нарушает надлежащую правовую процедуру и подрывает правовую легитимность

Необъяснимые решения ИИ превращают технологию из инструмента в барьер на пути к правосудию

Реальный кейс 1

Инцидент с роботакси Cruise (2023)

Обзор инцидента

- Время/Место: 2 октября 2023 г., Сан-Франциско, Калифорния
- Инцидент: Роботакси Cruise протащило пешехода около 20 футов (около 6 метров) после столкновения
- Пострадавшая сначала была сбита автомобилем под управлением человека, затем ее переехало и протащило роботакси

Технические проблемы

- Система ИИ не смогла обнаружить пешехода, оказавшегося под транспортным средством
- Система попыталась припарковаться вместо того, чтобы немедленно остановиться
- Неспособность ИИ справляться со сложными, неожиданными сценариями
- Крайний случай, недостаточно охваченный обучающими данными



Проблема «черного ящика»

- Журналы показывают сбои в обнаружении, но не могут объяснить причину неверной классификации
- Невозможно определить, была ли это системная ошибка или крайний случай
- Отсутствие прозрачности сделало невозможным раннее выявление этих критических недостатков

Реальный кейс 1

Инцидент с роботакси Cruise (2023)

Дилемма ответственности

- Водитель: Первый водитель, сбивший пешехода, не был установлен и не понес ответственности
- Компания: Cruise не предъявили уголовных обвинений, несмотря на сокрытие деталей инцидента; генеральный директор ушел в отставку, а эксплуатация автопарка была приостановлена
- ИИ: Ошибочные решения системы не могут быть предметом ответственности, так как она не является юридическим лицом

Уроки

- ИИ типа «черный ящик» несет значительные риски в критически важных областях
- Человеческий контроль необходим, но сам по себе недостаточен
- Внедряйте многоуровневые системы безопасности (избегайте полагаться на один механизм защиты)
- Прозрачность имеет решающее значение для выявления и устранения проблем
- Необходимы четкие правовые рамки для определения ответственности ИИ



Четкая подотчетность и прозрачность необходимы для предотвращения сбоев в работе ИИ

Реальный кейс 2

Скандал с мошенничеством при получении пособий с помощью ИИ (2023)

Обзор инцидента

- Время/Место: использованный алгоритм (2013–2019); скандал и последствия (2019–2023), страна ЕС
- Национальная налоговая служба использовала систему ИИ для выявления мошенничества с пособиями на детей
- Система ошибочно обвинила около 26 000 семей в течение нескольких лет
- Последствия непропорционально сильно затронули этнические меньшинства и лиц с двойным гражданством
- Скандал привел к отставке правительства (2021) и масштабным выплатам компенсаций (2023)

Основные проблемы

- Семьи были заклеймены как «мошенники» без внятных объяснений
- Решения «черного ящика» затрудняли понимание или проверку обвинений
- Апелляции и оспаривания были медленными, ограниченными или неэффективными
- Принципы надлежащей правовой процедуры на практике были подорваны
- Многие семьи столкнулись с серьезными долгами и длительным социальным ущербом



Реальный кейс 2

Скандал с ИИ в сфере социальных пособий (2023 г.)

Юридические и политические последствия

- Парламентское расследование (2020 г.) выявило дискриминационный алгоритм
- Весь состав кабинета министров ушел в отставку в 2021 году
- В 2023 году было предписано выплатить компенсацию в размере 30 000 евро каждой семье
- Использование алгоритма было окончательно прекращено

Уроки

- ИИ типа «черный ящик» может нанести катастрофический ущерб при принятии важных государственных решений
- Непрозрачность скрывает дискриминацию и препятствует подотчетности
- Без права на объяснение люди не могут защититься от ложных обвинений
- Эффективность ИИ не может оправдать принесение в жертву фундаментальных прав, таких как надлежащая правовая процедура
- Правительства должны обеспечивать объяснимость, когда ИИ влияет на жизнь граждан

