Раздел 4.2.

Этические проблемы ИИ

4.2.1. Предвзятость данных и вопросы справедливости

4.2.2. Целостность контента: галлюцинации и дипфейки

4.2.3. Проблема непрозрачности «черного ящика»

4.2.4. Несанкционированное использование и защита прав

Несанкционированное использование и защита прав

Определение

- Неопределенность атрибуции
  - Неясная ответственность за решения ИИ и право собственности на результаты его работы
- Проблемы владения
  - Неясные права и разрешения в отношении данных, результатов работы и ответственности

Пример

- Если результат работы нарушает чьи-либо права, ответственность может оспариваться между сторонами
- Неясность прав собственности повышает риски и замедляет внедрение

Проблемы владения: ключевые области

Юридические аспекты

- Права на использование, воспроизведение или распространение контента

Конфиденциальность

- Право собственности на персональные данные и действительное согласие пользователя.

Авторское право

- Разрешения на использование обучающих данных и право собственности на результаты работы.

Подотчетность

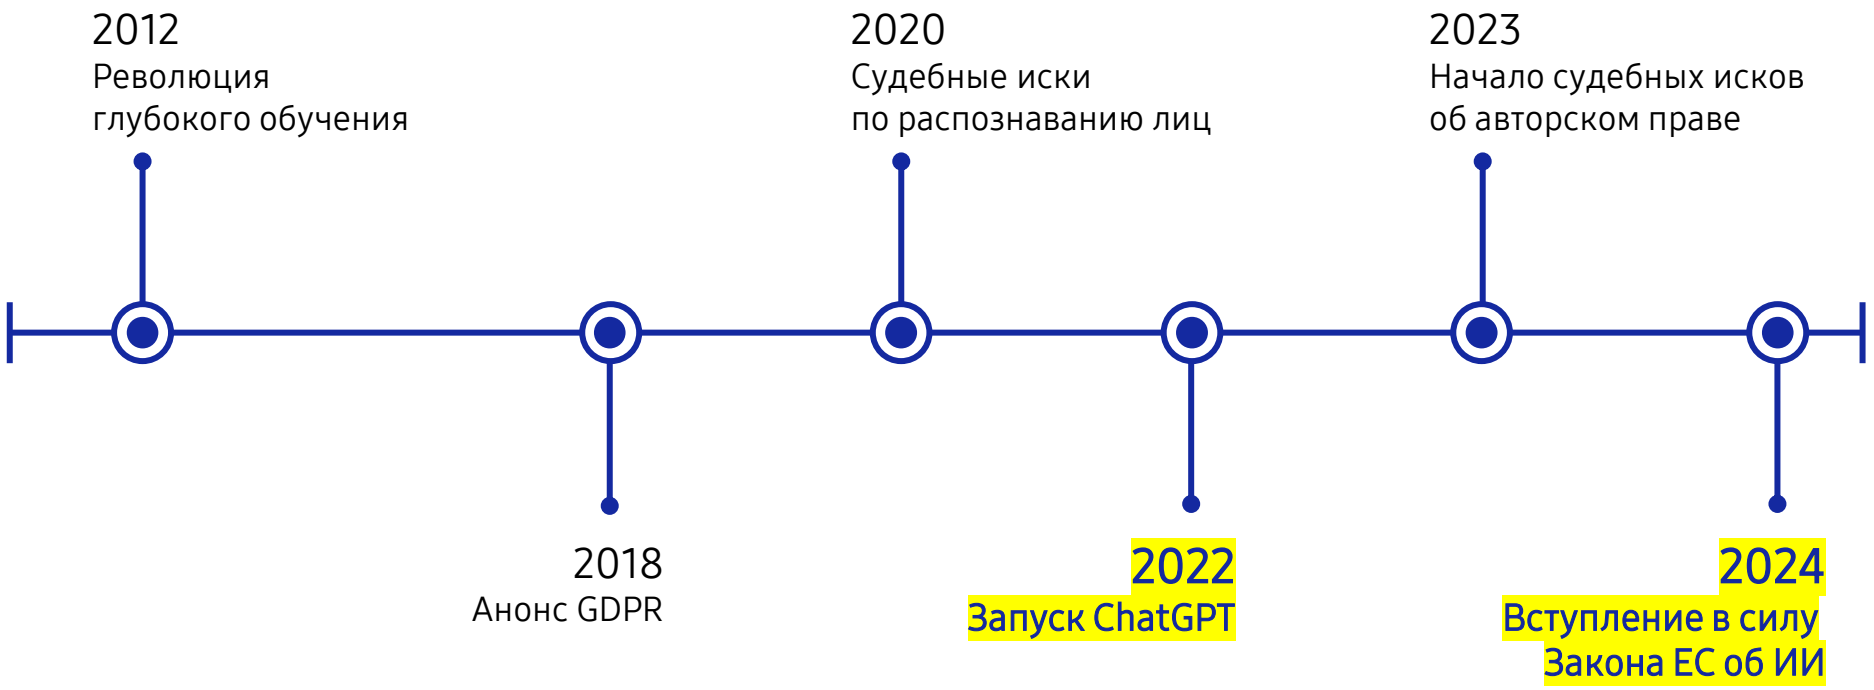
- Ответственность за ущерб, убытки или претензии о нарушении прав.

Определите права, согласие и ответственность перед внедрением генеративного ИИ

1 Нормативное отставание

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

Сравнение хронологии



1 Регуляторное отставание

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

Правила меняются медленно, в то время как возможности генеративного ИИ быстро масштабируются.

Проблемы

- Технологии меняются за месяцы, законы адаптируются годами
- Регуляторный разрыв создает нечеткие границы между «разрешенным» и «незаконным».
- Вред часто распространяется до того, как становятся возможными правоприменение и исправление ситуации.



Примеры

Дипфейки откровенного характера

- Изображения, созданные ИИ без согласия оригинала, широко распространились до ужесточения контроля на платформах
- Хронология: бум генерации изображений (2022) → крупный инцидент (янв. 2024) → задержка реакции

Споры об авторских правах на музыку, созданную ИИ

- Звукозаписывающие компании заявили о нарушении авторских прав при обучении и генерации и подали судебные иски
- Хронология: масштабирование музыкальных ИИ-сервисов (2023) → подача исков (июнь 2024) → задержка реакции

2 Проблема двойного назначения

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

Одна и та же технология может приносить пользу, использоваться во вред или находиться в «серой зоне»

Технология	Типичная польза (разрешено)	Типичное злоупотребление (запрещено)	Серая зона (критерии)
Генеративный ИИ (текст)	Черновики для внутренних целей	Мошенничество / выдача за другое лицо	Раскрытие информации, точность
Генеративный ИИ (изображения)	Оригинальные активы	Дипфейки без согласия	Согласие, права на изображение
Синтез голоса	Доступность для лиц с ОВЗ	Голосовой фишинг	Согласие, проверка личности
Рекомендательные системы	Ранжирование по релевантности	Дискриминирующий таргетинг	Справедливость, прозрачность
Распознавание лиц	Разблокировка устройства	Массовая слежка	Ограничение целей, хранение данных
Использование данных для обучения	Лицензированные наборы данных	Нелицензированный парсинг	Статус прав, отказ от участия

- Почему возникает «неоднозначное использование»
  - Намерение и ожидания: законная цель, неясное согласие
  - Размытая граница: помощь против манипуляции
  - Риск масштаба: небольшое использование vs. массовое воздействие
- Проблемы
  - Определите допустимые цели и запрещенные результаты
  - Требуйте раскрытия информации и согласия для использования, ориентированного на пользователя
  - Установите пороговые значения для масштабирования, воздействия и мониторинга

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

2 Проблема двойного назначения

Одна и та же возможность может приносить как пользу, так и вред — политический выбор всегда предполагает компромиссы

- Риск двойного назначения: меры контроля, снижающие вероятность злоупотреблений, могут также ограничивать законное использование

Риск чрезмерного регулирования

- Концепция: Широкие запреты на «злоупотребления» могут непреднамеренно заблокировать ценные «позитивные варианты использования»
- Пример: Запреты на распознавание лиц сокращают слежку, но препятствуют поиску пропавших без вести
- Последствие: Инновации замедляются, а полезные приложения могут исчезнуть или переместиться в другие юрисдикции
- Рекомендация: Используйте целевые правила для конкретных случаев использования с четко утвержденными исключениями

Неоднозначность стандартов

- Концепция: Границы между «вдохновением» и «нарушением» часто неясны
- Пример: Имитация стиля — дань признания (разрешено) против нарушения авторских прав (запрещено)
- Последствие: Команды сталкиваются с противоречивыми решениями и правовой неопределенностью
- Рекомендация: Определите четкие внутренние пороги и установите проверки происхождения данных

- Результат: Баланс между мерами безопасности и сохранением законного использования

3 Проблемы с юрисдикцией

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

Трансграничный характер ИИ размывает понимание того, какие законы применяются и кто обеспечивает их соблюдение

Проблемная ситуация

- Системы ИИ выходят за рамки границ: разработка → хостинг → использование → причинение вреда могут происходить в разных странах
- Это создает противоречивые правила в отношении конфиденциальности, интеллектуальной собственности, безопасности и ответственности
- Ключевые вопросы: какой закон применяется, какой орган проводит расследование и какой суд рассматривает дело?



Регуляторный арбитраж (что это значит)

- Определение: перенос деятельности в юрисдикцию с более мягким регулированием
- Как это происходит: перемещение серверов, обработки данных или юридических лиц через границы
- Результат: использование пробелов в правоприменении и слабая международная координация

Влияние на бизнес

- Более высокие расходы на соблюдение нормативных требований из-за множества противоречивых правил
- Замедление реагирования на инциденты из-за неясности полномочий и юрисдикции
- Повышенные правовые риски при конфликте правил на разных рынках

4 Конфликты интересов сторон

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты интересов сторон

Существуют различные позиции относительно регулирования ИИ

Корпорации (технологические компании)

- Позиция: выступают за саморегулирование и делают упор на инновации
- Тезис: «Чрезмерное регулирование препятствует инновациям»
- Лоббирование: инвестируют значительные средства

Правительство (регуляторы)

- Позиция: баланс между регулированием и конкурентоспособностью
- Озабоченность: защита отечественных компаний против защиты граждан
- Различия: позиции варьируются в зависимости от страны
  - ЕС: более строгое регулирование, основанное на правах и рисках
  - США: более мягкий подход, большая опора на отраслевые стандарты и существующие законы
  - Китай: более жесткий государственный надзор и контроль



4 Конфликты интересов сторон

1 Регуляторное отставание
2 Проблема двойного назначения
3 Проблемы с юрисдикцией
4 Конфликты заинтересованных сторон

Гражданское общество (правозащитные группы)

- Позиция: выступают за строгое регулирование
- Опасения: конфиденциальность, дискриминация, безопасность
- Ограничения: недостаточное техническое понимание и ограниченные ресурсы
- Конфликты с корпорациями и политиками по поводу регулирования и приоритетов

Академические круги (исследователи и специалисты по этике)

- Позиция: смешанные взгляды (как поддерживающие, так и критические)
- Вклад: исследования, предложения по руководящим принципам
- Ограничения: трудно достичь консенсуса
- Конфликты между специалистами по этике, технологами и экономистами



Конкурирующие стимулы и неравномерное распределение ресурсов замедляют достижение консенсуса, откладывая регулирование

1 Нарушение конфиденциальности

1 Нарушение конфиденциальности
2 Нарушение авторских прав
3 Отсутствие подотчетности

Несанкционированный сбор данных

- Осуществляется без согласия или ведома пользователя
- Трудно или почти невозможно удалить, даже по запросу

Проблемы общества тотальной слежки

- Распознавание лиц может происходить где угодно в общественных местах
- Становится возможным отслеживание моделей перемещения
- Слежка в стиле «Большого брата» становится все более вероятной
- Свобода выражения мнений и собраний может быть ограничена

Специфика данных биометрического распознавания

- Данные лица, отпечатков пальцев и радужной оболочки глаза невозможно изменить в течение жизни
- Кредитные карты можно перевыпустить, а биометрические данные нет
- Утечка биометрической информации имеет пожизненные последствия
- Ущерб фактически необратим



Большой брат

Определение

- Постоянный, невидимый мониторинг со стороны властей или платформ

Последствие

- Люди занимаются самоцензурой, когда чувствуют, что за ними наблюдают

2 Нарушение авторских прав

1 Нарушение конфиденциальности
2 Нарушение авторских прав
3 Отсутствие подотчетности

Риски нарушения авторских прав в обучающих данных

Масштаб

Масштаб

- Модели обучаются на более чем 5,8 млрд пар «изображение-текст» (например, LAION-5B), собранных без согласия авторов

Беспорядочный сбор данных

- Веб-краулеры собирают всё: от личных портфолио до лицензированных стоковых изображений

Пример: Stable Diffusion, LAION-5B

Возникающие проблемы

Риск репликации

- Переобучение может приводить к созданию результатов, почти идентичных оригинальным работам

Вытеснение с рынка

- Имитация стиля позволяет создавать более дешевые альтернативы, заменяющие художников-людей

Бремя доказывания

- Трудно доказать нарушение авторских прав из-за «черного ящика» систем ИИ

Последствия: потеря рабочих мест, юридические споры

1 Нарушение конфиденциальности
2 Нарушение авторских прав
3 Отсутствие подотчетности

3 Пробел в подотчетности

Когда происходит ущерб, ответственность может быть неясной во всей цепочке поставок ИИ-услуг

- **Определение**
  - Не существует единой ответственной стороны при возникновении ущерба, поэтому она оспаривается между множеством участников
- **Пример проблемы**
  - Кто несет ответственность, если ущерб стал следствием решения, принятого с помощью ИИ?
  - Ответственность может оспариваться между разработчиками, внедряющими организациями, пользователями и платформами.

Проблемы в действующем законодательстве

Отставание регулирования	Ограничения ответственности за качество продукции	Пробелы в правоприменении	Сложности с возмещением ущерба пострадавшим
▸ Правила, касающиеся ИИ, развиваются медленнее, чем его внедрение ▸ Далее: дело о дипфейке Тейлор Свифт показывает реальные пробелы	▸ Трудно доказать дефект или халатность, когда решения непрозрачны. ▸ Доказательства фрагментированы между данными, моделями, рабочими процессами и вмешательствами человека	▸ Вред может распространиться до того, как меры по сообщению о нарушениях и удалению контента станут эффективными ▸ Платформы часто действуют реактивно, уже после того, как контент становится вирусным	▸ Жертвы сталкиваются с задержками в удалении контента, расследовании и получении компенсации ▸ Трансграничный хостинг и повторные публикации усложняют правоприменение

Реальный кейс 1

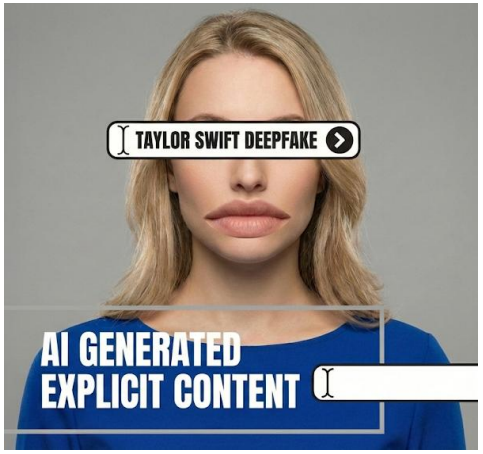
Кризис дипфейков – Инцидент с Тейлор Свифт

Что произошло

Дипфейк с интимным контентом без согласия (Image Abuse) быстро распространился по платформам, опережая механизмы модерации и правоприменения

Обзор инцидента

- Событие: Распространение дипфейковых изображений интимного характера без согласия оригинала на платформе X (январь 2024 г.)
- Механизм: Создано с помощью потребительских инструментов генеративного ИИ; проверки безопасности были обойдены
- Масштаб: Один из постов набрал более ~47 млн просмотров до момента удаления



Первопричины (почему реакция не успевала за событиями)

- Отставание нормативно-правовой базы: юридические средства защиты отстают от распространения контента на платформах в реальном времени
- Пробелы в правоприменении: процессы сообщения о нарушениях и удаления контента движутся медленнее, чем повторные публикации
- Отсутствие подотчетности: ответственность поделена между создателями инструментов, платформами и пользователями

Виральность опережает правоприменение при отсутствии контроля безопасности и подотчетности.

Реальный кейс 1

Кризис дипфейков – инцидент с Тейлор Свифт

Реакция и выводы

Реакция была быстрой, но по большей части запоздалой, так как контент уже успел стать вирусным

- Реакция (последующие действия)
  - Платформа: поиск был заблокирован; аккаунты удалены; меры по удалению контента усилены
  - Инструментарий: уязвимости, позволяющие злоупотреблять промптами ИИ, устранены
  - Политика: обсуждались меры по борьбе с инцидентами, связанными с несогласованным интимным контентом, и усилилось давление в плане обеспечения соблюдения правил
- Уроки для организаций
  - Безопасность как принцип проектирования: отдавайте приоритет предотвращению, а не устранению последствий после того, как контент стал вирусным
  - Проверка происхождения: выявляйте манипуляции и блокируйте контент с высоким уровнем риска на ранней стадии
  - Четкое распределение ответственности: назначьте ответственных за мониторинг, удаление контента и эскалацию проблем



Обеспечьте профилактику и четкое распределение ответственности до того, как произойдет следующий инцидент

Реальный кейс 2

Война за авторские права в ИИ-музыке (2024)

Обзор инцидента

- Стороны: RIAA* (включая крупные лейблы, такие как Sony, Universal и Warner) против стартапов в области генеративного ИИ (Suno, Udio)
- Проблема: модели ИИ генерировали вокал, неотличимый от голосов известных артистов, и воспроизводили защищенные авторским правом мелодии
- Ключевое доказательство: наличие «продюсерских тегов» в песнях, созданных ИИ (например, «Jason Derulo»), стало явным доказательством несанкционированного обучения на материалах, защищенных авторским правом

Противостояние логики сторон

Категория	RIAA (сторона правообладателей)	ИИ-компании (сторона Suno/Udio)
Основная логика	Массовое воровство защищенных авторским правом звукозаписей ради коммерческой выгоды	Добросовестное использование: анализ данных для создания новых, не нарушающих авторские права звуков
Суть обучения	Копирование уникального человеческого самовыражения и вокала является нарушением авторских прав	Изучение статистических закономерностей музыки, а не копирование файлов
Влияние на рынок	Дешевые имитации обесценивают человеческое творчество	Демократизация создания музыки и расширение рынка в целом

*) Американская ассоциация звукозаписывающих компаний

Реальный кейс 2

Война за авторские права в ИИ-музыке (2024)

Юридические вопросы и глобальные судебные иски

Критические правовые вопросы (музыка)

- Нарушение прав личности и «голосовое сходство» артистов
- Доказательства несанкционированного обучения моделей через прямое воспроизведение продюсерских тегов

Отраслевые эталонные судебные иски

- Журналистика: NYT против OpenAI — использование контента
- Визуальное искусство: имитация стиля без согласия автора
- Программирование: несанкционированное использование или воспроизведение лицензионного кода с открытым исходным кодом

Ключевые уроки и этические стандарты

Устранение правовых и регуляторных пробелов

- Внедрение или усиление нормативных актов, таких как «Закон ELVIS», для защиты личности и художественного стиля

Переосмысление информированного согласия

- Публичная доступность потокового контента не подразумевает согласие на интеллектуальный анализ данных с помощью ИИ

Экосистема справедливой компенсации

- Переход от нерегулируемой практики сбора данных (скрейпинга) к стандартизированным структурам лицензирования

Сосуществование: ИИ должен быть разработан для расширения творческих возможностей, а не для замены индивидуальности

Как мы можем решить эти проблемы?

- Рассмотренные проблемы выходят за рамки технических сбоев, они носят структурный, а не случайный характер
- Причина их возникновения — данные и способы проектирования моделей
- Хорошая новость в том, что пути решения есть

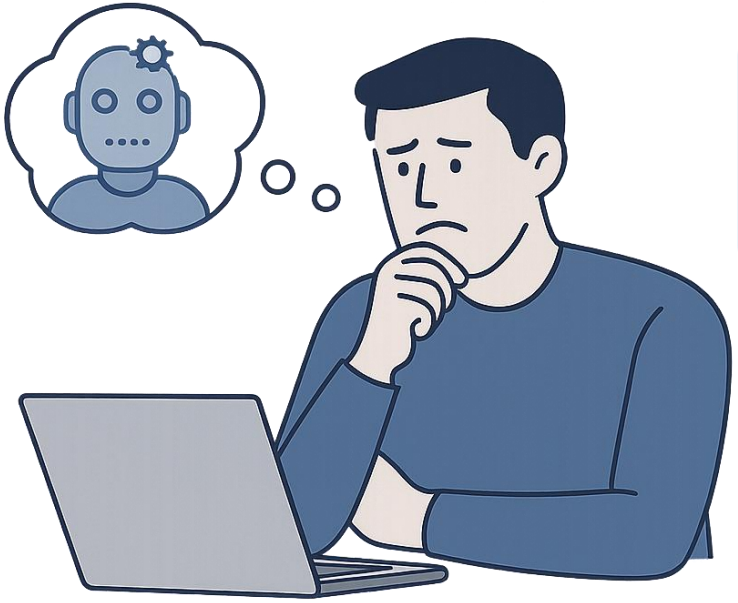
Текущие проблемы (риски)

Галлюцинации

Предвзятость

Дипфейк

«Черный ящик»



Будущие решения (этика ИИ)

Прозрачность

Справедливость

Безопасность

Ответственность