Раздел 4.3.

Принципы ответственного ИИ и управление рисками

4.3.1. За пределами этики: внедрение защитных механизмов ответственного ИИ

4.3.2. Защитные механизмы на основе политик: управление и работа с данными

4.3.3. Механизмы защиты I: обеспечение доверия и безопасности

4.3.4. Механизмы защиты II: прозрачность и решение проблемы «черного ящика»

Защитные механизмы на основе политик

Определение

- Защитные механизмы, разработанные для устранения предвзятости и обеспечения защиты
- Подход, который устанавливает четкие правила и процедуры в виде политик до развертывания ИИ и обеспечивает их соблюдение во всех проектах

Основные принципы

- Эти защитные механизмы строятся на четырех основных столпах:
  Принципы, Управление, Процессы и Подотчетность

Внедрение

- Требует последовательности, идеально подходит для отраслей со строгим соблюдением нормативных требований и системами ИИ с высоким уровнем риска



Пример защитных механизмов на основе политик

- Стандарт ответственного ИИ от Microsoft
  - Стандарт v2 с системой Frontier Governance Framework (февраль 2025 г.)
  - Комплексная общеорганизационная система управления разработкой и развертыванием ИИ



Защитные механизмы на основе политик: Контроль предвзятости

Задача для решения	Инструменты (примеры)	Что это дает
Системная предвзятость ▸ Приводит к несправедливым результатам при найме, кредитовании и в здравоохранении **Риск дискриминации** ▸ Создает неравное воздействие на защищенные группы при скоринге и ранжировании **Дисбаланс данных** ▸ Приводит к искаженным прогнозам из-за недостаточной представленности определенных групп ▸ Снижает обобщающую способность модели и усиливает существующее неравенство	**IBM/Trusted-AI** ▸ AI Fairness 360 для измерения и устранения предвзятости **Google PAIR** ▸ What-If Tool (WIT) для визуализации подгрупп и тестирования пороговых значений **Внутренний контроль политик** ▸ Обязательные проверки на предвзятость перед развертыванием ▸ Рабочий процесс утверждения комитетом по ответственному ИИ (RAI) ▸ Документированные пороговые значения справедливости	**Анализ разрывов (Gap Analysis)** ▸ Выявляет различия между подгруппами и скрытые предвзятости **Валидация модели** ▸ Сравнивает варианты устранения рисков и записывает результаты для аудита **Снижение рисков и соответствие требованиям** ▸ Гарантирует, что модели соответствуют стандартам справедливости и нормативным требованиям ▸ Предоставляет документальное подтверждение для аудитов и внешних проверок

Защитные механизмы на основе политик : Контроль предвзятости

- AI Fairness 360 (AIF360)
  - Обнаруживает и устраняет предвзятость в наборах данных и моделях машинного обучения
- Что он предоставляет
  - Измеряет метрики справедливости для различных групп
  - Применяет алгоритмы устранения предвзятости на этапах предварительной, промежуточной или постобработки
  - Сравнивает результаты и документирует принятые решения для дальнейшей проверки



Инструменты визуализации, такие как What-If Tool, помогают командам исследовать срезы данных и проводить стресс-тестирование гипотез

Защитные механизмы на основе политик : Защита конфиденциальности

Задача

- Предотвращение нарушений конфиденциальности, вызванных неразборчивым сбором данных. Например, сервисы поиска по распознаванию лиц, используемые некоторыми компаниями

Используемые технологии

- Дифференциальная конфиденциальность (Differential Privacy, DP)
- Федеративное обучение (Federated Learning, FL)

Как это работает

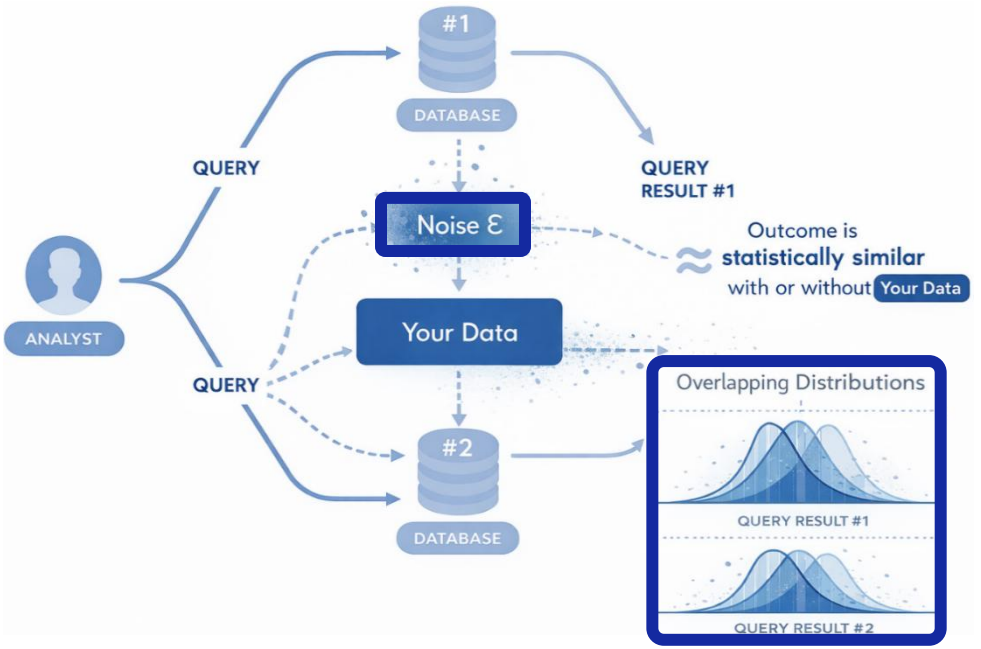
- Добавляет математический шум, чтобы предотвратить идентификацию конкретных лиц, даже при анализе масштабных наборов данных
- Обучает модели непосредственно на устройствах пользователей без централизации исходных данных. Это гарантирует, что личная информация никогда не собирается и не раскрывается, а также снижает риск утечки информации



Защитные механизмы на основе политик: Защита конфиденциальности

- Дифференциальная приватность (DP)
  - **Внесение шума**
    Добавляет математический шум (небольшие статистические ошибки) в набор данных, чтобы сохранить общие статистические закономерности, делая при этом отдельные области данных неидентифицируемыми
  - **Регуляризация для конфиденциальности**
    Предотвращает запоминание ИИ обучающих данных, тем самым снижая риск выдачи моделью конфиденциальной личной информации
  - **Вероятностная неразличимость**
    Гарантирует, что результаты остаются статистически схожими (≈) независимо от того, включены ли данные конкретного человека

Как работает дифференциальная приватность



Защитные механизмы на основе политик: Защита конфиденциальности

Федеративное обучение (FL)

- Модель обучается на устройстве каждого пользователя без передачи исходных данных на центральный сервер, а для обновления глобальной модели собираются только измененные веса
- Поскольку исходные данные никогда не покидают устройство, этот подход повышает производительность ИИ, снижая при этом риски для конфиденциальности — особенно при работе с конфиденциальной медицинской информацией или данными личных разговоров

