Раздел 4.3.

Принципы ответственного ИИ и управление рисками

4.3.1. За пределами этики: внедрение защитных механизмов ответственного ИИ (RAI)

4.3.2. Защитные механизмы на основе политик: управление и работа с данными

4.3.3. Механизмы защиты I: обеспечение доверия и безопасности

4.3.4. Механизмы защиты II: прозрачность и решение проблемы «черного ящика»

Технические механизмы защиты

Определение

- Защитные механизмы, разработанные для блокировки галлюцинаций и неправомерного использования
- Эти механизмы встраивают средства обеспечения безопасности в процессы модели для гарантии безопасных результатов

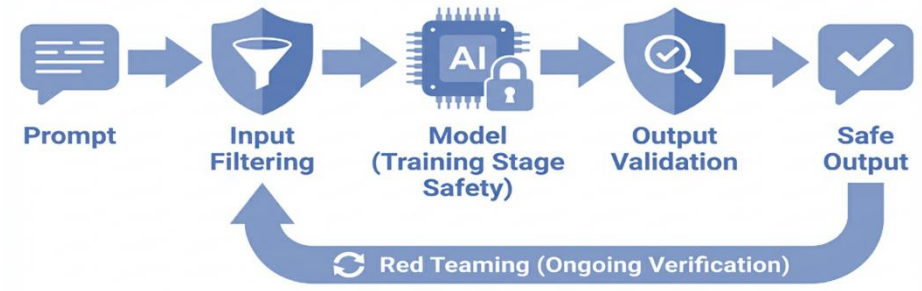
Основные принципы

- Защитные механизмы опираются на четыре основных столпа: фильтрация входных данных, обеспечение безопасности на этапе обучения, проверка выходных данных и атака «красной команды» (red teaming*)

Реализация

- Применяется в сервисах на базе LLM, средах с ответами в реальном времени и интерактивными пользовательскими сценариями

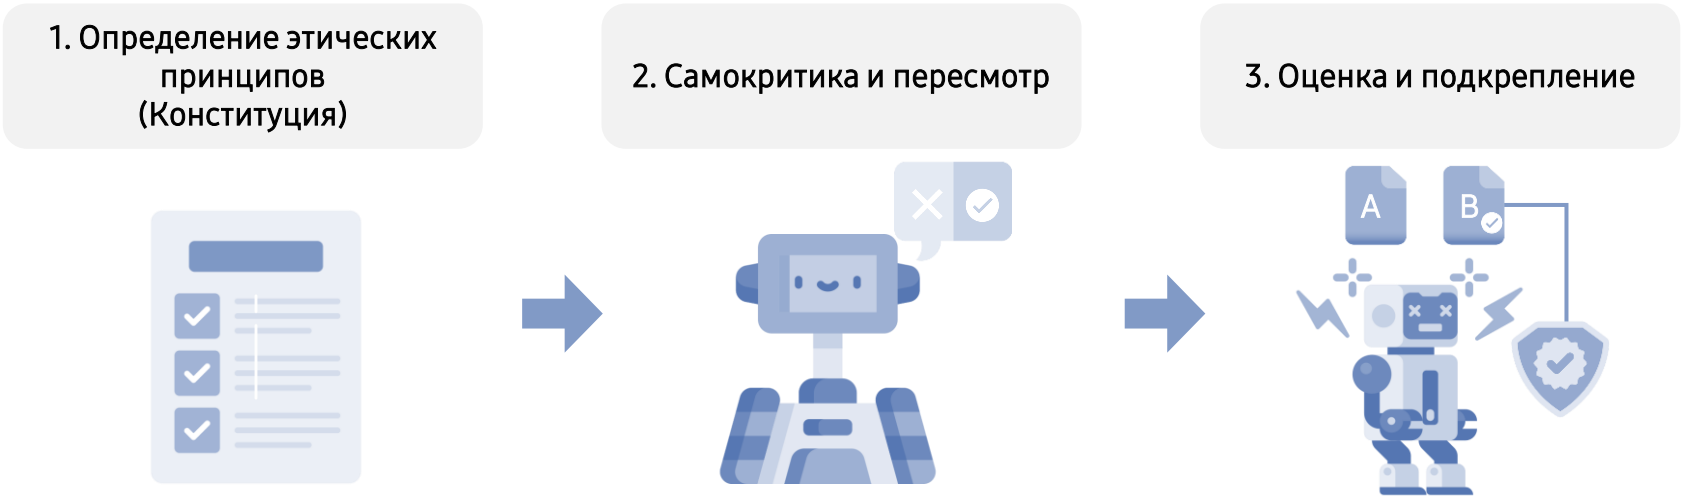
Основные компоненты и технологический процесс



*) Red teaming - комплексная имитация реальных атак с целью оценки кибербезопасности систем. «Красная команда» представляет собой группу специалистов, выполняющих тесты на проникновение в систему.

Пример технических механизмов защиты

- «Конституционный ИИ» от Anthropic (Constitutional AI, CAI)
  - «Конституционный ИИ» — фундаментальный механизм безопасности, используемый в таких моделях, как Claude 3
  - Созданные технические механизмы защиты помогают моделям ИИ усваивать принципы безопасности во время обучения



Конституционный ИИ: Основной процесс обучения (упрощенная схема этапов)

Технические механизмы защиты: Обоснование (Grounding)

Задача для решения

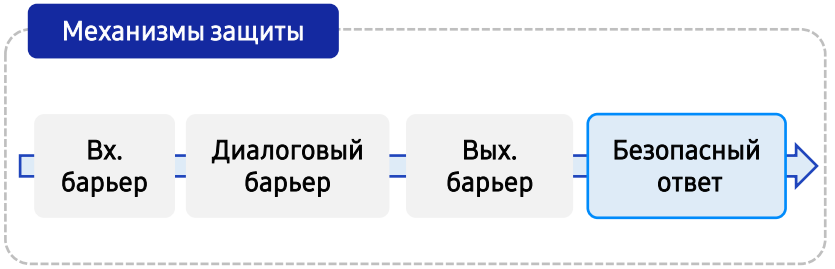
- Минимизация неподтвержденных или вымышленных утверждений в критически важных результатах (например, в юридических, политических или клиентских вопросах)

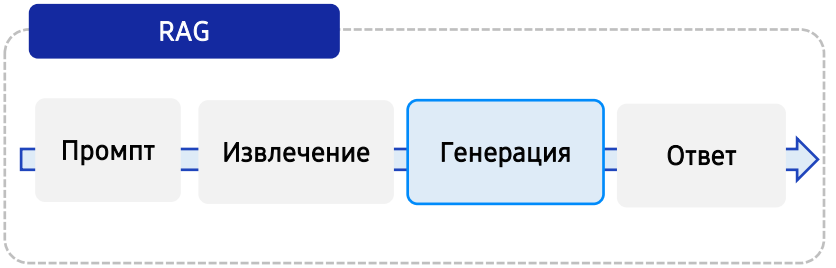
Используемые подходы

- **NeMo Guardrails (NVIDIA)**: внедряет механизмы защиты для диалогов в режиме реального времени
- **RAG (Retrieval-Augmented Generation)**: основывает ответы на извлеченных документах, а не полагается исключительно на параметрическую память

Как это предотвращает галлюцинации

- Проверка на соответствие политикам до, во время и после генерации
- Обоснование ответов путем извлечения релевантных источников и создания доказательств (включая ссылки, где это возможно)

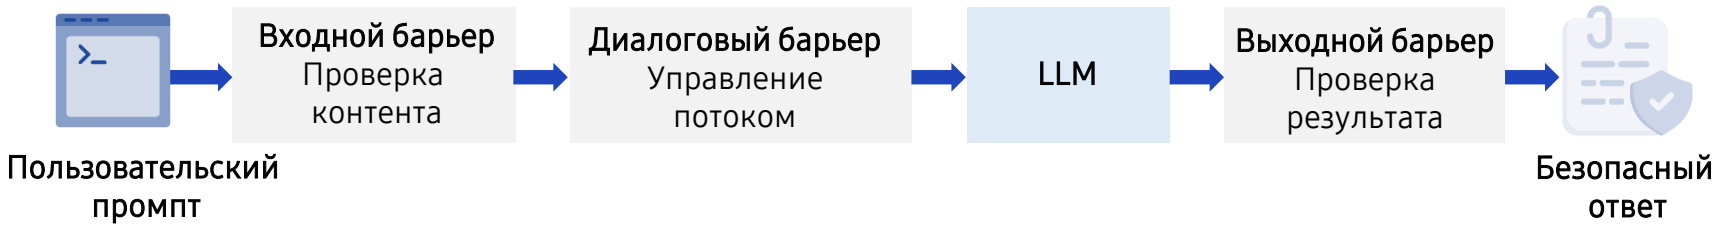




Защитные механизмы и обоснование гарантируют, что ИИ остается надежным, безопасным и опирается на факты

NeMo Guardrails: Упрощенная схема

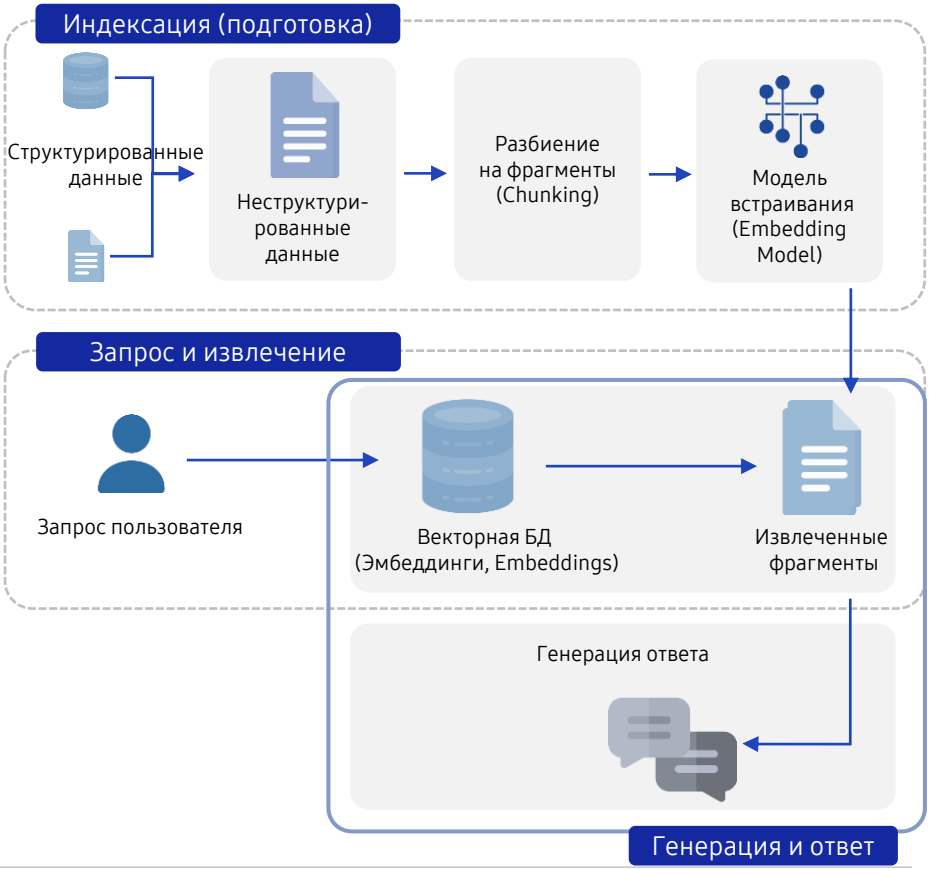
- Что это
  - Добавляет настраиваемые защитные барьеры для контроля того, что ИИ-помощник может принимать, говорить и делать
- Что делает (3 типа механизмов защиты/барьеров)
  - **Входной барьер (Input rail):** блокирует или переписывает рискованные запросы пользователей до того, как они попадут в модель
  - **Диалоговый барьер (Dialog rail):** направляет ход беседы, используя заранее определенные правила о том, что ИИ-помощник должен или не должен делать
  - **Выходной барьер (Output rail):** проверяет или пост-обрабатывает выходные данные модели перед выдачей ответа пользователю



Безопасность — это не функция модели, это выбор при проектировании процессов взаимодействия с пользователем

RAG: Поток генерации с обоснованием

- Что это
  - Сочетает языковую модель с поиском по хранилищу документов, выступающему в роли непараметрической памяти
- Почему полезно
  - Извлеченные фрагменты обеспечивают контекст и подтверждение источника, позволяя RAG генерировать основанные на фактах ответы, в большей степени, чем модели, полагающиеся только на параметрическую память
  - Оценка все равно необходима — возможны галлюцинации, если поиск работает слабо/неточно
- Как используется (типовой процесс)
  - **Индексация:** разбиение документов на части и создание эмбеддингов
  - **Поиск:** по запросу пользователя выполняется поиск top-k релевантных фрагментов
  - **Генерация:** ответ с использованием найденных доказательств, по возможности с ссылками на источники



Технические механизмы защиты: Обнаружение дипфейков

Задача

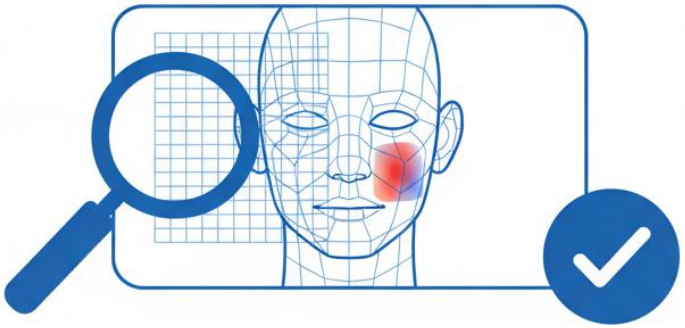
- Снижение риска использования медиа-контента, созданного ИИ, для введения в заблуждение, мошенничества или подрыва общественного доверия
- Растущая сложность разделения реальных медиафайлов и синтетического контента

Используемые технологии

- Экспертиза медиа (например, Microsoft Video Authenticator)
- Анализ физиологических и поведенческих сигналов (например, ритм моргания, нерегулярность пульса и признаки дыхания)

Ключевая цель

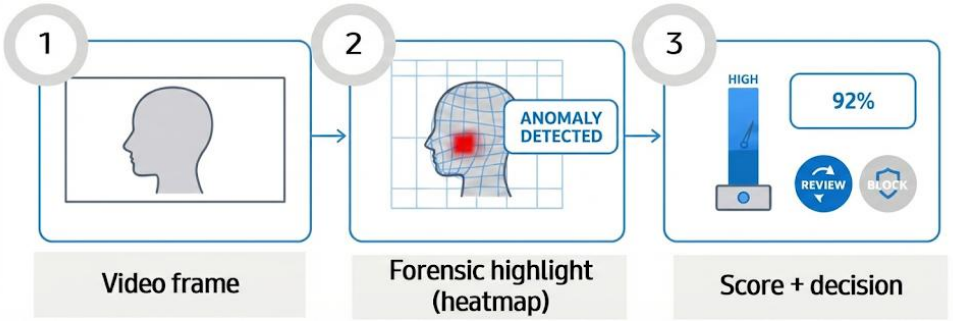
- Оценка вероятности манипуляции и запуск рабочих процессов верификации до распространения контента
- Защита пользователей и целостности платформы



RAG укрепляет доверие к тексту, созданному ИИ.
Обнаружение дипфейков укрепляет доверие к медиаконтенту, созданному ИИ

Видеотехническая экспертиза

- Microsoft Video Authenticator
  - Обнаруживает артефакты манипуляции на уровне кадров видео, которые трудно заметить визуально
  - Выдает оценку вероятности манипуляции каждого кадра для поддержки рабочих процессов автоматической модерации
  - Направляет контент на проверку, применяет предупреждающие метки или удаляет его на основе заранее заданных пороговых значений
- Альтернативные инструменты
  - Intel FakeCatcher, Sensity AI, Deepware Scanner и др.



Рабочий процесс видеотехнической экспертизы



Реальный с [99%]

Поддельный с [99%]

Пример: Анализ биологических сигналов

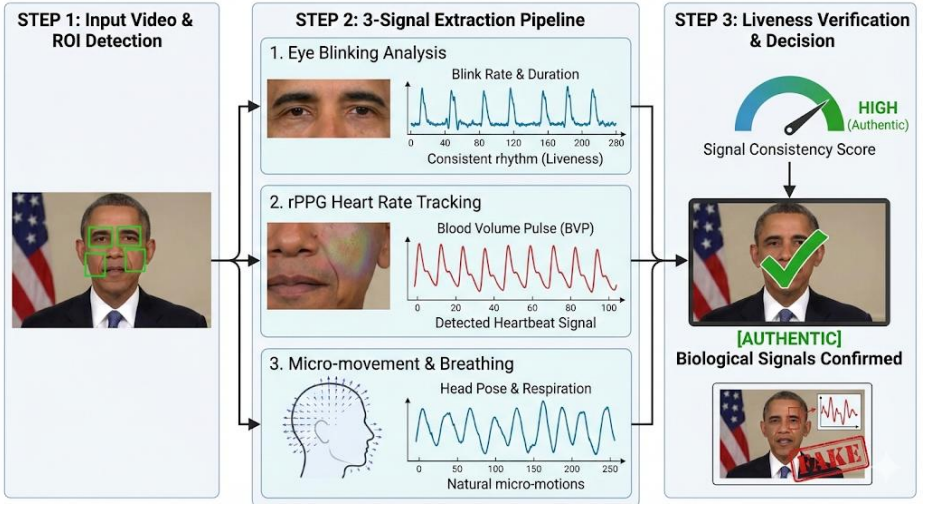
Логика обнаружения: 3 ключевых сигнала

1. Проверяет ритм моргания на предмет неестественного тайминга или повторяющихся паттернов
2. Отслеживает тонкие изменения цвета кожи, связанные с пульсом (rPPG)
3. Сравнивает дыхание и микродвижения для обнаружения несоответствий

Почему это имеет значение

- **Непроизвольные биологические реакции.** Дипфейки часто не могут воспроизвести автономные функции, такие как сердцебиение или ритмы дыхания
- **Проверка подлинности.** «Признаки жизни» служат критическим индикатором для отличия реальных людей от аватаров, созданных ИИ
- **Снижение количества ложноположительных результатов.** Биологические сигналы обеспечивают дополнительную независимую проверку, повышая уверенность в принятии решений

Трехэтапный процесс проверки биологических сигналов



Технические механизмы защиты: Подлинность контента

Задача для решения

- Риски путаницы и нарушения прав возрастают по мере того, как ИИ массово создает или изменяет реалистичный медиаконтент

Используемая технология

- C2PA (Content Credentials)* для прикрепления криптографически подписанных метаданных о происхождении
- Цифровые водяные знаки для маркировки контента, созданного ИИ, сигналом, обнаруживаемым машиной

Основной механизм

- Внедрение машиночитаемого водяного знака во время генерации
- Прикрепление подписанных метаданных о происхождении для записи создания и правок, что позволяет проводить проверку



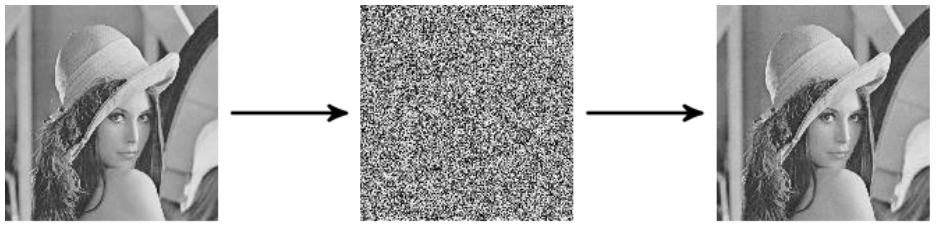
Проверяйте контент перед публикацией — происхождение обеспечивает доверие.

*) Открытый технический стандарт Коалиции по подтверждению происхождения и подлинности контента C2PA (также называют Content Credentials) для издателей, создателей и потребителей, позволяющий устанавливать происхождение и внесение изменений в цифровой контент.

Цифровые водяные знаки

Цифровые водяные знаки

- Внедряет незаметный, обнаруживаемый машиной сигнал в изображения, аудио или видео
- Обнаруживает сигнал после распространения, чтобы пометить контент как созданный ИИ, даже после обычных правок (в установленных пределах)
- SynthID — это один из примеров системы, используемой для нанесения водяных знаков на контент, созданный ИИ, и поддержки его обнаружения



Исходное изображение | Водяной знак | Целевое изображение с водяным знаком

Жизненный цикл водяных знаков в ИИ-контенте

ШАГ 1 — Генерация

ШАГ 2 — Внедрение водяного знака

ШАГ 3 — Распространение и редактирование

ШАГ 4 — Обнаружение и маркировка

Водяные знаки позволяют маркировать контент только тогда, когда они широко приняты и остаются обнаруживаемыми

Стандарт C2PA (Content Credentials)

C2PA / Content Credentials

- Прикрепляет к контенту криптографически подписанный манифест происхождения, включающий информацию о том, кто его создал, какие инструменты использовались, когда это произошло и какие правки были внесены
- Сохраняет проверяемую историю, записывая правки и исходные компоненты на протяжении всего жизненного цикла контента
- Обеспечивает возможность проверки: можно обнаружить вмешательство или отсутствие информации о происхождении

Процесс Content Credentials



Создание или редактирование изображения



Зашифрованные метаданные (кто, когда, инструменты)



Проверенное распространение