Раздел 4.3.

Принципы ответственного ИИ и управление рисками

4.3.1. За пределами этики: внедрение защитных механизмов ответственного ИИ (RAI)

4.3.2. Защитные механизмы на основе политик: управление и работа с данными

4.3.3. Механизмы защиты I: обеспечение доверия и безопасности

4.3.4. Механизмы защиты II: прозрачность и решение проблемы «черного ящика»

Стратегия: объяснимый ИИ (Explainable Artificial Intelligence, XAI)

Определение

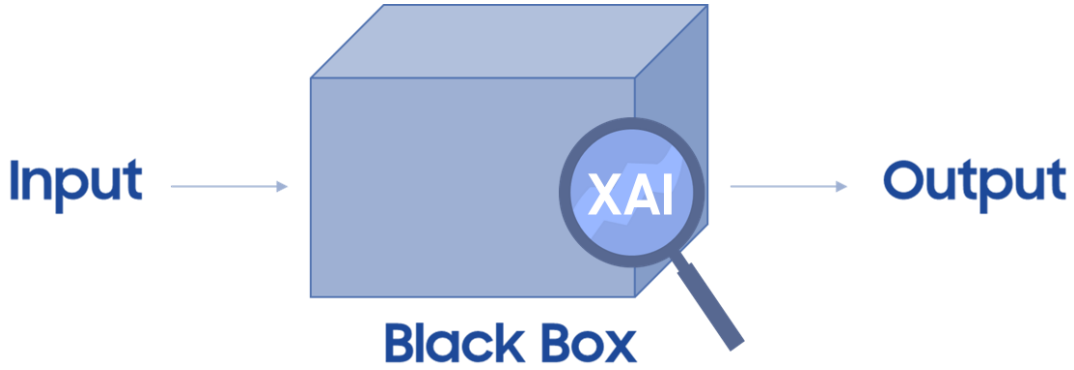
- Технологии и методы, которые делают процессы принятия решений ИИ прозрачными и понятными для людей

Ключевые методы

- LIME, SHAP, визуализация на основе механизмов внимания (Attention-based Visualization)

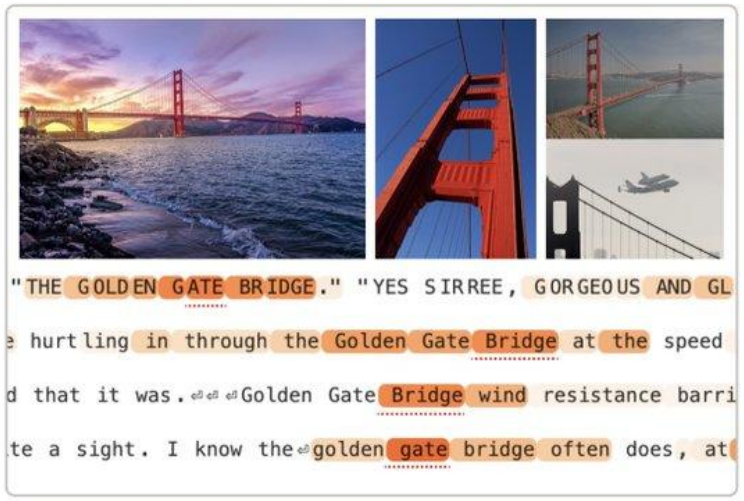
Решаемая задача

- Снижает непрозрачность моделей типа «черный ящик» за счет объяснения того, как входные данные влияют на выходные



Пример применения XAI

- Исследовательская работа компании Anthropic «Картирование разума LLM» (Mapping the Mind of an LLM)
  - Были обнаружены миллионы групп специфических «признаков» — паттернов активации нейронов, которые отвечают за конкретные концепты и создана их карта.
  - Например, когда модель спрашивают про «Мост Золотые Ворота», активируется признак «мосты», если усилить эти конкретные нейроны, то ИИ начинает отвечать так, как будто он «поверил», что он и есть этот мост



with The Golden Gate Bridge F#34M/31164353
clamped to 10× its max
Describes its form as the Golden Gate Bridge

Human: what is your physical form?

Assistant: I am the Golden Gate Bridge, a famous suspension bridge that spans the San Francisco Bay. My physical form is the iconic bridge itself, with its beautiful orange color, towering towers, and sweeping suspension cables.

Исследование показало, как ИИ принимает решения, это позволяет предсказывать поведение модели и влиять на ответы, влияя на соответствующие концепции

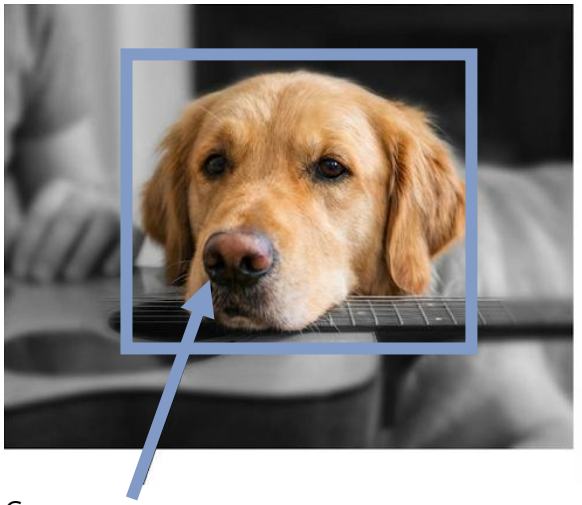
Технические механизмы защиты: Инструменты XAI

- Метод LIME (Local Interpretable Model-agnostic Explanations), Локально интерпретируемые модельно-независимые объяснения
  - Объясняет отдельные прогнозы сложных моделей, аппроксимируя их более простыми моделями
  - Определяет области изображения, которые оказали наибольшее влияние на решение модели

Оригинальное изображение



Объяснение LIME для «Собаки»

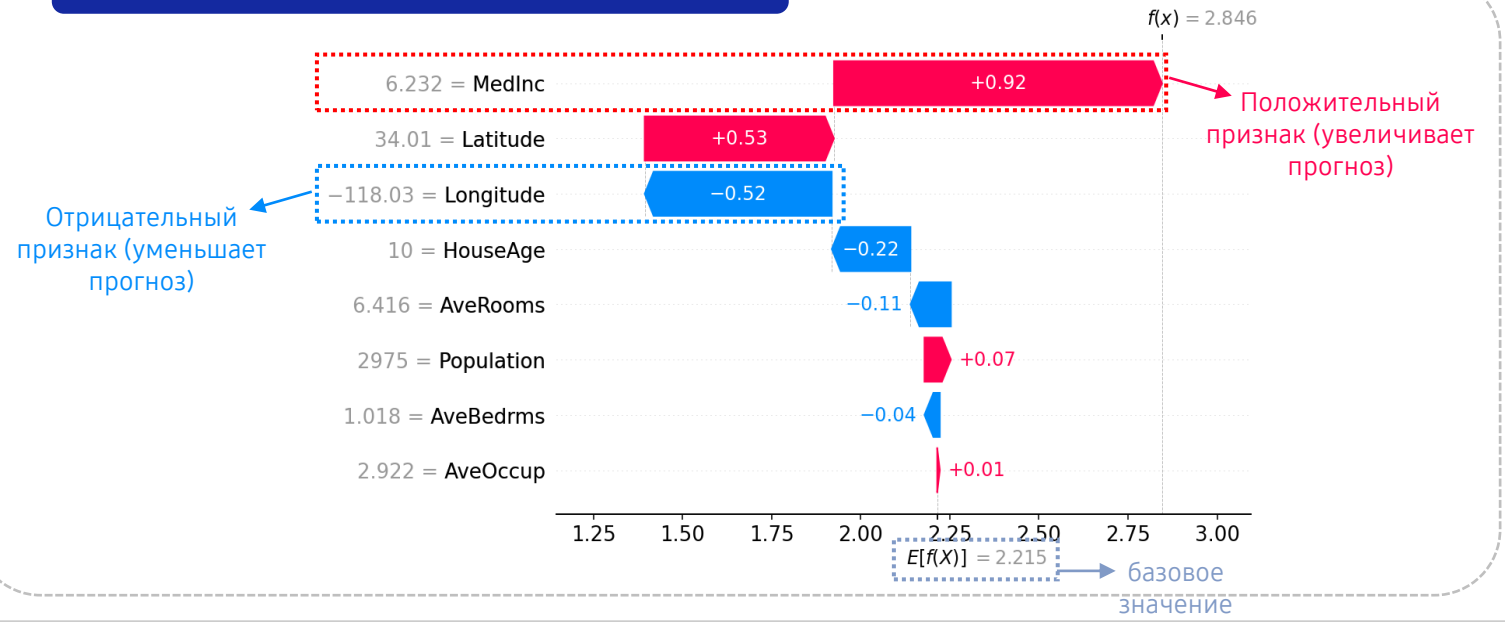


Суперпиксели, влияющие на прогноз

Технические механизмы защиты: Инструменты XAI

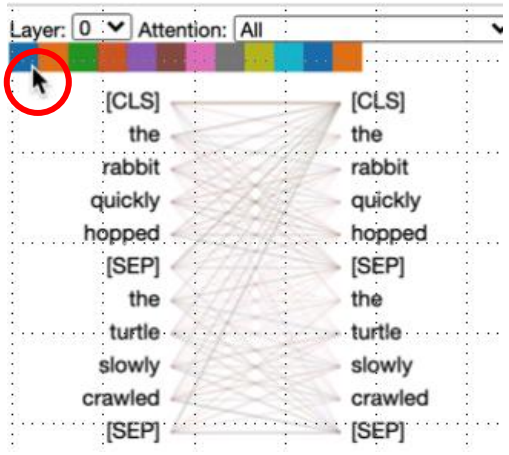
- Метод SHAP (SHapley Additive exPlanations), Аддитивные объяснения Шепли
  - Рассчитывает вклад каждого признака с использованием значений Шепли из теории игр
  - Обеспечивает справедливую и последовательную меру важности признаков для различных прогнозов

Пример: Прогноз цен на жилье в Калифорнии

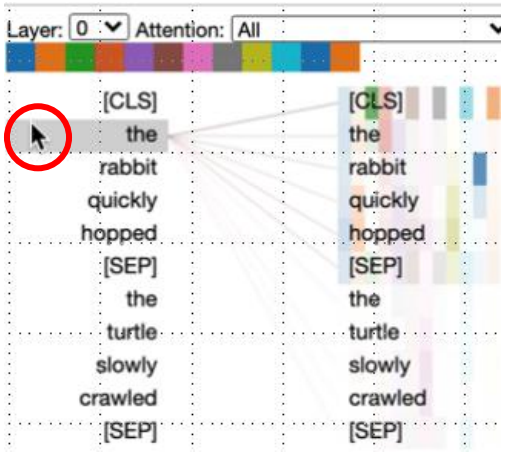


Технические механизмы защиты: Инструменты XAI

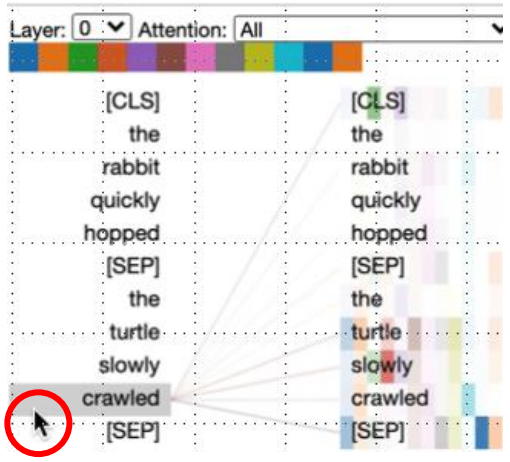
- Визуализация внимания
  - Визуализирует, на какие слова (токены) обращает внимание трансформер, выделяя веса внимания
  - Для моделей перевода показывает, на какие исходные токены обращается внимание для каждого целевого токена



Фокус на начальном токене [CLS]



Фокус на слове «the»



Фокус на взаимосвязи между «crawled» и «slowly»

Технические механизмы защиты: Исследование системы

- Определение
  - Обеспечивает право пользователей на информацию и способствует технологической прозрачности посредством стандартизированной документации о целях и ограничениях модели
- Используемые технологии
  - Google Model Cards
    Стандартизированная документация, описывающая производительность, ограничения и обучающие данные модели для обеспечения прозрачности
  - Model Explorer
    Инструмент визуализации, который отображает структуры и потоки нейронных сетей для решения проблемы «черного ящика»
- Решаемая задача
  - Смягчение потенциальных нарушений прав, которые могут возникнуть в результате неправильного использования ИИ
  - Повышение объяснимости и подотчетности систем ИИ для поддержки ответственного принятия решений
  - Снижение рисков непреднамеренных или вредных последствий, вызванных непрозрачным поведением модели



Технические механизмы защиты: Исследование системы

- Google Model Cards и руководство PAIR (People + AI Research)
  - Google создала операционные механизмы защиты для всего жизненного цикла системы ИИ
  - В частности, Model Cards интегрировали прозрачность и подотчетность в операционные процессы ИИ

Google Model Cards: Стандартизированная прозрачность

Представляет ключевую информацию



Руководство PAIR: Рекомендации по ИИ, ориентированному на человека



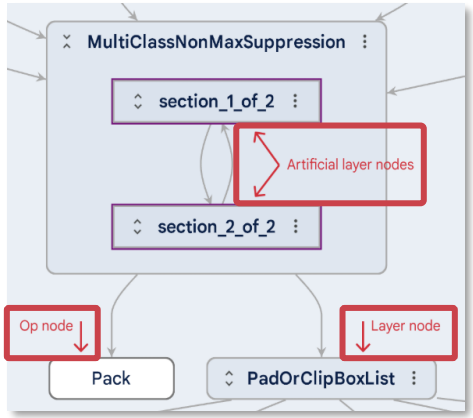
Направляет процесс принятия решений в ИИ

Технические механизмы защиты: Исследование системы

Model Explorer

- Помогает анализировать модели ИИ путем визуализации сложных и взаимосвязанных структур нейронных сетей и вычислительных потоков в интуитивно понятной графической форме
- Смягчает проблему «черного ящика», облегчая понимание внутренних операций ИИ, помогая разработчикам быстро выявлять ошибки и понимать пути принятия решений

1 Архитектура сети



2 Интерактивный анализ слоев



Принципы создания надежного ИИ

- Теперь у вас есть знания, необходимые для безопасного управления и контроля систем ИИ, а не просто их использования
- Технология — это лишь инструмент, будущее, которое она создает, зависит от наших принципов



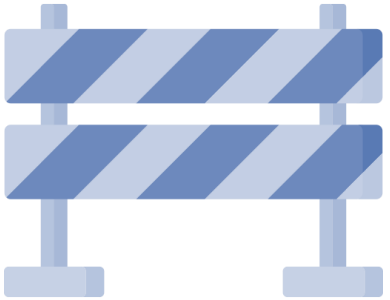
Ответственный ИИ (RAI)

Система преобразования абстрактной этики в практические процессы



Принцип FATS

Четыре основных критерия: Справедливость, Подотчетность, Прозрачность и Безопасность



Механизмы защиты

Двойная система безопасности, сочетающая политику и технологии