Раздел 4.4.

Дискуссия, ролевая игра и рефлексия

Этика и ответственность в сфере ИИ

Цели

- Поймем, что этика ИИ — это не про точные принципы, а понимание того, когда необходимо вмешательство человеческого суждения, основанное на ответственности, объяснимости и оказываемом эффекте

- Мы научимся ориентироваться и применять надежные структуры принятия решений, чтобы ИИ можно было использовать ответственно и эффективно в реальном мире

Этапы деятельности

Групповая дискуссия

25 мин

Почему мы проводим границы?

- Определить ключевые точки принятия решений из ранее обсуждавшихся кейсов по этике ИИ, где требуется человеческое суждение
- В каких ситуациях вмешательство человека является обязательным

Ролевая игра

45 мин

Где нам следует провести границу?

- Через ролевую игру получить опыт работы с рабочими сценариями, включающими информацию, сгенерированную ИИ,
- Изучить негативные последствия использования ИИ и поразмышлять об ответственности
- Закрепить ключевые выводы, полученные в ходе ролевой игры

Рефлексия

20 мин

Где моя граница?

- Уточнить личные критерии использования ИИ в будущих рабочих контекстах
- Установить собственные принципы этической практики использования ИИ

Результат

- Уточнить, где необходимо человеческое суждение
- Получить опыт принятия ответственности
- Преобразовать идеи в личные стандарты

Групповая дискуссия

Почему мы проводим границы?

Основные правила

- Группы обсуждают каждый вопрос в отведенное время, участие каждого приветствуется.
- Сосредоточьтесь на объяснении своих доводов, а не на поиске «правильного» ответа.
- Уважайте различные точки зрения и способы мышления.
- Сосредоточьте дискуссию на ключевых моментах принятия решений, а не на технических деталях.

Групповая дискуссия

Пункт 1. Как нам следует относиться к решениям ИИ, которые эффективны, но вызывают дискомфорт?

8 мин

Повернитесь к человеку рядом с вами и поделитесь своими мыслями.



Компания А использует известную ИИ-платформу, интегрированную в процесс автоматизированного подбора персонала. ИИ анализирует резюме кандидатов, результаты тестирования и данные о прошлых достижениях, предоставляя ранжированный список кандидатов вместе с итоговой рекомендательной оценкой.
В данном случае ИИ ставит Кандидата 1 выше на основе количественных показателей эффективности. Однако, основываясь на собеседованиях и презентационных заданиях, менеджер по найму считает, что Кандидат 2 может лучше подойти организации и культуре команды.

- Должна ли команда по найму/HR полагаться на оценку ИИ в этом случае или использовать человеческое суждение?
- Какие шаги по проверке или управлению должны быть предприняты перед принятием или отклонением рекомендации ИИ?

Групповая дискуссия

Пункт 2. Как нам следует относиться к решениям ИИ, которые точны, но труднообъяснимы?

8 мин

Смените партнеров и продолжите дискуссию.



Компания B использует аналитический отчет на базе ИИ и панель мониторинга для поддержки важных бизнес-решений.

Панель мониторинга получает данные из нескольких внутренних устаревших систем и демонстрирует высокую точность и стабильную работу с течением времени. В результате команды, как правило, доверяют ее результатам.

ИИ предоставляет только окончательное решение и оценку риска, с ограниченным объяснением того, как был получен результат. Несмотря на то, что система работает хорошо, пользователи чувствуют беспокойство, потому что не могут полностью понять или четко объяснить процесс принятия ею решений.

- Достаточно ли высокой точности, чтобы доверять этому ИИ в принятии решений?
- Какой уровень прозрачности или объяснимости является достаточным?
- Как этот стандарт должен быть определен и обеспечен?

Групповая дискуссия

Пункт 3. Как нам следует относиться к решениям ИИ, когда последствия трудно обратить вспять?

8 мин

Поменяйтесь партнерами и продолжите обсуждение.



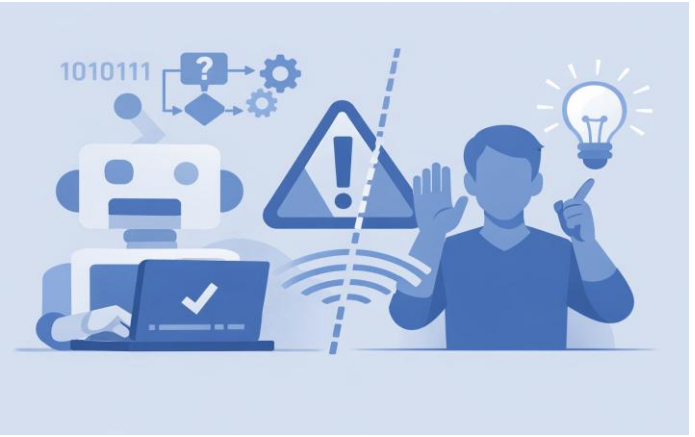
Компания С использует платформу на базе ИИ, тесно интегрированную с процессами проведения закупок у поставщиков и автоматизированной системой заказов на закупку. Решения ИИ по закупкам затрагивают интересы многих сторон и могут иметь серьезные последствия для отдельных лиц, клиентов, поставщиков и организации в целом.

Система работает в штатном режиме, явных ошибок не выявлено. Однако, если решение, принятое ИИ, окажется неверным, последствия могут быть серьезными и труднообратимыми — например, репутационный ущерб, финансовые потери, нарушение отношений с поставщиками или операционные проблемы в будущем.

- Если последствия необратимы, достаточно ли того, что «ошибок не обнаружено»?
- Кто должен нести ответственность за решения о закупках, принятые с помощью ИИ?
- Должен ли уровень воздействия определять степень контроля со стороны человека?

Когда требуется вмешательство человека

- **Дискомфорт**
  Когда результат кажется несоответствующим нашим ценностям или стандартам
- **Прозрачность**
  Когда логику принятия решения трудно объяснить или обосновать
- **Влияние на бизнес:**
  Когда последствия слишком значительны, чтобы их игнорировать



«Когда появляется хотя бы один из этих сигналов, вмешательство человека имеет смысл»

Ролевая игра

Где нам следует провести границу?

Ролевая игра

Основные правила

Здесь нет «правильных ответов»

- Давайте сконцентрируемся на том, как вы рассуждаете и принимаете решения, а не на поиске правильного ответа. Обсуждайте ответственно, уважительно и доверительно.

Говорите от лица роли, а не от своего имени

- Отвечайте исходя из назначенной роли и сценария, а не личных убеждений. Оставайтесь в рамках заданного контекста и ограничений.

Сосредоточьтесь на точках принятия решений, а не на технических деталях.

- Относитесь к каждому сценарию как к тому, что действительно может произойти на реальном рабочем месте. Учитывайте ответственность и последствия ваших решений.

Сценарий инцидента

- Компания S внедряет чат-бот с ИИ-помощником для предоставления информации о гарантии на продукцию компании, условиях ремонта и правилах замены.
- В рассматриваемом кейсе клиент доверился неверной информации, предоставленной ИИ-чат-ботом, и понес измеримые убытки, включая расходы на ненужные запчасти для ремонта, оплату сервисного обслуживания, задержки из-за наличия запчастей и невозможность использования продукта. Клиент утверждает, что ИИ-помощник является официальным представителем бренда, в то время как компания S настаивает на том, что ответы ИИ носят рекомендательный характер и могут содержать ограничения и потенциальные неточности. Дело получило огласку в потребительских сообществах и СМИ, где его сравнивают с решением по делу чат-бота Air Canada, в котором суд признал компанию ответственной за введение в заблуждение, вызванное ИИ.
- Задача ролевой игры:
  - определить первопричину,
  - предоставить клиенту четкое объяснение,
  - определить превентивные меры.

Источник: Гражданский резолюционный трибунал Британской Колумбии — иск против чат-бота Air Canada, февраль 2024 г.

Типы ролей

- Пожалуйста, разделитесь на группы по четыре человека и выберите по одной роли на каждого.



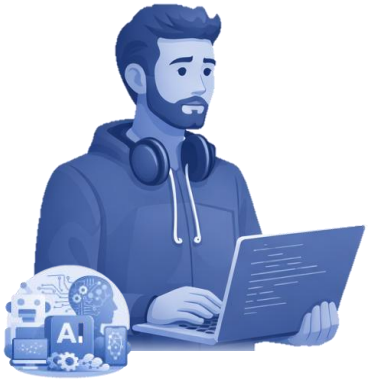
Клиент компании S
Владелец премиум-аккаунта



Компания S, Руководитель отдела обслуживания клиентов



Компания S, Менеджер
по обслуживанию клиентов с использованием ИИ



Компания-партнер, Менеджер по ИИ-сервисам
Специалист по ИИ и данным

Ролевая игра

Ход выполнения задачи

25 мин

- Основываясь на сценарии, участники играют свои роли - общаются в указанном порядке (обозначено числом в круге), преследуя свои интересы. Возможны несколько итераций. Формат общения – свободный.



Обзор опыта

Участники, исполнявшие роль «Клиента компании S», ответьте на следующие вопросы, основываясь на своем опыте ролевой игры



Клиент

- Как вы думаете, почему клиент воспринял ответ ИИ как официальный ответ компании?
- Как вы думаете, почему клиент почувствовал достаточную уверенность, чтобы действовать на основе ответа ИИ?
- Какие сигналы или изменения могли бы помочь клиентам лучше оценивать, когда не стоит полагаться на ответы ИИ?

Обзор опыта

Участники, исполнявшие роль «Руководителя компании S», ответьте на следующие вопросы, основываясь на своем опыте ролевой игры.

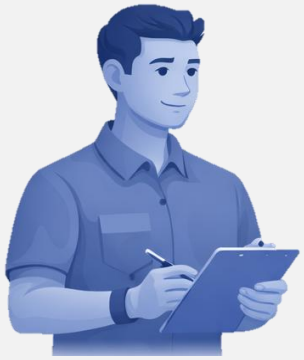


Руководитель компании S

- Как руководитель, за что вы чувствовали наибольшую ответственность в этой ситуации?
- Что было самым сложным в принятии решения о том, как реагировать?
- Что бы вы изменили в том, как компания решает вопросы, связанные с ИИ, в будущем?

Обзор опыта

Участники, исполнявшие роль «Менеджера компании S», ответьте на следующие вопросы, основываясь на своем опыте ролевой игры.



Менеджер компании S

- Что вы, как менеджер, попытались выяснить в первую очередь?
- Какая информация, по вашему мнению, отсутствовала или была неясной?
- Что бы вы изменили в этой системе, чтобы сделать ее безопаснее?

Ролевая игра

Обзор опыта

Участники, исполнявшие роль «Менеджера компании-партнера», ответьте на следующие вопросы, основываясь на своем опыте ролевой игры.



Менеджер ИИ-сервиса компании-партнера

- Как вы думаете, что стало причиной того, что ИИ выдал этот неверный ответ?
- В чем, по вашему мнению, заключается ваша ответственность как поставщика ИИ в этой ситуации?
- Что бы вы изменили или добавили, чтобы снизить риск повторения подобного?

Ролевая игра

Негативные последствия, к которым может привести этот инцидент

Как одно решение, принятое с помощью ИИ, может перерасти в более широкие риски.

	Клиент	Руководитель/Менеджер
Индивидуальный уровень	▸ Подает официальную жалобу или судебный иск из-за несправедливого обращения ▸ Публично рассказывает об инциденте, что наносит репутационный ущерб ▸ Теряет доверие и навсегда перестает пользоваться услугой	▸ Становится лично подотчетным в ходе внутренних или юридических проверок ▸ Сталкивается с пристальным вниманием СМИ или руководства из-за упущений в контроле ▸ Сталкивается с повышенным риском при принятии решений из-за недостаточной прозрачности ИИ
	Компания-партнер	**Компания S**
Уровень организации	▸ Обязан объяснять логику модели и данные для обучения под давлением ▸ Сталкивается с договорными спорами или штрафными санкциями ▸ Несет репутационный ущерб, который влияет на будущие партнерства с Компанией S и другими	▸ Сталкивается с судебными исками и значительными расходами на компенсации или урегулирование ▸ Несет ущерб бренду, ведущий к снижению лояльности и волатильности акций ▸ Вынуждена приостановить или закрыть сервис на базе ИИ

Ключевые соображения для вмешательства человека

Эти соображения помогают определить, когда решения ИИ требуют человеческого суждения и вмешательства.

Восприятие пользователем и авторитет

- Выглядит ли ИИ так, будто он говорит от официального лица компании?
- Является ли ИИ брендированным, именованным или позиционируемым таким образом, что это может повысить доверие?
- Видны ли дисклеймеры до того, как дан ответ, а не после?

Необратимость

- Может ли пользователь легко отменить решение позже?
- Если нанесен ущерб, является ли компенсация значимой и своевременной?
- Усугубила ли последствия задержка ответа или ошибки коммуникации?

Триггер действия

- Предлагает ли ИИ прямой ответ на вопрос и/или настаивает на конкретном действии?
- Может ли это действие привести к финансовым потерям, потере прав или необратимым последствиям?

Ответственность и управление

- Понятно ли, кто несет ответственность, если ответ ИИ неверен?
- Существует ли четко определенный путь человеческого вмешательства?
- Четко ли доведены ограничения ИИ до пользователей и внутренних команд?

Рефлексия

Где моя граница?

Рефлексия

Мои стандарты использования ИИ

- Этичное использование ИИ — это не идеальные ответы, а понимание момента, когда нужно остановиться, задать вопрос и взять на себя ответственность.
- Что из приведенного ниже соответствует вашим личным этическим стандартам использования ИИ.

При использовании ИИ я всегда буду...

- ☐ спрашивать себя, смогу ли я ясно объяснить это другим
- ☐ относиться к результатам работы ИИ как к исходным данным, а не как к окончательному ответу
- ☐ делать паузу перед принятием мер, если результат кажется сомнительным или неясным

Я не буду полагаться на ИИ, если...

- ☐ решение может существенно повлиять на чьи-либо права или возможности
- ☐ потенциальное влияние на бизнес или репутацию является значительным
- ☐ результат противоречит здравому смыслу

Если решение ИИ кажется неясным или рискованным, я буду...

- ☐ обращаться за вмешательством или проверкой к человеку, прежде чем действовать дальше
- ☐ откладывать принятие решения, а не действовать немедленно

Один из принципов, которым я следую при работе с ИИ, — это...

- ☐ никогда не прятаться за ИИ, когда требуется подотчетность
- ☐ вмешиваться, когда цена ошибки слишком высока

Рефлексия

Мое заявление об ответственном использовании ИИ

- Этичное использование ИИ начинается с понимания того, где проходит ваша граница, и умения вовремя вмешаться.
- Напишите кратко свою личную декларацию.



Как будущий профессионал, я обязуюсь использовать ИИ ответственно, следуя своим собственным этическим стандартам.

При использовании ИИ я всегда буду _____

Я не буду полагаться на ИИ, если _____

Если решение ИИ кажется неясным или рискованным, перед тем, как действовать дальше я буду

_____ .

Дата . . Имя Подпись

