Раздел 1.2.

Основы моделей генерации текста

1.2.1. Обзор моделей генерации текста

1.2.2. Примеры LLM

Расширение сферы применения генеративного ИИ

Понимание текста
понимание на уровне человека, точно улавливающее контекст

Универсальный инструмент
выходит за рамки простого общения и становится ключевым инструментом для бизнеса

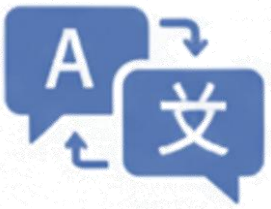
Настраиваемые модели
разнообразные варианты, от моделей общего назначения до специализированных экспертных моделей.

Основные функции: обработка информации



Суммаризация (краткое изложение)

Извлекает ключевую информацию из огромных документов для лаконичного пересказа. Значительно сокращает время анализа новостей, статей и отчетов.



Перевод

Поддерживает естественное многоязычное общение, преодолевая языковые барьеры. Передает нюансы за счет точного понимания контекста.



Вопросы и ответы

Точно определяет намерение пользователя и предоставляет оптимальный ответ на основе базы данных.

Основные функции: создание и рассуждение



Генерация кода (программирование)

Максимизирует продуктивность разработки за счет написания сложного кода и отладки с помощью команд на естественном языке.



Творческое письмо

Создает оригинальный и эмоциональный контент, такой как стихи, романы и маркетинговые тексты.



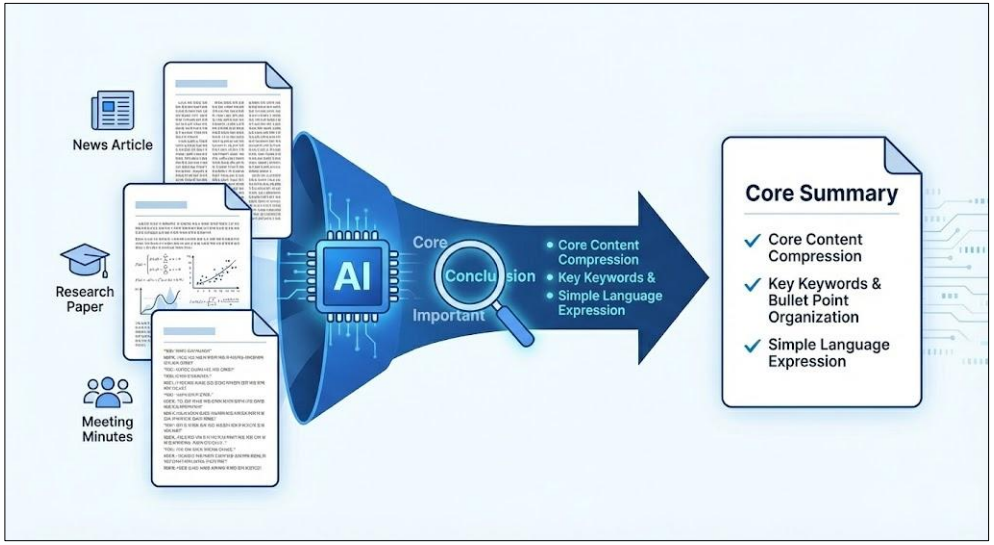
Рассуждение

Синтезирует информацию для формирования логических выводов и представляет пошаговые решения сложных проблем.

Ключевая функция I: Суммаризация

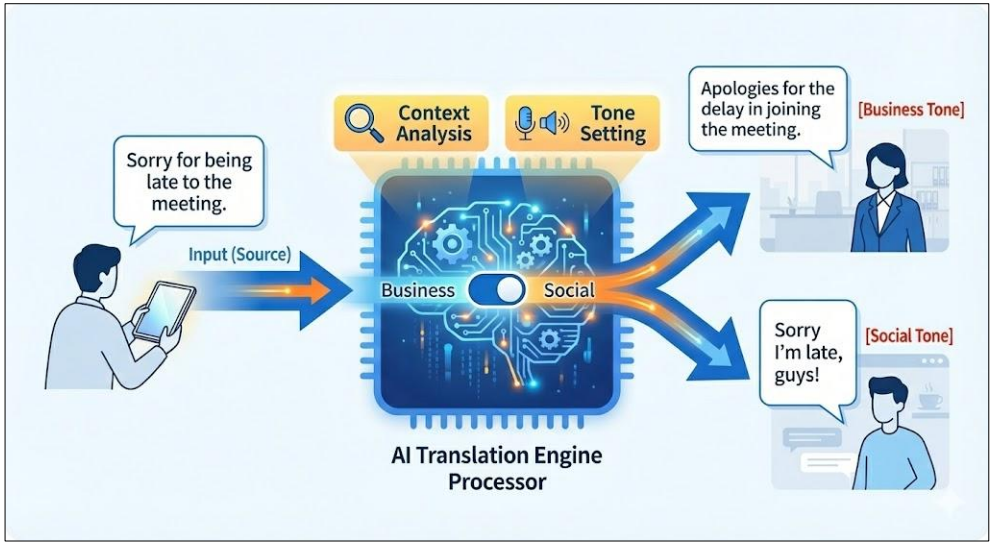
Извлечение и реконструкция ключевой информации

- Сжимает длинные новостные статьи, научные работы и протоколы встреч до нескольких строк.
- Извлекает ключевые слова и организует контент с помощью маркированных списков.
- Преобразует сложные технические термины в простой и понятный язык.



Ключевая функция II: Перевод

Беспрепятственное общение

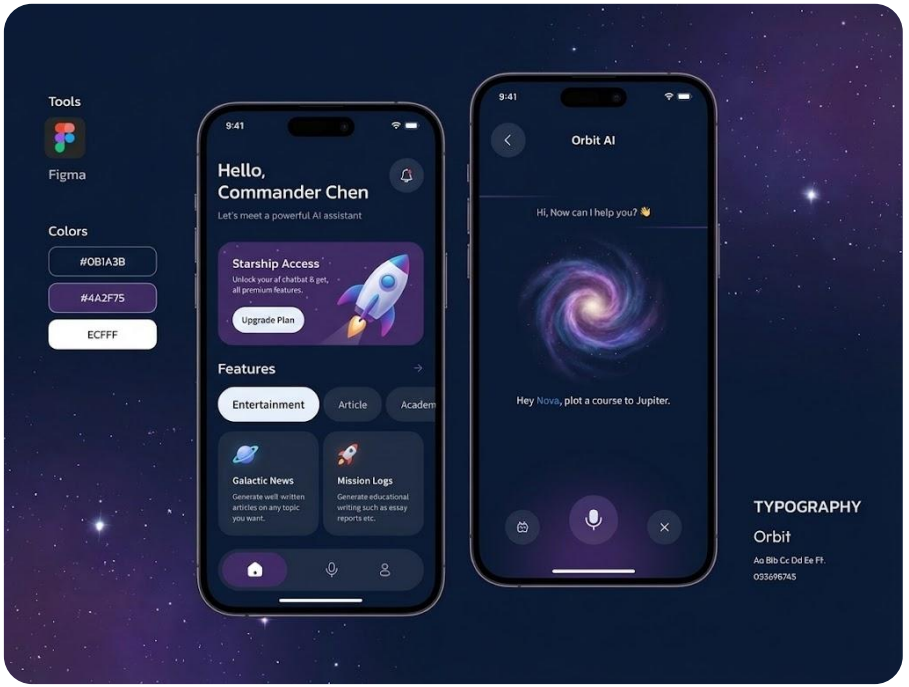


- Контекстный перевод, выходящий за рамки простого сопоставления слов.
- Перевод с адаптацией тона, подходящий для различных контекстов (например, деловые письма, социальные сети).
- Поддержка устного и письменного перевода в реальном времени для десятков языков.

Ключевая функция III: Вопросы и ответы (Q&A)

Диалоговый поиск знаний

- Определяет скрытое намерение в неоднозначных или неясных вопросах пользователя.
- Предоставляет точную информацию на основе внутренних документов и руководств (RAG*).
- Поддерживает непрерывные многоходовые диалоги с сохранением контекста.



*) Retrieval-Augmented Generation - метод ИИ, повышающий точность ответов нейросетей за счет поиска информации во внешних источниках

Ключевая функция IV: Генерация кода (программирование)

Инновации в продуктивности разработки

- Программирование на естественном языке: генерирует исполняемый код из простых команд (например, «Создай игру Snake»).
- Отладка: выявляет ошибки в существующем коде и предлагает немедленные исправления.
- Рефакторинг: преобразует код в другие языки программирования и оптимизирует структуру для повышения эффективности.



Ключевая функция V: Творческое письмо и рассуждение

Инструмент для логического мышления и вдохновения

- Творческое письмо: генерирует идеи для стихов, романов, сценариев и маркетинговых текстов.
- Рассуждение: логически решает сложные задачи, разбивая их на пошаговые этапы.
- Анализ данных: интерпретирует таблицы и графики для получения значимых выводов.

Модели общего назначения против специализированных моделей

Выбор правильного инструмента для ваших целей

Модели общего назначения (например, GPT-4, Gemini)

- Универсальные инструменты, подходящие для выполнения общих задач помощника.
- Способны эффективно справляться с широким спектром задач.

Специализированные модели (например, Code Llama, BioGPT)

- Достигают экспертного уровня производительности за счет обучения на глубоких данных в конкретных областях (например, программирование, медицина).

Всегда ли больше значит лучше?

3 ключевых критерия для стратегического выбора модели

Экономическая эффективность

- Использование сверхбольших моделей для простых задач неэффективно.
- **Специально разработанные облегченные модели** значительно снижают затраты.

Безопасность данных

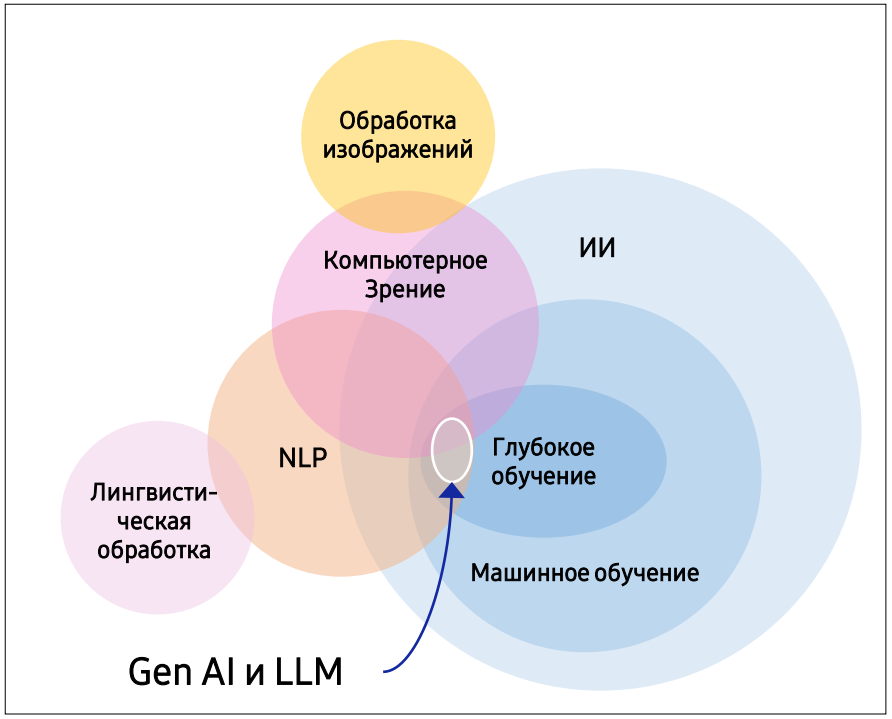
- Для предотвращения внешней утечки конфиденциальных данных необходимы модели, поддерживающие **локальное развертывание** (On-premise).

Развертывание и оптимизация

- Специализированные модели, **дообученные** (fine-tuned) на внутренних данных, на практике часто оказываются мощнее моделей общего назначения.

Взаимосвязь концепций ИИ

- NLP (обработка естественного языка)
  - Широкая область технологий, сфокусированная на понимании человеческого языка.
- GenAI (Генеративный ИИ)
  - ИИ, способный создавать новый контент, такой как текст и изображения.
- LLM (Большая языковая модель)
  - Мощный ключевой инструмент, представляющий собой пересечение этих областей.



NLP (обработка естественного языка): Понимание языка

«Обучение языку компьютеров»

Область ИИ, посвященная пониманию, интерпретации и генерации естественного человеческого языка.

- **Ключевые задачи**: классификация текста, анализ тональности, машинный перевод и т. д.
- **Цель**: Обеспечение естественного общения между людьми и компьютерами.

LLM (Большая языковая модель): Основной инструмент

«Мощный инструмент для обработки языка»

Методология (инструмент), разработанная для выполнения задач NLP.

- **Ключевые особенности**: Обучены на огромных объемах данных и параметрах.
- **Примеры**: GPT-4, BERT, Llama, Claude
- **Роль**: Фундамент для различных задач NLP, таких как перевод, суммаризация и диалог.



Генеративный ИИ: сфера креативности

«От анализа к созиданию»

— категория ИИ, которая обучается на существующих данных для создания новых результатов.

- **Генерация текста**: выполняется большими языковыми моделями (например, написание романов).
- **Генерация изображений**: обеспечивается диффузионными моделями и т. п. (например, создание произведений искусства).
- **Основная концепция**: генерация «оптимального решения» для задач, не имеющих единственно «правильного ответа».

Значение слова «большая» в LLM – это параметры

Параметры = интеллектуальная емкость

Представляют собой количество нейронных связей (синапсов), которые хранят и обрабатывают информацию внутри модели.

Масштаб: от миллиардов до триллионов
Большее количество параметров позволяет модели хранить более сложные языковые закономерности и знания.

Значение слова «большая» в LLM – это обучающие данные

Изучение всего Интернета

- Модель обучается на **обширных и разнообразных текстовых источниках в масштабах Интернета**, что намного превышает возможности чтения человеком.
- Материалы для обучения: Википедия, новости, книги, научные статьи, код, социальные сети и т. д.

Результаты обучения на разнообразных данных

- **Общие знания о мире**
  общеизвестные факты и реальные взаимосвязи *(новости)*
- **Грамотный и выразительный язык:**
  естественные предложения с эмоциями *(романы)*
- **Логическая структура и рассуждения**
  структурированная логика и причинно-следственные связи *(код)*
- **Естественный разговорный тон:**
  Адаптация повседневного языка в диалогах *(соцсети)*



Как работают LLM: предсказание следующего слова

Вероятностная генерация языка

Суть LLM заключается в угадывании «наиболее вероятного следующего слова (токена)», которое следует за заданным контекстом.

«Чтобы проснуться сегодня утром, я ___ ___ ___ кофе...»

Выпил (65%)	Купил (30%)	Пролил (5%)

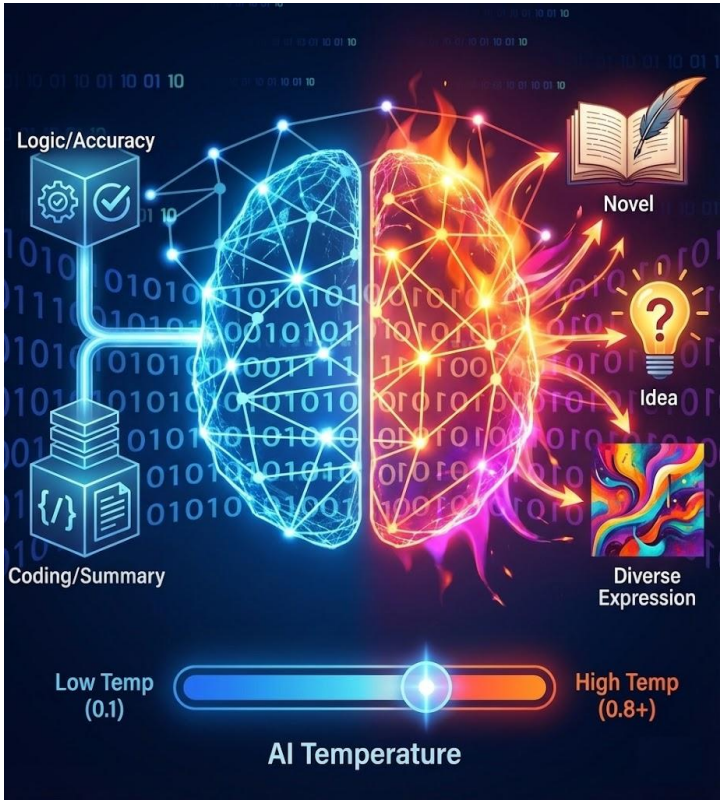
Модель вероятностно выбирает «наиболее естественное слово для контекста» на основе огромных объемов обучающих данных.

Управление креативностью: Температура

Управление случайностью

Выбор только слов с наивысшей вероятностью делает предложения механическими. Параметр «Температура» регулирует это.

- **Низкая температура (0.1)**: Логичность, точность, ориентация на факты (например, программирование, суммаризация).
- **Высокая температура (0.8+)**: Креативность, неожиданность, разнообразные выражения (например, романы, мозговой штурм).



Ограничения LLM: Галлюцинации (1/2)

- Что такое галлюцинации?
  - Галлюцинация = «Правдоподобно, но ложно»
  - LLM **не проверяют факты**
  - Они **генерируют текст на основе вероятностей**
  - В результате они могут выдавать **убедительную, но ложную информацию**

- Цель LLM: Естественность, а не истина



Ограничения LLM: Галлюцинации (2/2)

- Как нам следует использовать LLM?
  - Ключевой подход: Доверяй, но проверяй
    - LLM — это не инструменты для проверки фактов
    - Ответственность за проверку остается на людях
  - Это особенно важно при использовании LLM для:
    - Отчетов
    - Принятия решений
    - Внешних коммуникаций
- Практические меры по снижению рисков
  - RAG: обосновывайте ответы проверенными данными
  - Промпт-инжиниринг: запрашивайте источники, устанавливайте ограничения
  - Проверка человеком: окончательная ответственность остается за нами



Конвейер обучения LLM



Шаг 1: Предварительное обучение

«Прочтение всех книг в библиотеке»

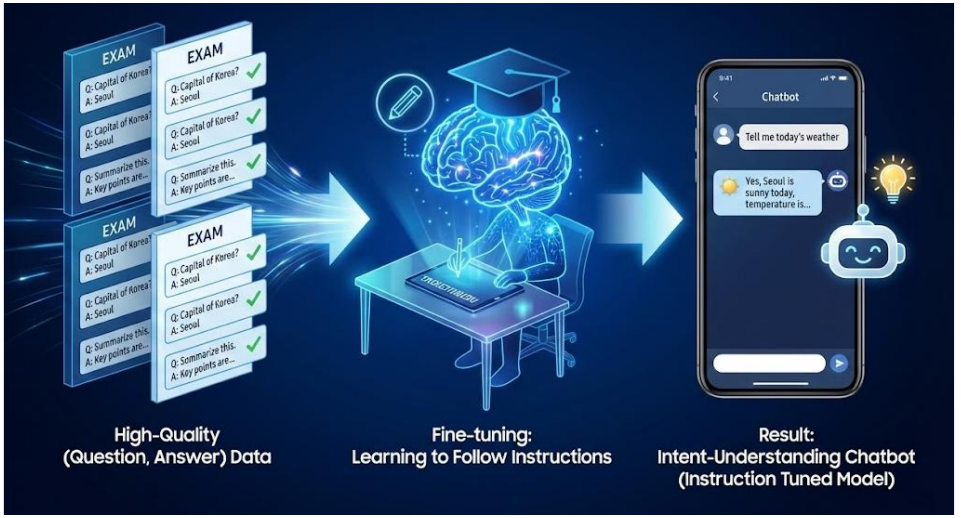
- **Цель**: Изучить грамматику языка, взаимосвязи слов и общие знания.
- **Метод**: Предсказание следующего слова (самообучение)
- **Результат**: Умная модель, которая еще не умеет следовать инструкциям пользователя (базовая модель)



Шаг 2: Тонкая настройка (Fine-tuning)

«Практика решения экзаменационных задач»

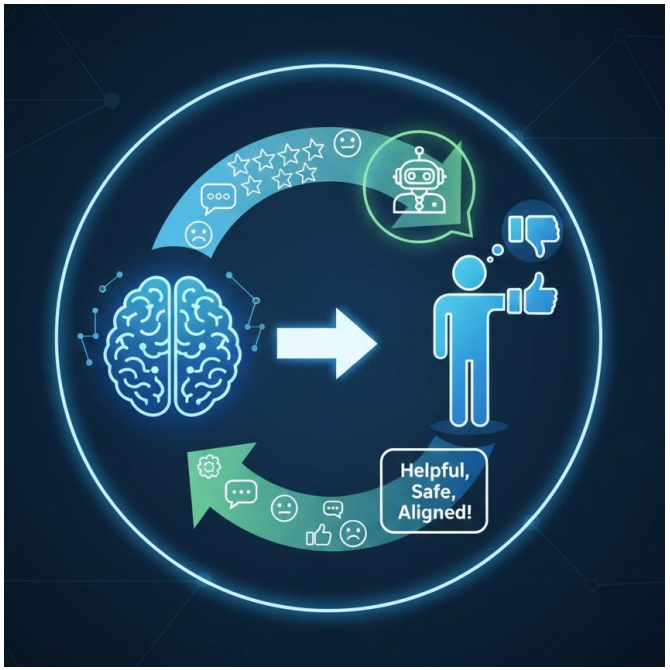
- **Цель**: Научиться следовать конкретным инструкциям, таким как ответы на вопросы, суммаризация и перевод.
- **Метод**: Обучение на высококачественных наборах данных, состоящих из пар (вопрос, ответ).
- **Результат**: Формат чат-бота, способного понимать намерения пользователя (модель, настроенная на инструкции).



Шаг 3: RLHF* (обучение с подкреплением на основе человеческих предпочтений)

«Изучение предпочтений людей»

- **Цель**: привести поведение модели в соответствие с человеческими ценностями, предпочтениями и стандартами безопасности.
- **Метод**:
  - Люди оценивают ответы модели и предоставляют обратную связь (например, ранжируют ответы).
  - Модель оптимизируется с использованием обучения с подкреплением на основе этой обратной связи.
- **Результат**: полезный, безопасный и согласованный помощник, подходящий для реального взаимодействия (согласованная модель).



*) Reinforcement Learning from Human Feedback