Раздел 1.

Эволюция и основы генеративного ИИ

1.1.1. Тенденции ИИ и генеративного ИИ

1.1.2. Эволюция и определение генеративного ИИ

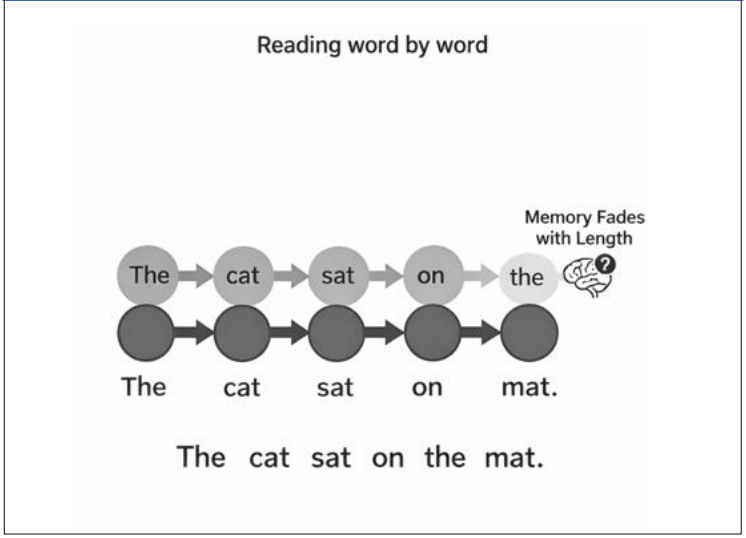
1.1.3. Базовые технологии: Transformer и Diffusion

1.1.4. Применение в индустрии и кейсы Samsung

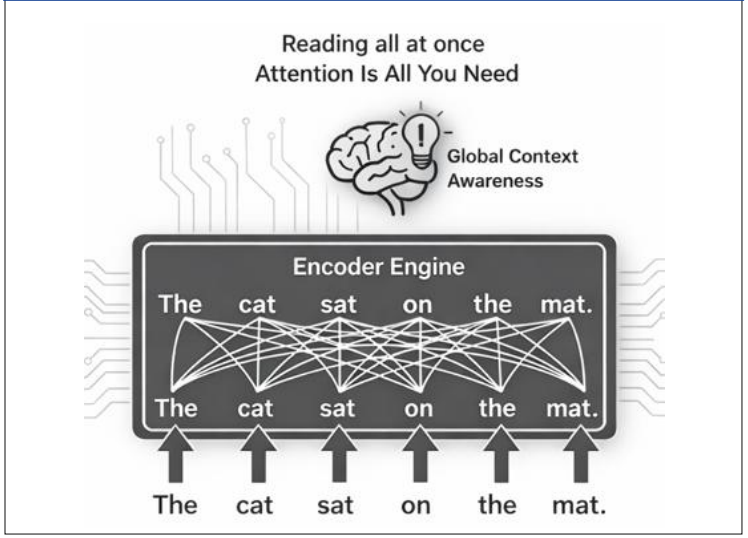
Появление технологии Transformer (2017)

- До: чтение слово за словом
- После: чтение всего предложения сразу
- Хронология: RNN/LSTM* → Transformer

До: RNN/LSTM (последовательная обработка)



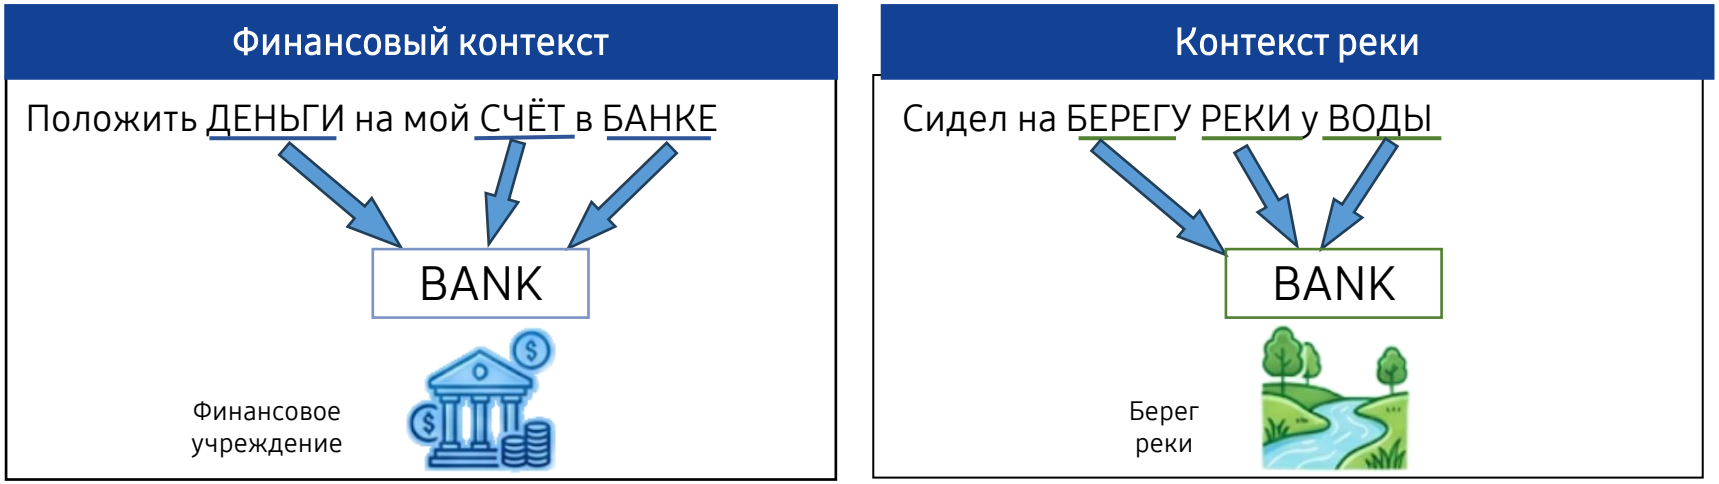
После: Transformer (параллельная обработка)



*) RNN — Recurrent Neural Network (Рекуррентная нейронная сеть)
LSTM — Long Short-Term Memory (Долгая краткосрочная память)

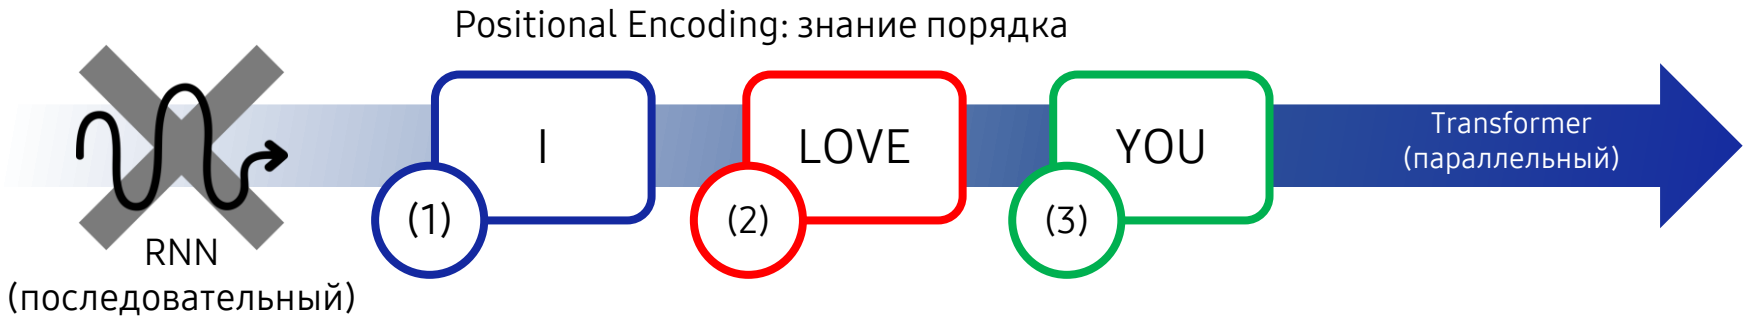
Механизм 1: Self-Attention

- Контекст определяет значение.
- Внимание: фокус на значимых словах.



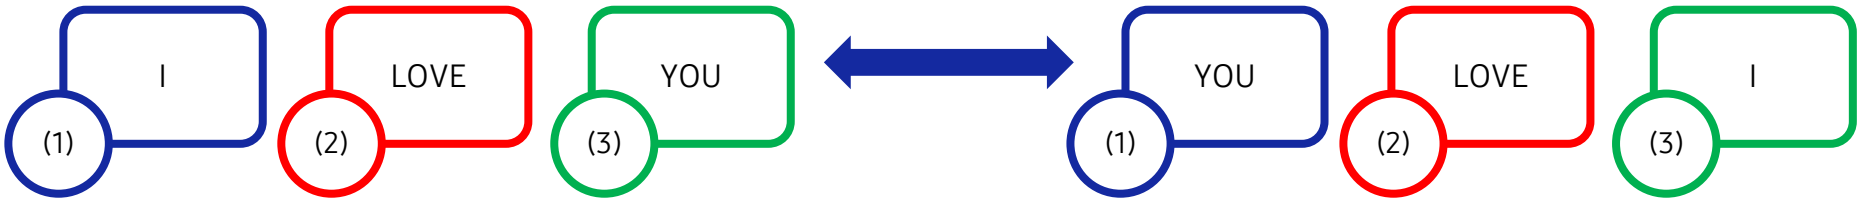
[Концептуальное определение]: Self-Attention позволяет каждому слову определять своё значение путём оценки его связей со всеми остальными словами в том же предложении.
[Формальное (техническое) определение]: Self-Attention вычисляет веса внимания с помощью Query, Key и Value — векторов, полученных из одной входной последовательности. (Vaswani et al., 2017)

Механизм 2: Positional Encoding

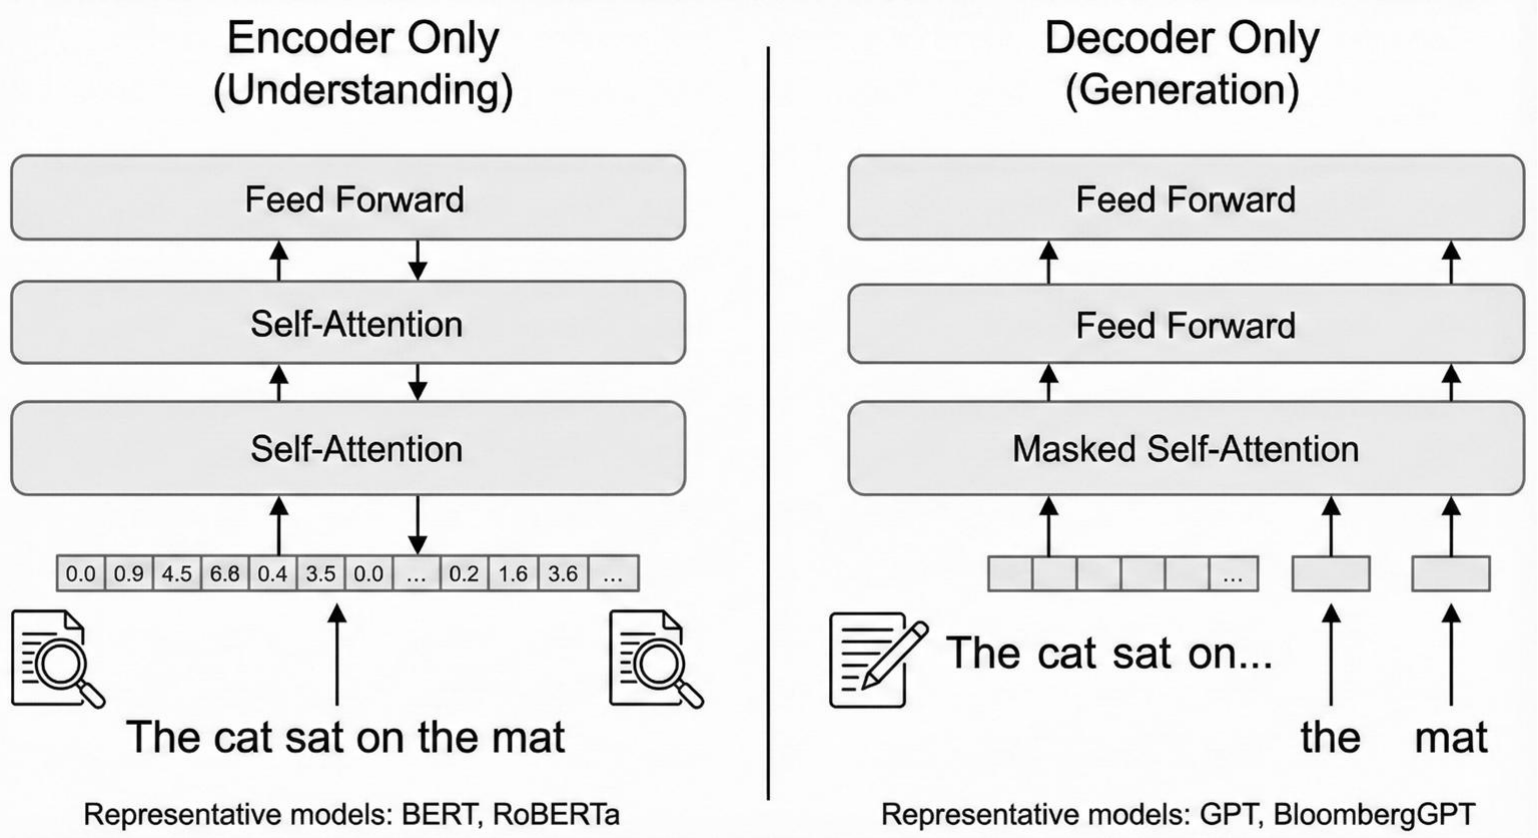


Текст: в отличие от RNN, Transformer читает параллельно.
Решение: каждому слову присваивается уникальный «ID позиции».

‘I(1) LOVE(2) YOU(3)’ Определение значения с помощью тегов позиции ‘YOU(1) LOVE(2) I(3)’



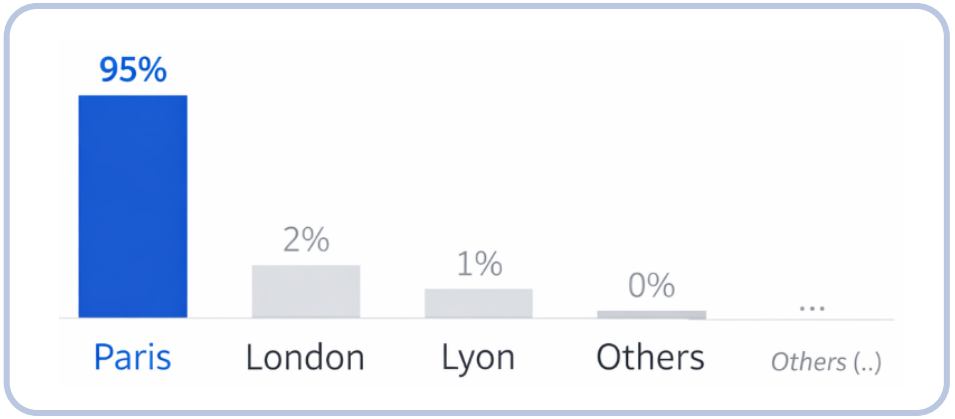
Типы архитектур (Encoder/Decoder)



Механизм 3: предсказание следующего токена

- Ввод: столица Франции — _____
- Предсказания:
  - Париж (95%)
  - Лондон (2%)
  - Лион (1%)

Вероятностное распределение следующих токенов



[Концептуальное определение]: предсказание следующего токена генерирует текст путём вычисления статистической вероятности того, какое слово с наибольшей вероятностью следует за предыдущей последовательностью.

[Формальное (техническое) определение]: модель вычисляет распределение вероятностей по словарю, чтобы выбрать токен с наибольшей условной вероятностью. $P(w_t \mid w_\{1{:}\,t-1\})$

Мощь контекстного окна

- Контекстная память ИИ эволюционировала от нескольких предложений до обработки целых книг за один раз.

Прошлое (напр., GPT-2)



Малый контекст
(несколько предложений)

Взрывной рост размера

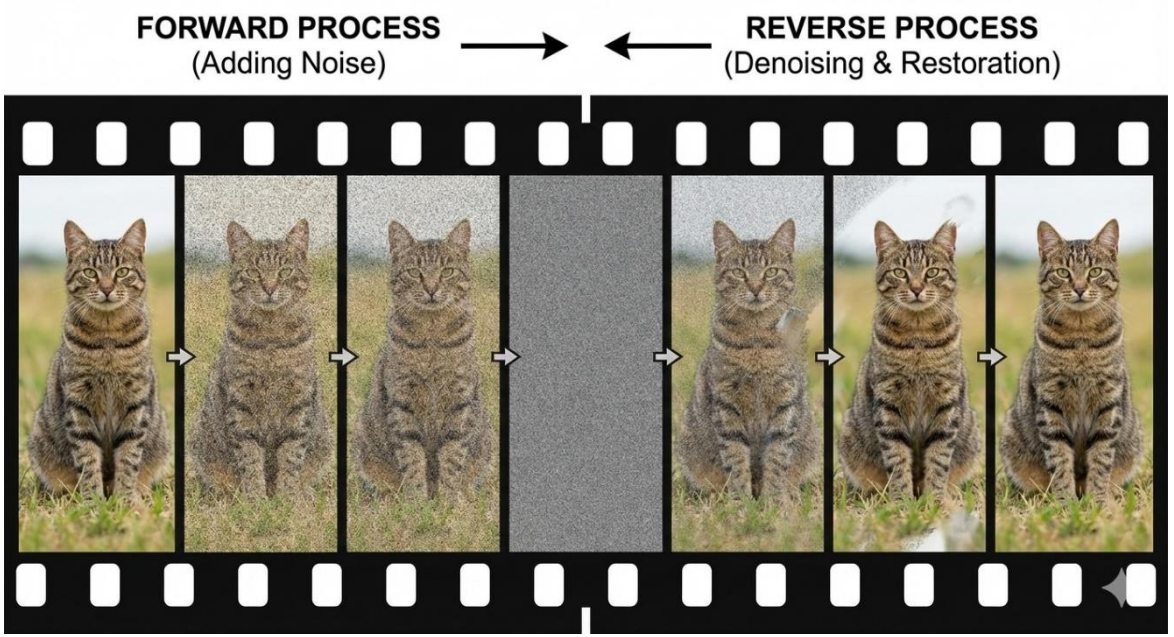
Настоящее (напр., Gemini)



Огромный контекст
(целые книги/библиотеки)

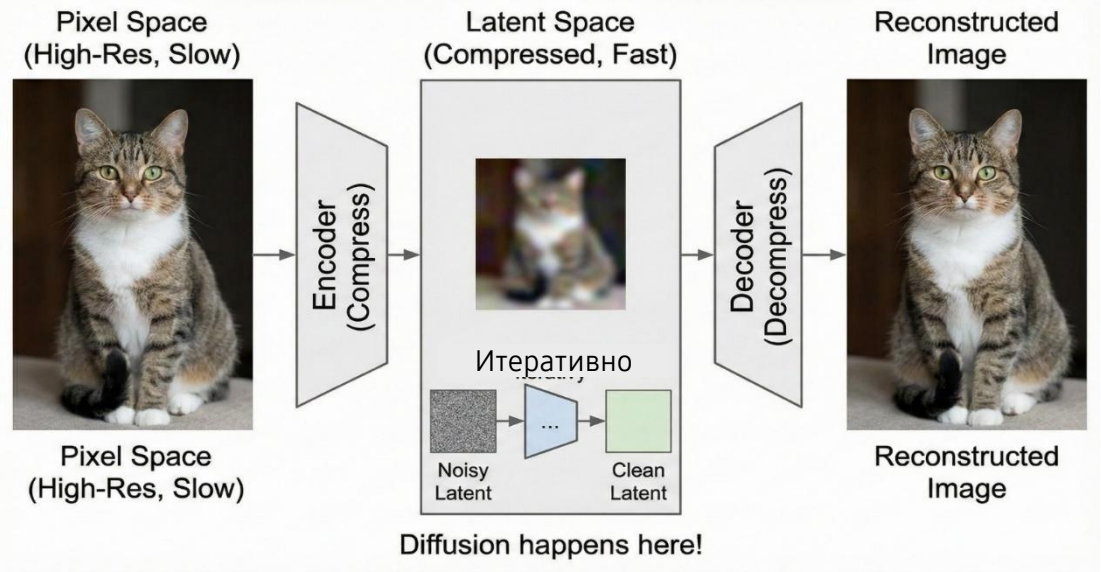
Diffusion: от шума к изображению

- Учится убирать шум.
- Создаёт форму из хаоса.



Эффективность: латентное пространство

- Латентное пространство (latent space) максимизирует эффективность и ускоряет генерацию, сжимая высокодетальные данные в компактное управляемое пространство. Это скрытое представление данных, в котором сложная информация (картинки, тексты, звуки) сжата в набор числовых характеристик.



Два столпа генеративного ИИ

Понять двигатель, чтобы ездить лучше.

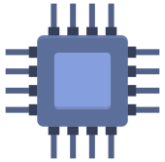
Transformer (текст/код)



Внимание:
Фокус на контексте



Роль:
Предсказание следующего токена

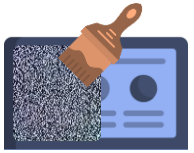


Ключевые игроки:
GPT-4, Samsung Gauss Language

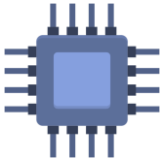
Diffusion (изображения/видео)



Ключевое слово:
Шумоподавление



Роль:
Восстановление изображений из шума



Ключевые игроки:
Stable Diffusion, Samsung Gauss Image